

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Minería de Datos

Semestre I – 2026



Laboratorio 2 (avance)

Integrantes:

Ciprian Jimenez, Mishell Rosa Elvira – 231169
Nájera Marakovits, Ingrid Nina Alessandra - 231088
Ramírez Velásquez, Diego Alejandro – 23601

1. Clustering

Link del repositorio: <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Laboratorio2>

- **Preprocesamiento**

Se trabajó con el dataset de películas movies_2026.csv, el cual tiene 19,883 registros y 28 columnas.

Para preparar los datos para clustering, primero se eliminaron variables que no aportan al agrupamiento porque son identificadores, texto, fechas sin transformar o variables categóricas no codificadas. Estas variables no son adecuadas para calcular distancias entre observaciones.

- **Variables eliminadas**

- id
- genres
- homePage
- productionCompany
- productionCompanyCountry
- productionCountry
- director
- actors
- actorsPopularity
- actorsCharacter
- originalTitle
- title
- originalLanguage
- releaseDate
- Video

- **Variables utilizadas para clustering**

- budget
- revenue
- runtime
- popularity
- voteAvg
- voteCount
- genresAmount
- productionCoAmount
- productionCountriesAmount
- actorsAmount
- castWomenAmount
- castMenAmount
- ReleaseYear

- **Manejo de valores nulos**

Se revisaron valores faltantes en las variables seleccionadas. Se encontraron nulos en:

- castWomenAmount: 37
- castMenAmount: 162
- releaseYear: 2

Las demás variables no presentaron nulos.

Para asegurar consistencia en el análisis, se eliminaron las filas con valores faltantes. Después de esto, el dataset quedó con 19,719 registros y 13 variables.

- **Estandarización de datos**

Finalmente, se aplicó estandarización a las variables numéricas para que todas quedaran en la misma escala. Esto es importante en clustering porque variables con valores grandes podrían dominar el cálculo de distancias si no se escalan.

- **Tendencia al agrupamiento**

Antes de aplicar algoritmos de clustering, se evaluó si los datos presentan una estructura agrupable.

- **Estadístico de Hopkins**

Se calculó el estadístico de Hopkins y se obtuvo:


- Hopkins = 0.9869

Este valor es muy cercano a 1, lo cual indica una fuerte tendencia al agrupamiento. Esto sugiere que los datos no están distribuidos de forma aleatoria y que sí tiene sentido aplicar técnicas de clustering.

- **VAT (Visual Assessment of Tendency)**

También se generó una visualización tipo VAT para analizar visualmente la estructura de agrupamiento.

Figura 1. Gráfico VAT




En el gráfico VAT se observan zonas y bloques con cambios de intensidad, lo que sugiere la presencia de grupos naturales dentro de los datos. Aunque no se ven bloques perfectamente definidos, la visualización sí refuerza el resultado del estadístico de Hopkins y apoya la idea de que el dataset tiene estructura para clustering.

- **Número de clústeres**

Para estimar el número adecuado de clústeres, se utilizó el método del codo, calculando la inercia para valores de k entre 1 y 10.

Figura 2. Gráfico de codo



En la gráfica del codo se observa una disminución fuerte de la inercia entre $k = 1$ y $k = 4$, y a partir de ese punto la mejora comienza a ser menor y más gradual.

- **Justificación del número de clústeres**

Con base en la forma de la curva, se identifica un punto de inflexión alrededor de $k = 4$, por lo que se propone usar 4 clústeres como cantidad inicial para el análisis.

Esta elección permite un buen balance entre:

- reducir la inercia
- evitar usar demasiados grupos
- mantener una interpretación más clara de los resultados

- **k-medias y clustering jerárquico**

Tamaño de los clusters

K-Means:

- Cluster 2: 8,656 películas
- Cluster 0: 6,710 películas
- Cluster 1: 3,856 películas
- Cluster 3: 497 películas


Jerárquico:

- Cluster 4: 8,585 películas
- Cluster 1: 8,393 películas
- Cluster 2: 2,396 películas
- Cluster 3: 345 películas

Comparación

- Ambos métodos generan un grupo muy grande y uno muy pequeño.
- K-Means presenta una distribución ligeramente más balanceada.
- El jerárquico tiende a formar un cluster muy dominante.

- **calidad del agrupamiento**



Se evaluó la calidad del agrupamiento mediante el índice de silueta.

Silhouette K-Means: 0.3197

Silhouette Jerárquico: 0.3286

Interpretación

Ambos valores se encuentran en el rango 0.3 – 0.5, lo que indica:

- Existe estructura de agrupamiento.
- La separación es moderada.
- No hay clusters completamente separados, pero sí diferenciación clara.

El clustering jerárquico presenta un valor ligeramente mayor (0.3286), por lo que muestra una separación marginalmente mejor.

Sin embargo, dado que la diferencia es pequeña, se puede optar por K-Means debido a:

- Mayor estabilidad
- Mayor simplicidad interpretativa
- Mejor balance en tamaños de grupos

- **Interpretación los grupos**

	budget	revenue	runtime	popularity	voteAvg	voteCount	genresAmount	productionCoAmount	productionCountriesAmount	actorsAmount	castWomenAmount	castMenAmount
cluster_kmeans												
0	2.468372e+06	4.679009e+06	89.023994	36.891875	6.430225	276.726677	2.400745	2.424441	1.760209	13.909985	3.978390	24101.776155
1	2.719439e+07	6.920589e+07	110.485477	36.799680	6.629798	1808.845695	2.742998	3.848548	1.512189	40.636670	10.183351	35.024896
2	5.355115e+03	1.484243e+03	25.400531	0.523389	0.361139	0.194085	1.174561	0.608364	0.666474	3.387015	0.449284	36.841266
3	1.316976e+08	5.507711e+08	123.223340	244.592698	7.008491	9259.418511	3.219316	3.824950	1.498994	61.712274	13.334004	31.338028

castWomenAmount	castMenAmount	releaseYear	cluster_jerarquico
3.978390	24101.776155	2015.525484	3.834277
10.183351	35.024896	2001.133558	3.050052
0.449284	36.841266	2025.203212	1.164164
13.334004	31.338028	2010.861167	2.000000

Cluster 2 – Producciones muy pequeñas / datos atípicos

- Budget promedio: 5,355
- Revenue promedio: 1,484
- Runtime promedio: 25 minutos
- Popularidad: 0.52
- VoteAvg: 0.36
- VoteCount: prácticamente 0
- Año promedio: 2025

Este grupo representa producciones extremadamente pequeñas o posiblemente registros incompletos.

Podrían tratarse de cortometrajes, proyectos no comerciales o datos poco consolidados.

Cluster 0 – Producciones pequeñas comerciales

- Budget: 2.4 millones
- Revenue: 4.6 millones
- Runtime: 89 minutos
- VoteAvg: 6.43
- VoteCount: 276
- Año promedio: 2015

Representa películas de bajo presupuesto con desempeño comercial moderado

Cluster 1 – Producciones mediana

- Budget: 27 millones
- Revenue: 69 millones
- Runtime: 110 minutos
- VoteAvg: 6.62
- VoteCount: 1,808
- Año promedio: 2001

Películas comerciales con inversión considerable y buen retorno.

Cluster 3 – Blockbusters

- Budget: 131 millones
- Revenue: 550 millones
- Runtime: 123 minutos
- Popularidad: 244
- VoteAvg: 7.00
- VoteCount: 9,259
- Año promedio: 2010

Este grupo representa grandes producciones de alto presupuesto y alto impacto comercial.

2. PCA:




Figura matriz de correlación

La matriz de correlación muestra la existencia de correlaciones moderadas y altas entre variables del conjunto de datos. Por ejemplo, se observa una fuerte correlación positiva entre el presupuesto (budget) y los ingresos (revenue), así como entre la Cantidad total de actores (actorsAmount) y la cantidad de actrices (castWomenAmount).

Asimismo, se identifican correlaciones entre voteCount y revenue, lo que sugiere que las películas con mayores ingresos tienden a recibir mayor participación de los usuarios. La presencia de estas correlaciones indica redundancia en la información, lo cual justifica la aplicación del Análisis de Componentes Principales para reducir la dimensionalidad del conjunto de datos.

Evaluación de la pertinencia del PCA

Para determinar si era adecuado aplicar el análisis de componentes principales, se calculó el KMO y el test de esfericidad de Bartlett.

El kmo obtenido fue de 0.835, lo cual indica una adecuación muestral buena. Este valor sugiere que las variables comparten suficiente varianza común para justificar la aplicación del PCA.


Por otra parte, el test de esfericidad de Bartlett arrojó un valor de chi-cuadrado de **115646.63** con un **p-value = 0.0** ($p < 0.05$). Esto indica que se rechaza la hipótesis nula

de matriz identidad, confirmando que existen correlaciones significativas entre las variables.

Análisis del Scree Plot

El Scree Plot muestra que el primer componente explica aproximadamente el 37% de la varianza total, seguido de una disminución considerable en los siguientes componentes. A partir del segundo componente, la reducción de varianza explicada se vuelve más gradual.


Esto indica que los primeros componentes concentran la mayor parte de la información relevante del conjunto de datos.



Como se observa en la Figura , la proporción de varianza explicada aumenta progresivamente a medida que se agregan componentes principales.

Se determinó que con **6 componentes principales** se supera el **80% de la varianza total explicada**, lo cual permite reducir las 13 variables numéricas originales a 6 dimensiones principales sin perder una cantidad significativa de información.

Por esta razón, se decidió trabajar con 6 componentes, ya que ofrecen un equilibrio adecuado entre reducción de dimensionalidad y conservación de información relevante del conjunto de datos.



Interpretacion de los componentes principales;

Con base en el analisis de la variaza acumulada se determinó que