

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Minería de datos

Semestre I – 2026



Proyecto 1

Integrantes:

Canastuj Matías, Eliazar José Pablo - 23384

Ciprian Jimenez, Mishell Rosa Elvira – 231169

Lou Schwank, Anthony - 23410

Nájera Marakovits, Ingrid Nina Alessandra - 231088

Ramírez Velásquez, Diego Alejandro – 23601

Enlace del repositorio: <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Proyecto1>

1. Selección de la variable de respuesta

- **Variable respuesta propuesta**

Se propone como variable respuesta la etapa de vida de la pareja al momento del divorcio. Esta variable se construye a partir del promedio de edad de ambos cónyuges, con el objetivo de representar de manera más general el momento del ciclo de vida en el que ocurre el divorcio.

- **Tipo de variable**

La variable respuesta es cualitativa ordinal, ya que se expresa en categorías con un orden natural. En este caso, las categorías representarían etapas de vida, por ejemplo: temprana, intermedia y tardía.

- **Justificación de la elección**

Se eligió esta variable porque permite analizar si existen patrones sociodemográficos asociados a la etapa de vida en la que ocurre el divorcio. Además, es una variable interpretable y útil para construir modelos predictivos, ya que puede relacionarse con otras variables disponibles en el conjunto de datos, como escolaridad, ocupación, nacionalidad, departamento y temporalidad del registro.

- **Transformaciones realizadas**

Para construir la variable respuesta, primero se utilizaron las variables EDADHOM y EDADMUJ, correspondientes a las edades de ambos cónyuges. Estas variables fueron convertidas a formato numérico, ya que algunos registros contenían valores no numéricos o categorías como “Ignorado”. Luego, se consideraron como valores faltantes las edades menores a 15 años o mayores a 100 años, con el fin de evitar registros inconsistentes.

Después de esta limpieza, se eliminaron los registros que no tenían edad válida para alguno de los dos cónyuges, ya que ambas edades eran necesarias para construir la variable respuesta. La base original tenía 71,576 registros y, luego del proceso de limpieza, el conjunto utilizado para el modelado quedó conformado por 34,359 registros válidos.

Posteriormente, se calculó la edad promedio de la pareja mediante la media entre EDADHOM y EDADMUJ. A partir de esta variable numérica se construyó la variable respuesta ETAPA_VIDA_PAREJA, la cual clasifica cada registro en tres categorías: temprana, intermedia y tardía. Para definir estas categorías se utilizó una división por cuantiles, con el objetivo de mantener una distribución balanceada entre clases. Los puntos de corte obtenidos fueron 17.00, 29.00, 35.50 y 81.50 años.

Finalmente, las variables EDADHOM, EDADMUJ y EDAD_PROMEDIO_PAREJA fueron excluidas del conjunto de predictores para evitar fuga de información, ya que la variable respuesta fue construida directamente a partir de ellas.

2. Proyectos similares (investigación)

What Tears Couples Apart: A Machine Learning Analysis of Union Dissolution in Germany

Este estudio analiza la disolución de uniones de pareja en Alemania utilizando datos longitudinales provenientes del German Socio-Economic Panel, que incluye información de más de dos mil parejas. Los autores aplican modelos de Random Survival Forests, con el objetivo de identificar los factores que influyen en la probabilidad de ruptura y estimar cuándo es más probable que ocurra. El análisis incorpora variables individuales y de pareja, como satisfacción de vida, condiciones laborales, distribución del trabajo doméstico y características socioeconómicas, permitiendo modelar relaciones complejas y no lineales en el proceso de disolución.

Predictors of divorce and duration of marriage among first marriage women in Dejne administrative town

(Shita, 2024) Este trabajo examina los factores asociados al divorcio y a la duración del matrimonio en mujeres que contrajeron matrimonio por primera vez en Etiopía. Para ello, utiliza una combinación de regresión logística binaria para modelar la ocurrencia del divorcio y un modelo de supervivencia Gompertz para analizar el tiempo hasta la disolución del matrimonio. El estudio considera variables demográficas, sociales y familiares, como edad al matrimonio, número de hijos, nivel educativo y condiciones del hogar, con el fin de identificar qué factores aumentan el riesgo de divorcio y cómo estos influyen en la duración del vínculo conyugal.

Divorce prediction using machine learning algorithms in Ha'il region

Este estudio analiza la predicción del divorcio mediante el uso de diferentes algoritmos de aprendizaje automático, con el objetivo de comparar su desempeño. Para ello, se utiliza un conjunto de datos basado en evaluaciones de terapia de pareja, que incluye múltiples variables relacionadas con la relación y el comportamiento de los cónyuges.

En la investigación se aplican modelos como redes neuronales artificiales (ANN), Naive Bayes y Random Forest. Los resultados muestran que las redes neuronales alcanzan la mayor precisión, aproximadamente un 96%, lo que evidencia la capacidad

de estos modelos para capturar relaciones complejas en los datos y mejorar la predicción del divorcio.

Modelo predictivo de divorcio utilizando Random Forest en datos sociodemográficos

Este trabajo desarrolla un modelo predictivo de divorcio utilizando el algoritmo Random Forest, aplicado a variables sociodemográficas como la edad de los cónyuges, la duración del matrimonio y el número de hijos. El objetivo del estudio es identificar patrones asociados a la disolución del matrimonio y determinar los factores más influyentes. Los resultados evidencian que Random Forest es capaz de capturar relaciones complejas entre variables, logrando un buen desempeño predictivo y permitiendo identificar los principales factores asociados al divorcio en contextos latinoamericanos.

3. Antecedentes

En los últimos años, el análisis del divorcio y la disolución de parejas ha sido abordado mediante distintos enfoques metodológicos que combinan modelos estadísticos tradicionales con técnicas de aprendizaje automático. Estos estudios no solo buscan identificar los factores asociados al divorcio, sino también desarrollar modelos predictivos capaces de capturar patrones complejos en datos sociodemográficos, lo cual resulta clave para problemas de clasificación como el planteado en este proyecto.

Un trabajo relevante en este campo es *“What Tears Couples Apart: A Machine Learning Analysis of Union Dissolution in Germany”*, en el cual se analiza la disolución de parejas utilizando datos longitudinales del German Socio-Economic Panel. Este estudio emplea el algoritmo Random Survival Forest, un modelo basado en árboles que permite capturar relaciones no lineales y manejar múltiples variables simultáneamente. Los resultados muestran que este tipo de modelos tiene una alta capacidad para identificar patrones complejos en la disolución de parejas. Este enfoque es particularmente relevante, ya que evidencia la efectividad de los métodos basados en árboles —como Random Forest y Gradient Boosting— en problemas donde existen interacciones complejas entre variables, tal como ocurre en el conjunto de datos de este proyecto. (Arpino, Le Moglie, & Mencarini, 2022)

Por otro lado, el estudio *“Predictors of divorce and duration of marriage among first married women in Ethiopia: the application of survival and binary logistic regressions”* aborda el problema desde un enfoque estadístico, utilizando regresión logística binaria y modelos de supervivencia. Este trabajo demuestra que variables como la edad, el nivel educativo y el número de hijos influyen significativamente en la probabilidad de divorcio. La relevancia de este estudio radica en el uso de modelos interpretables, lo cual respalda la elección de la regresión logística ordinal en este

proyecto, ya que permite analizar cómo las variables influyen en la probabilidad de pertenecer a distintas categorías ordenadas de la variable respuesta. (Shita, 2024)

En el ámbito del aprendizaje automático, el estudio *“Divorce prediction using machine learning algorithms in Ha’il region”* presenta una comparación entre distintos algoritmos, incluyendo redes neuronales artificiales (ANN), Naive Bayes y Random Forest. Los resultados indican que las redes neuronales alcanzan una precisión cercana al 96%, evidenciando su capacidad para capturar relaciones complejas entre variables. Este tipo de resultados refuerza la importancia de considerar modelos capaces de manejar no linealidad e interacciones complejas, como los métodos de Gradient Boosting, los cuales comparten esta capacidad, pero con mejor desempeño en datos tabulares como los utilizados en este proyecto. (Moumen, Shafqat, & Alraqad, 2024).

Asimismo, en el contexto latinoamericano se han desarrollado investigaciones que utilizan algoritmos de aprendizaje automático para analizar el divorcio a partir de variables sociodemográficas. Un ejemplo de ello es el estudio *“Modelo predictivo de divorcio utilizando Random Forest en datos sociodemográficos”*, en el cual se emplea este algoritmo para identificar patrones asociados a la disolución del matrimonio. Los resultados evidencian que Random Forest permite capturar relaciones no lineales y manejar datos heterogéneos de manera eficiente. Este hallazgo es especialmente relevante, ya que el conjunto de datos del presente proyecto presenta características similares, como la combinación de variables categóricas y numéricas, lo cual respalda la selección de modelos basados en árboles dentro de los algoritmos a evaluar. (Gálvez Mora, 2025)

En conjunto, los estudios revisados muestran que no existe un único enfoque para abordar el análisis del divorcio, sino que diferentes tipos de modelos aportan ventajas específicas. Los modelos estadísticos tradicionales ofrecen interpretabilidad, mientras que los algoritmos de aprendizaje automático permiten mejorar el desempeño predictivo al capturar relaciones complejas. Esta evidencia respalda la estrategia adoptada en este proyecto de combinar distintos enfoques, incluyendo modelos interpretables como la regresión logística ordinal y modelos más robustos como Random Forest y Gradient Boosting.

Para el presente proyecto, estos antecedentes son fundamentales, ya que el objetivo es predecir la **etapa de vida de la pareja al momento del divorcio**, lo cual corresponde a un problema de clasificación ordinal. A partir de la literatura revisada, se justifica la selección de algoritmos que permitan tanto interpretar los resultados como capturar patrones complejos en los datos, asegurando así un balance entre explicabilidad y desempeño predictivo.

Para sintetizar los principales enfoques utilizados en los estudios revisados, se presenta la siguiente tabla comparativa:

Estudio	Tipo de Modelo	Variables utilizadas	Aporte principal
---------	----------------	----------------------	------------------

What Tears Couples Apart: A Machine Learning Analysis of Union Dissolution in Germany	Random Survival Forest	Variables socioeconómicas y de pareja	Captura relaciones no lineales en la disolución
Predictors of divorce and duration of marriage among first marriage women in Dejne administrative town	Regresión logística + supervivencia	Edad, educación, hijos	Alta interpretabilidad
Divorce prediction using machine learning algorithms in Ha'il region, KSA	ANN, Naive Bayes, Random Forest	Variables de comportamiento de pareja	ANN logra mayor precisión (~96%)
Modelo de predicción de divorcio en el Ecuador basado en algoritmos de aprendizaje de máquina	Random Forest	Variables sociodemográficas	Identificación de factores clave en Latinoamérica

Tabla 1 comparativa de artículos

4. Algoritmos de aprendizaje más útiles

Dado que la variable respuesta propuesta es la etapa de vida de la pareja al momento del divorcio, definida como una variable cualitativa ordinal, el problema a resolver corresponde a una clasificación ordinal. Esta variable fue construida a partir del promedio de edad de ambos cónyuges, agrupado en categorías ordenadas según la distribución observada en el análisis exploratorio.

Además, el conjunto de datos contiene 71,576 observaciones y 23 variables, con una combinación de variables categóricas y numéricas. Entre ellas destacan variables demográficas, geográficas y temporales, así como las edades de ambos cónyuges, que muestran una relación positiva fuerte entre sí. Estas características sugieren que conviene evaluar algoritmos capaces de trabajar bien con datos heterogéneos, posibles relaciones no lineales y clases ordinales.

4.1. Regresión logística multiclase

La regresión logística multiclase es un modelo lineal utilizado para problemas de clasificación con más de dos categorías. En este proyecto se utiliza como modelo base, ya que permite comparar el desempeño de modelos más complejos contra una alternativa más simple e interpretable.

Aunque la variable respuesta tiene un orden natural, porque sus categorías representan etapas de vida de la pareja, la implementación utilizada trata el problema como una clasificación multiclase. Esto significa que el modelo no aprovecha explícitamente la ordinalidad de las categorías, pero sigue siendo útil para evaluar qué tan bien pueden separarse las clases a partir de las variables disponibles.

Su principal ventaja es que permite obtener un modelo más sencillo, estable y fácil de interpretar. Además, ayuda a identificar si las relaciones entre las variables predictoras y la variable respuesta pueden ser capturadas mediante un enfoque lineal. Sin embargo, su principal limitación es que puede quedarse corto cuando existen relaciones no lineales o interacciones complejas entre variables, como suele ocurrir en datos sociodemográficos.

Por esta razón, en este proyecto se utiliza como modelo de comparación frente a modelos de ensamble más flexibles, como Random Forest y XGBoost.

4.2 Bosques aleatorios (Random Forest)

El algoritmo **Random Forest** también es una muy buena alternativa para este problema. Este método construye múltiples árboles de decisión y combina sus resultados, lo que suele producir modelos más robustos y con mejor capacidad predictiva que un árbol individual.

Su utilidad en este caso radica en que puede capturar relaciones complejas entre variables, manejar interacciones entre atributos demográficos y geográficos, y trabajar bien con grandes volúmenes de datos como el conjunto analizado. También es menos sensible al ruido y al sobreajuste que un árbol de decisión simple.

Otra ventaja importante es que permite obtener medidas de **importancia de variables**, lo cual ayudaría a identificar cuáles factores explican mejor la etapa de vida de la pareja al momento del divorcio. Por ejemplo, podría revelar si la escolaridad, la nacionalidad, el departamento o ciertas variables temporales tienen más peso que otras.

Como limitación, Random Forest no modela explícitamente la naturaleza ordinal de la variable respuesta, sino que la trata como una clasificación categórica general.

Aun así, sigue siendo una opción muy útil por su buen desempeño predictivo y su capacidad para manejar estructuras complejas en los datos.

4.3 Gradient Boosting

Los modelos de **Gradient Boosting**, como XGBoost, LightGBM o CatBoost, estos son otra alternativa altamente recomendable. Estos algoritmos construyen árboles secuenciales donde cada nuevo árbol corrige errores del anterior, lo que suele producir muy buen rendimiento predictivo.

Para este proyecto son especialmente útiles porque:

- manejan bien bases de datos grandes,
- capturan relaciones no lineales e interacciones complejas,
- suelen superar en precisión a modelos lineales,
- y pueden adaptarse bien a variables categóricas y numéricas.

Dentro de esta familia, **CatBoost** sería una opción especialmente atractiva si se trabaja con muchas variables categóricas, ya que fue diseñado precisamente para este tipo de datos. En su conjunto de divorcios, gran parte de las variables disponibles son categóricas, como departamento, municipio, nacionalidad, escolaridad, pueblo, ocupación y grupo étnico. Por ello, un modelo de boosting puede aprovechar de mejor forma la información disponible.

Su principal desventaja es que suele ser menos interpretable que la regresión ordinal y requiere ajuste de hiperparámetros. Sin embargo, si el objetivo principal es obtener la mejor capacidad predictiva posible, probablemente sea uno de los candidatos más fuertes.

4.4 Árbol de decisión

Un **árbol de decisión** también puede considerarse como algoritmo candidato, especialmente por su simplicidad e interpretabilidad. Este modelo genera reglas claras del tipo “si la escolaridad es X y el departamento es Y, entonces la pareja pertenece a cierta etapa de vida”, lo que facilita mucho la explicación de resultados.

No obstante, los árboles individuales suelen ser inestables y más propensos al sobreajuste que métodos ensamblados como Random Forest o Gradient Boosting. Por ello, aunque es valioso como punto de comparación y como modelo fácil de explicar, normalmente no sería la mejor opción final si se busca maximizar desempeño predictivo.

5. Selección final de los tres algoritmos a utilizar

Con base en las características del problema y del conjunto de datos, se propone trabajar con los siguientes tres algoritmos:

1. Regresión logística multiclase

Se selecciona porque permite construir un modelo base interpretable para un problema de clasificación con tres categorías. Aunque no modela explícitamente el orden de la variable respuesta, permite comparar el desempeño de modelos más complejos contra un enfoque lineal y sencillo.

2. Random Forest

Se selecciona porque puede manejar relaciones no lineales, múltiples variables categóricas y una base de datos grande. También ofrece una medida útil de importancia de variables.

3. Gradient Boosting (preferiblemente CatBoost o XGBoost)

Se selecciona porque suele ofrecer alto rendimiento predictivo en problemas tabulares, especialmente cuando existen muchas variables categóricas y relaciones complejas entre los predictores.

Para sintetizar las características de los algoritmos seleccionados, se presenta la siguiente tabla:

Algoritmo	Tipo	Ventajas	Desventajas	Uso en el proyecto
Regresión logística multiclase	Modelo lineal de clasificación	Alta interpretabilidad y bajo riesgo de sobreajuste	No captura bien relaciones complejas ni modela directamente la ordinalidad	Modelo base explicativo
Random Forest	Ensamble de árboles	Maneja datos heterogéneos y relaciones no lineales	No considera explícitamente la ordinalidad	Modelo predictivo principal
XGBoost	Ensamble secuencial	Alta capacidad predictiva y captura de interacciones complejas	Menos interpretable y más propenso al sobreajuste si no se controla	Modelo de alto rendimiento

Tabla 2. Comparación de algoritmos de aprendizaje seleccionados.

6. Justificación de la selección

La combinación de estos tres algoritmos permite comparar enfoques complementarios:

- un modelo **estadístico e interpretable** que respeta la naturaleza ordinal de la respuesta,
Un modelo **ensamblado robusto** y fácil de analizar,
y un modelo **más potente predictivamente** para capturar patrones complejos.

De esta forma, la comparación entre los tres permitirá identificar cuál logra el mejor equilibrio entre **interpretabilidad, manejo de la ordinalidad y desempeño predictivo**.

7. Preprocesamiento del conjunto de datos

Antes de entrenar los modelos se realizó un preprocesamiento general del conjunto de datos. Primero, se limpiaron las edades de ambos cónyuges, convirtiendo las variables EDADHOM y EDADMUJ a formato numérico. Los valores menores a 15 años o mayores a 100 años fueron tratados como valores faltantes, ya que se consideraron inconsistentes para el contexto del problema. Luego, se eliminaron los registros que no tenían edad válida para alguno de los dos cónyuges.

Después de construir la variable respuesta, se definió el conjunto de predictores eliminando ETAPA_VIDA_PAREJA, EDAD_PROMEDIO_PAREJA, EDADHOM y EDADMUJ. Estas últimas tres variables fueron retiradas para evitar fuga de información, debido a que la variable respuesta fue creada directamente a partir de las edades.

El conjunto final de predictores quedó formado por 21 variables. Las variables numéricas consideradas fueron DIAOCU, AÑOOCU y AÑOREG. El resto de variables fueron tratadas como categóricas, incluyendo variables geográficas, temporales, de nacionalidad, escolaridad, ocupación, pueblo y grupo étnico.

Para poder aplicar los modelos correctamente, las variables numéricas fueron imputadas con la mediana y las variables categóricas fueron imputadas con la categoría más frecuente. Posteriormente, las variables categóricas fueron transformadas mediante One-Hot Encoding. Este preprocesamiento permitió que los modelos pudieran trabajar con variables numéricas y categóricas de forma adecuada.


8. Método utilizado para obtener los conjuntos de entrenamiento y prueba

Para obtener los conjuntos de entrenamiento y prueba se utilizó la función `train_test_split`. Se asignó el 70% de los datos al conjunto de entrenamiento y el 30% al conjunto de prueba. En total, el conjunto de entrenamiento quedó conformado por

24,051 observaciones, mientras que el conjunto de prueba quedó conformado por 10,308 observaciones.

Debido a que la variable respuesta es categórica, se utilizó muestreo estratificado mediante el parámetro `stratify=y`. Esto permitió conservar la misma proporción de clases en el conjunto total, en el conjunto de entrenamiento y en el conjunto de prueba. Como resultado, las tres clases mantuvieron una distribución balanceada: aproximadamente 34.40% para la clase temprana, 32.28% para la clase intermedia y 33.32% para la clase tardía.

Esto indica que la partición realizada no introdujo desbalance entre los conjuntos y permite evaluar los modelos de forma más justa, ya que ninguna clase queda sobrerrepresentada o subrepresentada en entrenamiento o prueba.



Grafica 1. Balance de clases en conjunto total, entrenamiento y prueba

Dado que la variable respuesta es categórica ordinal, se aplicó un muestreo estratificado con el objetivo de preservar la distribución de clases en ambos conjuntos. Como se observa en la gráfica de balance de clases, las proporciones de cada categoría se mantienen prácticamente idénticas en el conjunto total, de entrenamiento y de prueba, con aproximadamente 34.40% para la clase temprana, 32.28% para la intermedia y 33.32% para la tardía. Esto indica que los datos se encuentran balanceados y que la partición realizada no introduce sesgos en la representación de las clases, lo cual es fundamental para garantizar una evaluación justa del desempeño de los modelos y evitar que estos se vean influenciados por desbalances en la variable respuesta.


9. Resultados de los algoritmos utilizados

Para la evaluación de los modelos predictivos se emplearon tres algoritmos de aprendizaje automático: Random Forest, XGBoost y Regresión Logística multiclase. Para cada algoritmo se entrenaron tres configuraciones distintas, variando sus hiperparámetros principales con el objetivo de identificar el mejor balance entre capacidad predictiva y generalización.

En Random Forest se modificó la cantidad de árboles, la profundidad máxima y el número mínimo de observaciones por hoja. En XGBoost se modificó la cantidad de estimadores, la profundidad máxima, la tasa de aprendizaje y el porcentaje de submuestreo. En Regresión Logística se modificó el parámetro de regularización C y el número máximo de iteraciones.

Para evaluar los modelos se utilizaron las métricas accuracy, balanced accuracy y F1 macro. La métrica principal fue F1 macro, ya que permite evaluar el desempeño promedio entre las tres clases sin favorecer únicamente a la clase mayoritaria. Además, se calculó la diferencia entre F1 macro de entrenamiento y F1 macro de prueba, con el fin de revisar posibles señales de sobreajuste.


En Random Forest y Regresión Logística se utilizó `class_weight="balanced"`. En XGBoost no se aplicó este parámetro directamente, ya que las clases se encontraban bastante balanceadas después de la construcción de la variable respuesta.



Grafica 2. Comparación de Random Forest


Para Random Forest se varió la cantidad de árboles (`n_estimators`), la profundidad máxima (`max_depth`) y el número mínimo de observaciones por hoja (`min_samples_leaf`), manteniendo `max_features="sqrt"` constante. Las configuraciones evaluadas progresaron desde un modelo simple y restrictivo (120 árboles, profundidad 8, mínimo 30 observaciones por hoja) hasta uno más flexible sin restricción de

profundidad (220 árboles, mínimo 8 observaciones por hoja), pasando por una configuración intermedia.



Grafica 3. Comparación de XGBoost

Para XGBoost se varió la cantidad de rondas de boosting ($n_estimators$), la profundidad máxima de cada árbol (max_depth), la tasa de aprendizaje ($learning_rate$) y la fracción de datos utilizada por árbol ($subsample$). Las configuraciones fueron desde una conservadora con pocos árboles, baja tasa de aprendizaje y submuestreo del 80% (100 árboles, profundidad 3, learning rate 0.05), hasta una agresiva con mayor capacidad y sin submuestreo (300 árboles, profundidad 7, learning rate 0.15), con una configuración intermedia entre ambos extremos.



Grafica 4. Comparación de Regresion Logistica

Para Regresión Logística se varió principalmente el parámetro de regularización C , que controla la flexibilidad del modelo: valores bajos implican mayor penalización y un

modelo más simple, mientras que valores altos permiten un ajuste más libre a los datos. Las tres configuraciones evaluadas utilizaron $C=0.01$, $C=0.1$ y $C=1.0$, con un número máximo de iteraciones ajustado progresivamente para garantizar la convergencia del modelo.

Algoritmo	Modelo	Accurac y test	Balance d accuracy test	F1 macro train	F1 macro test	Gap
Random Forest	RF_1_simple	0.4977	0.4933	0.4897	0.4802	0.0095
Random Forest	RF_2_intermedio	0.5045	0.5004	0.5232	0.4895	0.0338
Random Forest	RF_3_mas_flexible	0.5147	0.5112	0.5816	0.5025	0.0792
XGBoost	XGB_1_conservador	0.5062	0.5019	0.4990	0.4861	0.0128
XGBoost	XGB_2_intermedio	0.5145	0.5108	0.5917	0.5013	0.0904
XGBoost	XGB_3_agresivo	0.5129	0.5096	0.6924	0.5026	0.1898
Regresión Logística	LR_1_alta_regularizacion	0.4964	0.4928	0.4881	0.4830	0.0051
Regresión Logística	LR_2_regularizacion_mediana	0.5052	0.5019	0.5028	0.4951	0.0076
Regresión Logística	LR_3_baja_regularizacion	0.5064	0.5028	0.5031	0.4943	0.0088

Tabla 3. Resultados de los modelos evaluados

Como se observa en la Tabla 3, los modelos de Random Forest y XGBoost obtuvieron los valores más altos de F1 macro en prueba. Sin embargo, no solo se consideró el desempeño en prueba, sino también la diferencia entre entrenamiento y prueba. Esto permitió identificar configuraciones con buen rendimiento sin caer en sobreajuste fuerte.

10. Selección del mejor modelo

Para seleccionar el mejor modelo dentro de cada algoritmo se utilizó como métrica principal el F1 macro en prueba. Además, se aplicó como criterio adicional que la diferencia entre el F1 macro de entrenamiento y el F1 macro de prueba no superara 0.10. Este criterio se utilizó para evitar seleccionar modelos con señales claras de sobreajuste.

En el caso de Random Forest, el modelo seleccionado fue RF_3_mas_flexible, con un F1 macro en prueba de 0.5025 y un gap de 0.0792. Este modelo obtuvo el mejor desempeño dentro de las configuraciones de Random Forest y mantuvo una diferencia aceptable entre entrenamiento y prueba. Aunque los modelos más simples tuvieron gaps menores, su capacidad predictiva fue más baja.


En el caso de XGBoost, el modelo seleccionado fue XGB_2_intermedio, con un F1 macro en prueba de 0.5013 y un gap de 0.0904. Aunque XGB_3_agresivo obtuvo un F1 macro en prueba ligeramente mayor, con 0.5026, fue descartado porque presentó un gap de 0.1898. Esto indica que el modelo se ajustó demasiado al conjunto de entrenamiento y no generalizó de la misma forma en el conjunto de prueba.

En el caso de Regresión Logística, el modelo seleccionado fue LR_2_regularizacion_media, con un F1 macro en prueba de 0.4951 y un gap de 0.0076. Este modelo presentó un desempeño ligeramente superior al resto de configuraciones de Regresión Logística según el F1 macro en prueba, además de mostrar una diferencia muy baja entre entrenamiento y prueba. Esto indica que el modelo generaliza bien, aunque su capacidad predictiva es menor que la de los modelos de ensamble.

Algoritmo	Mejor modelo	Accuracy test	Balanced accuracy test	F1 macro test	Gap
Random Forest	RF_3_mas_flexible	0.5147	0.5112	0.5025	0.0792
XGBoost	XGB_2_intermedio	0.5145	0.5108	0.5013	0.0904
Regresión Logística	LR_2_regularizacion_media	0.5052	0.5019	0.4951	0.0076

Tabla 4. Comparación de los mejores modelos por algoritmo

Con base en la comparación de los tres mejores modelos, Random Forest fue seleccionado como el mejor modelo final. Aunque XGBoost obtuvo un desempeño muy similar, Random Forest alcanzó el F1 macro en prueba más alto entre los modelos aceptados por el criterio de gap. Además, su balanced accuracy también fue ligeramente superior. Por esta razón, se considera que RF_3_mas_flexible ofrece el mejor balance entre capacidad predictiva y control del sobreajuste.




Grafica 5. Comparación de los mejores modelos por algoritmo

11. Matrices de confusión


Para complementar la evaluación de los modelos, se analizaron las matrices de confusión de los mejores modelos seleccionados para cada algoritmo. Estas matrices permiten observar no solo el desempeño general, sino también qué clases son confundidas con mayor frecuencia.

En los tres modelos se observa un patrón similar: las clases temprana y tardía son identificadas con mayor facilidad, mientras que la clase intermedia presenta el menor desempeño. Esto tiene sentido, ya que la clase intermedia representa una zona de transición entre los divorcios en etapas más tempranas y tardías, por lo que puede compartir características con ambas categorías.




Grafica 6. Matriz de confusión del mejor modelo Random Forest

En Random Forest, la clase temprana obtuvo un recall de 0.65 y precisión de 0.54, lo que indica que el modelo identifica correctamente la mayoría de las parejas jóvenes, aunque con cierto nivel de falsos positivos provenientes de otras clases. La clase tardía mostró un comportamiento similar con recall de 0.57 y precisión de 0.53. La clase intermedia fue la más problemática, con recall de apenas 0.31 y precisión de 0.44, lo que significa que el modelo clasifica incorrectamente la mayoría de las parejas de esta categoría, confundiéndolas principalmente con las clases adyacentes. Este comportamiento es esperable dado que la clase intermedia comparte características sociodemográficas con ambos extremos al representar un rango de edad de transición.



Grafica 7. Matriz de confusión del mejor modelo XGBoost

XGBoost presentó un patrón muy similar, con una leve mejora en la clase temprana (recall 0.65, precisión 0.56) respecto a Random Forest, y un desempeño prácticamente idéntico en las clases intermedia y tardía. La clase intermedia nuevamente obtuvo el recall más bajo (0.30) y la precisión más baja (0.42) de las tres clases, confirmando que ningún algoritmo logra capturar patrones suficientemente distinguibles para esta categoría con las variables disponibles.



Grafica 8. Matriz de confusión del mejor modelo de Regresión Logística

La Regresión Logística presentó un comportamiento similar al de los modelos de ensamble, aunque con un desempeño general ligeramente menor. Para la clase temprana obtuvo un recall de 0.64, lo que indica que identifica correctamente una proporción importante de los registros de esta categoría. La clase tardía obtuvo un recall de 0.54, mientras que la clase intermedia volvió a ser la más difícil de clasificar, con un recall de 0.32.

Este resultado confirma que la dificultad principal del problema no está únicamente en el tipo de algoritmo utilizado, sino en la separación de las clases a partir de las variables disponibles. La clase intermedia comparte características con las clases temprana y tardía, por lo que tiende a confundirse con ambas.

12. Justificación del Rendimiento

El rendimiento general de los modelos, cercano a 0.50 en F1 macro y alrededor de 50% de accuracy, debe interpretarse dentro del contexto del problema. Aunque estos valores no son extremadamente altos, sí superan el rendimiento esperado de una clasificación aleatoria en un problema de tres clases balanceadas, cuyo baseline aproximado sería 33%.

Además, la variable respuesta fue construida a partir de la edad promedio de la pareja, pero las variables de edad fueron excluidas del conjunto de predictores para evitar fuga de información. Esto significa que los modelos debían predecir la etapa de vida de la pareja utilizando únicamente variables administrativas y sociodemográficas, como departamento, municipio, escolaridad, ocupación, nacionalidad, grupo étnico y temporalidad del registro.

Estas variables pueden estar relacionadas con la etapa de vida al momento del divorcio, pero su relación es indirecta. Por ello, existe un límite natural en la capacidad predictiva de los modelos. Factores que podrían explicar mejor el fenómeno, como duración del matrimonio, ingresos, número de hijos, historia de la relación o condiciones familiares, no se encuentran disponibles en el conjunto de datos.

También es importante notar que los tres algoritmos evaluados mostraron un patrón de resultados bastante parecido. Esto sugiere que el rendimiento observado no depende únicamente de la elección del algoritmo, sino de la información disponible en las variables predictoras. La clase intermedia fue la más difícil de clasificar en todos los modelos, lo cual refuerza la idea de que esta categoría no se separa claramente de las clases temprana y tardía.

En este sentido, el desempeño obtenido no representa una falla del modelado, sino una limitación esperable del problema y del conjunto de datos disponible. Aun así, los modelos logran capturar ciertos patrones por encima del baseline aleatorio, especialmente en la identificación de las clases temprana y tardía.

13. Conclusiones

A partir de los modelos evaluados, Random Forest fue seleccionado como el mejor modelo final, específicamente la configuración RF_3_mas_flexible. Este modelo obtuvo el mayor F1 macro en prueba entre los modelos aceptados por el criterio de sobreajuste, además de presentar la mejor balanced accuracy.

XGBoost presentó un desempeño muy cercano al de Random Forest, pero su configuración más agresiva mostró señales claras de sobreajuste. Por esta razón, se seleccionó la configuración intermedia como la mejor dentro de este algoritmo. Por otro lado, la Regresión Logística mostró el menor gap entre entrenamiento y prueba, lo que indica buena generalización, aunque su desempeño predictivo fue ligeramente menor que el de los modelos de ensamble.

En general, los resultados muestran que sí existen ciertos patrones sociodemográficos relacionados con la etapa de vida de la pareja al momento del divorcio. Sin embargo, la capacidad predictiva está limitada por la naturaleza de las variables disponibles, ya que muchas de ellas tienen una relación indirecta con la edad promedio de la pareja. La clase intermedia fue la más difícil de clasificar, debido a que comparte características con las etapas temprana y tardía.

Por lo tanto, el modelo final permite obtener una predicción mejor que una clasificación aleatoria, pero también evidencia que para mejorar el desempeño sería necesario contar con variables adicionales más relacionadas con la historia de la pareja, como duración del matrimonio, número de hijos, ingresos o condiciones familiares.

Referencias bibliográficas.

- Arpino, B., Le Moglie, M., & Mencarini, L. (febrero de 2022). What Tears Couples Apart: A Machine Learning Analysis of Union Dissolution in Germany. *Demography*, 59, págs. 161-182.
doi:<https://read.dukeupress.edu/demography/article/59/1/161/293326/What-Tears-Couples-Apart-A-Machine-Learning>
- Gálvez Mora, P. G. (2025). *Modelo de predicción de divorcio en el Ecuador basado en algoritmos de aprendizaje de máquina*. Obtenido de Repositorio Universidad de las Américas: <http://dspace.udla.edu.ec/handle/33000/17280>
- Moumen, A., Shafqat, A., & Alraqad, T. (2024). Divorce prediction using machine learning algorithms in Ha'il region, KSA. *Scientific Reports*, 14, pág. 502.
doi:<https://www.nature.com/articles/s41598-023-50839-1>
- Shita, N. Z. (2024). Predictors of divorce and duration of marriage among first marriage women in Dejne administrative town. *Scientific Reports*, 14, pág. 8728.
doi:<https://doi.org/10.1038/s41598-024-59360-5>