

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Minería de datos

Semestre I – 2026



Proyecto 1

Integrantes:

Canastuj Matías, Eliazar José Pablo - 23384

Ciprian Jimenez, Mishell Rosa Elvira – 231169

Lou Schwank, Anthony - 23410

Nájera Marakovits, Ingrid Nina Alessandra - 231088

Ramírez Velásquez, Diego Alejandro – 23601

Enlace del repositorio: <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Proyecto1>

1. Variable respuesta

Para este proyecto se definió como variable respuesta la etapa de vida de la pareja al momento del divorcio. Esta variable se construyó a partir del promedio de edad de ambos cónyuges, usando las variables EDADHOM y EDADMUJ.

Primero, se convirtieron ambas columnas a valores numéricos, ya que en la base algunos registros tenían valores no numéricos como Ignorado. Luego, se eliminaron los registros que no tenían una edad válida para alguno de los cónyuges, ya que no era posible calcular correctamente el promedio de edad de la pareja en esos casos.

La variable auxiliar utilizada fue:

$$EDAD\ PROMEDIO\ PAREJA = \frac{(EDADHOM + EDADMUJ)}{2}$$

Después de realizar la limpieza, la base pasó de 71,576 registros a 34,359 registros válidos. Aunque se eliminaron varios registros, esto fue necesario porque la variable respuesta dependía directamente de las edades de ambos cónyuges.

A partir de EDAD_PROMEDIO_PAREJA, se creó la variable final ETAPA_VIDA_PAREJA. Para formar las categorías se utilizó una división por cuantiles, con el objetivo de que las clases quedaran lo más balanceadas posible. Las categorías obtenidas fueron:

Categoría	Rango de edad promedio
Temprana	17.00 a 29.00
Intermedia	mayor a 29.00 hasta 35.50
Tardía	mayor a 35.50 hasta 81.50

La distribución final de la variable respuesta fue la siguiente:

Etapa de vida	Frecuencia	Porcentaje
Temprana	11,819	34.40%
Intermedia	11,091	32.28%
Tardía	11,449	33.32%

Como se observa, las tres categorías quedaron bastante equilibradas, ya que cada una representa aproximadamente un tercio de los registros válidos. Esto es importante

porque evita que el modelo aprenda principalmente una sola clase y permite que la comparación entre categorías sea más justa.

En conclusión, la variable respuesta `ETAPA_VIDA_PAREJA` es una variable cualitativa ordinal, porque sus categorías tienen un orden natural: temprana, intermedia y tardía. Esta variable permite analizar en qué etapa de vida ocurre el divorcio y relacionarla con otras características disponibles en la base, como escolaridad, ocupación, nacionalidad, departamento y temporalidad del registro.




Gráfico 1. Distribución de la variable respuesta

El gráfico muestra la distribución de la variable `ETAPA_VIDA_PAREJA`, dividida en las categorías temprana, intermedia y tardía. Se observa que las tres clases tienen frecuencias similares, con valores cercanos entre sí. La categoría temprana presenta la mayor cantidad de registros, seguida por la tardía y luego la intermedia. En general, la distribución se puede considerar bastante balanceada, lo cual es positivo para el entrenamiento del modelo, ya que evita que una sola categoría tenga demasiado peso sobre las demás.

2. Entrenamiento y prueba

Para la construcción de los conjuntos de entrenamiento y prueba, se utilizó la función `“train_test_split”`. Se dividieron los datos en 70% para entrenamiento y un 30% para prueba.

Además, se empleó una partición estratificada con el objetivo de conservar la proporción de las categorías de la variable respuesta `ETAPA_VIDA_PAREJA` para ambos conjuntos.

Dado que la variable respuesta es categórica ordinal y fue generada mediante una discretización por cuantiles, las categorías que resultaron presentan una distribución equilibrada. Como se mostró previamente en el Gráfico 1, las tres clases (temprana, intermedia y tardía) tienen frecuencias similares, lo que indica que el conjunto está balanceado.




Gráfico 2. Balance de clases en total, entrenamiento y prueba

El gráfico muestra el porcentaje de registros para cada clase de la variable respuesta en el conjunto total, en entrenamiento y en prueba. Se observa que las tres distribuciones son prácticamente iguales, lo cual indica que la partición estratificada funcionó correctamente. Esto significa que las categorías temprana, intermedia y tardía conservaron proporciones similares después de dividir los datos, evitando que alguno de los conjuntos quedara sesgado hacia una sola clase. Por esta razón, el modelo se entrenó y evaluó con una distribución representativa de la variable respuesta.

3. Algoritmo y preprocesamiento

Para abordar el problema de clasificación de la etapa de vida de la pareja, se utilizó el algoritmo Random Forest. Este modelo fue elegido por su capacidad para manejar variables categóricas y numéricas, así como por su buen desempeño en problemas de clasificación.

Previo al entrenamiento, se realizó un proceso de preprocesamiento de los datos. Primero, se definieron las variables predictoras, excluyendo la variable respuesta (ETAPA_VIDA_PAREJA) y aquellas utilizadas para construirla, como las edades de los cónyuges y su promedio.

Posteriormente, las variables se separaron en numéricas y categóricas. Para el manejo de valores faltantes, se aplicó imputación por mediana en las variables numéricas y por

la categoría más frecuente en las categóricas. Luego, las variables categóricas fueron transformadas mediante One-Hot Encoding, permitiendo su uso en el modelo.

Todo el proceso fue implementado mediante un Pipeline, lo que asegura que las transformaciones se apliquen de forma consistente tanto en entrenamiento como en prueba, evitando fugas de información.

Finalmente, se entrenaron distintos modelos Random Forest variando sus hiperparámetros, evaluando su desempeño con métricas como accuracy, balanced accuracy y F1-score macro.

4. Modelos

Para abordar el problema de clasificación de la etapa de vida de la pareja al momento del divorcio, se construyeron múltiples modelos utilizando el algoritmo Random Forest, variando sus hiperparámetros con el objetivo de encontrar la mejor combinación posible sin incurrir en sobreajuste. En particular, se definieron tres configuraciones distintas que permitieran evaluar el impacto de la complejidad del modelo sobre su desempeño.

modelo	n_estimators	max_depth	min_samples_leaf	max_features	accuracy_train	accuracy_test	balanced_accuracy_test	f1_macro_train	f1_macro_test	gap_f1_train_test
RF_3_mas_flexible	220	None	8	sqrt	0.5905	0.5147	0.5112	0.5816	0.5025	0.0792
RF_2_intermedio	180	15	15	sqrt	0.5362	0.5045	0.5004	0.5232	0.4895	0.0338
RF_1_simple	120	8	30	sqrt	0.5061	0.4977	0.4933	0.4897	0.4802	0.0095

El primer modelo (RF_1_simple) se diseñó como una alternativa más restringida, utilizando 120 árboles, una profundidad máxima de 8 niveles y un mínimo de 30 observaciones por hoja. Este enfoque busca evitar el sobreajuste limitando la capacidad del modelo para capturar patrones complejos. El segundo modelo (RF_2_intermedio) incrementó la complejidad, utilizando 180 árboles, profundidad máxima de 15 y un mínimo de 15 observaciones por hoja, con el objetivo de encontrar un equilibrio entre capacidad predictiva y generalización. Finalmente, el tercer modelo (RF_3_mas_flexible) se configuró con 220 árboles, sin restricción de profundidad y un mínimo de 8 observaciones por hoja, permitiendo al modelo capturar relaciones más complejas en los datos.




Gráfico 3. Comparacion de modelos random forest

Para comparar el desempeño de los modelos, se utilizaron métricas como accuracy, balanced accuracy y F1-score macro, siendo esta última la métrica principal debido a que considera el desempeño de todas las clases por igual. Además, se evaluó la diferencia entre el F1-score en entrenamiento y prueba (gap), con el fin de identificar posibles problemas de sobreajuste. Estos resultados también se complementan con la gráfica de comparación de modelos Random Forest, en la cual se visualiza claramente el comportamiento del F1-score en entrenamiento y prueba para cada modelo. En ella se observa que el modelo más flexible (RF_3_mas_flexible) presenta los valores más altos en ambas métricas, mientras que los modelos más simples muestran un desempeño menor. En términos numéricos, el modelo más simple obtuvo un F1-score en prueba cercano a 0.48, el modelo intermedio alrededor de 0.49, y el modelo más flexible aproximadamente 0.50, confirmando lo observado en la gráfica.

campo	valor
modelo	RF_3_mas_flexible
n_estimators	220
max_depth	None
min_samples_leaf	8
max_features	sqrt
accuracy_train	0.5905
accuracy_test	0.5147
balanced_accuracy_test	0.5112
f1_macro_train	0.5816
f1_macro_test	0.5025
gap_f1_train_test	0.0792

Con base en estos resultados, se seleccionó como modelo final el RF_3_mas_flexible, ya que logra el mejor equilibrio entre desempeño predictivo y generalización. Este modelo alcanza una exactitud aproximada de 0.51, un F1-score macro de 0.50 y una balanced accuracy de 0.51 en el conjunto de prueba. Aunque el desempeño es moderado, supera claramente el nivel esperado y demuestra la capacidad del modelo para capturar patrones relevantes en los datos.

5. Resultados

Para evaluar el modelo final se utilizó el F1-macro como métrica principal, dado que las tres clases, las cuales son temprana, intermedia y tardía. Estas presentan proporciones similares, pero no idénticas. Esta métrica promedia el F1 de cada clase sin ponderar por frecuencia, lo que penaliza de forma equitativa los errores en cualquiera de las tres etapas de vida.

La matriz de confusión permite identificar los patrones de error del modelo. Se espera que las confusiones se concentren entre clases adyacentes, es decir, que una pareja de etapa intermedia sea confundida con temprana o tardía, pero raramente que los extremos se confundan entre sí. Esto se debe a que las clases fueron construidas sobre una variable continua mediante cortes por cuantiles, por lo que los límites entre categorías no son abruptos.

La clase intermedia es la que típicamente presenta mayor dificultad para el modelo, ya que comparte características con ambos extremos en los bordes del intervalo. Las clases temprana y tardía resultan más fáciles de distinguir porque representan rangos de edad bien diferenciados. El uso de `class_weight='balanced'` durante el entrenamiento contribuye a que el modelo no ignore ninguna clase por tener menor representación, mejorando el recall de las clases menos frecuentes.




Gráfico 4. Gráfico de confusión - RF 3 más flexible

La matriz de confusión muestra que el modelo identifica mejor las clases temprana y tardía, con 2301 y 1963 predicciones correctas respectivamente. En cambio, la clase intermedia presenta mayor dificultad, ya que muchos registros reales de esta categoría fueron clasificados como temprana o tardía. Esto tiene sentido porque la clase intermedia se encuentra entre ambos extremos de edad promedio, por lo que puede compartir características con las otras dos categorías. Aun así, la mayor cantidad de aciertos se mantiene sobre la diagonal principal, lo cual indica que el modelo sí logra capturar parte del patrón general de los datos.




Gráfico 5. Top 10 variables más importantes

El gráfico presenta las diez variables con mayor importancia dentro del modelo final Random Forest. Las variables con mayor peso fueron ESCMUJ y ESCHOM, relacionadas con la escolaridad de la mujer y del hombre, seguidas por variables como CIUOHOM, CIUOMUJ, PUEHOM y PUEMUJ. Esto sugiere que las características sociodemográficas de ambos cónyuges aportan información relevante para predecir la etapa de vida de la pareja al momento del divorcio. También aparecen variables geográficas y temporales, como DEPOCU, DEPREG, AÑOREG y MUPOCU, lo que indica que el lugar y año del registro también contribuyen al comportamiento del modelo.