

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Minería de Datos

Semestre I - 2026



Informe final de consultoría **Modelos predictivos para propiedades de Airbnb**

Integrantes:

Ciprian Jimenez, Mishell Rosa Elvira - 231169

Nájera Marakovits, Ingrid Nina Alessandra - 231088

Ramírez Velásquez, Diego Alejandro - 23601

Contenido

1. Resumen ejecutivo
2. Contexto del problema de negocio
3. Descripción y preparación del conjunto de datos
4. Análisis exploratorio de datos
5. Modelos de regresión para estimación de precios
6. Modelos de clasificación para categorías de precio
7. Redes neuronales artificiales
8. Comparación final de algoritmos
9. Análisis de sobreajuste y generalización
10. Recomendaciones para SmartStay Advisors
11. Conclusión final
12. Anexo: repositorios y alcance

1. Resumen ejecutivo

Este informe integra las fases principales de la consultoría desarrollada para SmartStay Advisors, utilizando datos de propiedades de Airbnb. El objetivo general fue transformar la información disponible en insumos útiles para estimar precios competitivos, clasificar propiedades por nivel de precio y apoyar decisiones estratégicas basadas en datos.

El análisis inició con la limpieza del conjunto de datos, la transformación de la variable price a formato numérico y la exploración de patrones asociados al precio. Posteriormente se implementaron modelos de regresión y clasificación, incluyendo árboles de decisión, Naive Bayes, KNN, regresión logística, SVM, Random Forest y redes neuronales artificiales.

Los resultados muestran que, para clasificación, la red neuronal artificial obtuvo el mejor desempeño general, con una exactitud aproximada de 0.7468. Para regresión, el árbol de regresión presentó el mayor R^2 aproximado, pero la red neuronal obtuvo un resultado muy cercano y más equilibrado desde el punto de vista de generalización.

Tabla 1. Resumen ejecutivo de modelos recomendados

Tarea	Mejor modelo recomendado	Métrica principal	Resultado aproximado	Criterio de decisión
Clasificación de precio	Red neuronal artificial	Accuracy	0.7468	Mayor exactitud y buen control del sobreajuste
Predicción de precio	Árbol de regresión / RNA	R^2	0.816 / 0.805	Árbol con mejor métrica; RNA con desempeño cercano y más flexible

2. Contexto del problema de negocio

SmartStay Advisors funciona como una firma intermediaria que facilita la búsqueda y selección de propiedades en Airbnb para clientes corporativos y particulares. Para mejorar sus recomendaciones, la empresa necesita comprender qué factores influyen en el precio, identificar segmentos de propiedades y construir modelos capaces de estimar precios o categorías de precio.

Desde el punto de vista de negocio, los modelos permiten tomar mejores decisiones en tres áreas: estimación de precios competitivos, clasificación de propiedades según su nivel de precio y priorización de alojamientos con características atractivas para distintos perfiles de cliente.

- Estimar precios competitivos para propiedades nuevas o existentes.
- Clasificar propiedades en segmentos de precio para facilitar recomendaciones.
- Identificar variables que explican diferencias de precio entre alojamientos.
- Comparar algoritmos para seleccionar modelos útiles, interpretables y generalizables.

3. Descripción y preparación del conjunto de datos

El conjunto de datos utilizado en las fases principales corresponde a listados de propiedades de Airbnb. Inicialmente contenía 171,748 observaciones y 80 variables relacionadas con características del alojamiento, ubicación, disponibilidad, reseñas, tipo de habitación, tipo de propiedad y precio.

La variable principal fue price. Como esta variable estaba almacenada como texto e incluía símbolos monetarios y separadores de miles, se limpiaron estos caracteres y se convirtió a formato numérico. Luego se eliminaron

registros sin precio válido o con valores no utilizables, quedando aproximadamente 76,246 observaciones para el análisis.

Para los modelos de clasificación, el precio se dividió en tres categorías balanceadas: barata, media y cara. Para los modelos de regresión, se utilizó el precio numérico como variable respuesta. En varios modelos también se aplicaron imputación de valores faltantes, estandarización de variables numéricas y codificación one hot para variables categóricas.

Tabla 2. Resumen de preparación de datos

Elemento	Resultado
Registros originales	171,748
Variables originales	80
Registros usados después de limpieza	76,246
Variable para regresión	price / price_num
Variable para clasificación	categoría_precio
Categorías de clasificación	barata, media, cara
Preprocesamiento principal	imputación, escalamiento y codificación one hot

4. Análisis exploratorio de datos

El análisis exploratorio mostró que el precio presenta una distribución fuertemente asimétrica hacia la derecha. La mayoría de propiedades se concentra en precios bajos o medios, pero existe una cola de valores altos que representa alojamientos mucho más costosos. Por esta razón, en la etapa exploratoria también se analizó `log_price`, ya que permite visualizar el comportamiento del precio de forma más estable.




Figura 1. Distribución de `log_price` después de la transformación logarítmica.




Figura 2. Boxplot de log_price y presencia de valores extremos.

Las correlaciones indicaron que las variables asociadas al tamaño y capacidad del alojamiento son las más relacionadas con el precio. Entre ellas destacan accommodates, bathrooms, bedrooms_num y beds_num. En términos prácticos, las propiedades con mayor capacidad, más baños, más dormitorios y más camas tienden a presentar precios más altos.

Tabla 3. Principales relaciones exploratorias con el precio

Variable	Relación observada con log_price	Interpretación
accommodates	positiva alta	A mayor capacidad, mayor precio esperado
bathrooms	positiva moderada-alta	Más baños suelen asociarse con propiedades más caras
bedrooms_num	positiva moderada	Más dormitorios incrementan el valor esperado
beds_num	positiva moderada	Más camas tienden a elevar el precio
estimated_occupancy_1365d	negativa moderada	Mayor ocupación estimada no siempre implica mayor precio




Figura 3. Correlación entre variables seleccionadas y log_price.

El análisis por variables categóricas mostró diferencias importantes entre tipos de habitación y tipos de propiedad. En particular, las propiedades completas y ciertos alojamientos tipo hotel o resort tienden a tener precios más altos que habitaciones privadas o compartidas.

5. Modelos de regresión para estimación de precios

La tarea de regresión buscó predecir directamente el precio numérico de las propiedades. A lo largo de las entregas se evaluaron modelos lineales, árboles de regresión, Naive Bayes adaptado a regresión, KNN, Random Forest, SVR y redes neuronales artificiales. Las métricas principales fueron RMSE, MAE y R^2 .

Los modelos lineales y Naive Bayes mostraron limitaciones importantes para representar el comportamiento del precio, principalmente por la alta dispersión, los valores extremos y las relaciones no lineales presentes en los datos. En cambio, los modelos no lineales, especialmente árboles de regresión y redes neuronales, lograron capturar mejor los patrones del conjunto de datos.

Tabla 4. Comparación final de modelos de regresión

Modelo de regresión	Métrica principal	Resultado aproximado	Lectura del resultado
Árbol de regresión	R^2	0.816	Mejor valor numérico de R^2 , aunque con posible riesgo de sobreajuste
Red neuronal artificial	R^2	0.805	Desempeño muy competitivo y buen equilibrio general
SVR con kernel RBF	R^2	0.572	Desempeño intermedio
KNN	R^2	0.526	Desempeño moderado, sensible a escala y distribución
Random Forest	R^2	0.338	Desempeño menor al esperado en esta comparación
Regresión lineal	R^2	bajo	Limitada para relaciones no lineales
Naive Bayes	R^2	negativo	No adecuado para predecir precios continuos

En términos de predicción del precio, el árbol de regresión obtuvo el mayor R^2 . Sin embargo, la red neuronal presentó un resultado muy cercano, con mayor flexibilidad para representar relaciones complejas. Por esta razón, el árbol puede considerarse el mejor modelo por métrica, mientras que la red neuronal representa una alternativa más equilibrada para implementación.

6. Modelos de clasificación para categorías de precio

La tarea de clasificación consistió en asignar cada propiedad a una de tres categorías de precio: barata, media o cara. Esta clasificación es útil para segmentar el mercado y facilitar recomendaciones de propiedades de acuerdo con el presupuesto del cliente.

Los modelos evaluados incluyeron árbol de decisión, Naive Bayes, KNN, regresión logística, SVM, Random Forest y redes neuronales. La métrica principal fue la exactitud en el conjunto de prueba, complementada con el análisis de errores por clase mediante matrices de confusión.

Tabla 5. Comparación final de modelos de clasificación

Modelo de clasificación	Métrica principal	Resultado aproximado	Observación
Red neuronal artificial	Accuracy	0.7468	Mejor desempeño general
Random Forest	Accuracy	0.7090	Segundo mejor modelo
SVM con kernel RBF	Accuracy	0.6980	Buen desempeño, pero inferior a RNA
Regresión logística	Accuracy	0.6820	Modelo estable, menor capacidad para relaciones complejas
Árbol de decisión	Accuracy	0.6620	Desempeño moderado
KNN	Accuracy	0.6519	Sensible a escala y distribución
Naive Bayes	Accuracy	0.5050	Menor desempeño en esta tarea

La categoría media fue la más difícil de clasificar, ya que se ubica entre los segmentos barata y cara. Esto genera solapamiento de características y explica que muchos errores se concentren entre las clases media y cara, o entre media y barata.

7. Redes neuronales artificiales

En la etapa final se entrenaron modelos de redes neuronales artificiales tanto para clasificación como para regresión. En clasificación se compararon dos arquitecturas: RNA 1 con capas ocultas de 64 y 32 neuronas usando ReLU, y RNA 2 con capas de 128, 64 y 32 neuronas usando tanh. La segunda red obtuvo una exactitud ligeramente mayor, aunque con mayor tiempo de entrenamiento.

Tabla 6. Redes neuronales para clasificación

Modelo	Capas ocultas	Activación	Tiempo de entrenamiento	Accuracy
RNA 1	64, 32	ReLU	43.55 s	0.7425
RNA 2	128, 64, 32	tanh	99.59 s	0.7468

Las matrices de confusión confirman que la mayor cantidad de aciertos se concentra en la diagonal principal. La categoría barata fue clasificada con mayor facilidad, mientras que la clase media presentó más confusiones con las otras categorías.




Figura 4. Matriz de confusión del modelo RNA 1.




Figura 5. Matriz de confusión del modelo RNA 2.

En regresión, la RNA 1 fue claramente superior a la RNA 2. El modelo RNA 1 obtuvo RMSE de 1892.32, MAE de 393.56 y R^2 de 0.8012. Tras el ajuste de parámetros, el modelo mejoró a RMSE de 1872.36, MAE de 368.17 y R^2 de 0.8054.

Tabla 7. Redes neuronales para regresión

Modelo de regresión RNA	RMSE	MAE	R^2	Conclusión
RNA 1	1892.32	393.56	0.8012	Mejor modelo base de regresión RNA
RNA 2	4219.66	553.67	0.0116	Desempeño bajo para regresión
RNA 1 tuneado	1872.36	368.17	0.8054	Mejora ligera y consistente




Figura 6. Curva de aprendizaje del modelo RNA de regresión.

8. Comparación final de algoritmos

La selección final de modelos debe considerar no solo la métrica principal, sino también la estabilidad, interpretabilidad, costo computacional y riesgo de sobreajuste. En clasificación, la red neuronal artificial es la opción más sólida porque obtuvo el mayor accuracy y mantuvo un sobreajuste controlado. En regresión, el árbol de regresión obtuvo el mejor R^2 , pero la red neuronal quedó muy cerca y ofrece mayor flexibilidad para relaciones no lineales complejas.

Tabla 8. Comparación ejecutiva entre tareas

Criterio	Clasificación	Regresión
Modelo con mejor métrica	RNA	Árbol de regresión
Modelo más equilibrado	RNA	RNA / árbol de regresión
Modelo más simple	Regresión logística / Naive Bayes	Regresión lineal / Naive Bayes
Mayor riesgo de sobreajuste	Árbol de decisión y SVM lineal	Árbol de regresión profundo
Mayor utilidad de negocio	Segmentación de propiedades por presupuesto	Estimación de precio competitivo

En una implementación real para SmartStay Advisors, la clasificación por categoría de precio puede utilizarse como primer filtro para recomendaciones rápidas. La predicción numérica del precio puede utilizarse después para estimar valores competitivos o detectar propiedades con precios atípicos frente a sus características.

9. Análisis de sobreajuste y generalización

El análisis de sobreajuste mostró que los modelos más simples suelen ser más estables, pero también menos precisos. Los modelos más complejos capturan mejor los patrones no lineales, aunque requieren control de hiperparámetros para evitar memorizar los datos de entrenamiento.

Tabla 9. Comparación del nivel de sobreajuste

Modelo	Tipo	Nivel de sobreajuste estimado	Comentario
RNA clasificación	Clasificación	Bajo a moderado	Diferencia pequeña entre entrenamiento y prueba; early stopping ayuda a controlar el ajuste
Random Forest	Clasificación	Moderado	Buen desempeño, pero depende de profundidad y número de árboles
SVM	Clasificación	Moderado a alto	Algunos kernels mostraron diferencias importantes entre entrenamiento y prueba
Regresión logística	Clasificación	Bajo	Modelo estable, aunque menos flexible
Árbol de decisión	Clasificación	Alto	Puede memorizar reglas específicas si no se limita su profundidad
KNN	Clasificación / regresión	Moderado	Sensible a escala, ruido y elección de k
Naive Bayes	Clasificación / regresión	Bajo	Más bien presenta subajuste por supuestos fuertes
Árbol de regresión	Regresión	Moderado a alto	Alto R^2 , pero riesgo de ajuste excesivo a patrones específicos
RNA regresión	Regresión	Moderado	Buen desempeño global, aunque la curva de aprendizaje mostró inestabilidad en validación

Considerando el sobreajuste, la red neuronal se mantiene como la mejor opción de clasificación. Para regresión, el árbol de regresión debe usarse con control de profundidad y validación, mientras que la red neuronal puede considerarse una opción robusta cuando se busca equilibrio entre precisión y generalización.

10. Recomendaciones para SmartStay Advisors

1. Utilizar la red neuronal artificial como modelo principal para clasificar propiedades en segmentos de precio: barata, media y cara.
2. Utilizar el árbol de regresión y la red neuronal como modelos candidatos para estimar precio numérico; seleccionar entre ellos según el balance deseado entre precisión, interpretabilidad y estabilidad.
3. Monitorear continuamente el desempeño de los modelos con datos nuevos, ya que el mercado de Airbnb puede cambiar por temporada, ciudad, demanda y disponibilidad.
4. Mantener un proceso de limpieza de datos que controle precios extremos, valores faltantes y variables categóricas de alta cardinalidad.
5. Usar las variables de capacidad, tamaño y tipo de alojamiento como factores principales para explicar diferencias de precio.
6. Complementar las métricas generales con análisis de errores por categoría, especialmente en la clase media, donde se observan más confusiones.

11. Conclusión final

En conclusión, los modelos desarrollados permitieron analizar y predecir el comportamiento de los precios de propiedades de Airbnb. Para la tarea de clasificación, la red neuronal artificial fue el mejor modelo, ya que obtuvo la mayor exactitud al clasificar las propiedades en baratas, medias y caras. Aunque presentó algunos errores en la categoría media, su desempeño general fue superior al de los modelos utilizados en entregas anteriores.

Para la predicción del precio numérico, el árbol de regresión obtuvo el mejor R^2 , pero la red neuronal presentó un resultado muy cercano y más equilibrado en términos de generalización. Por ello, se considera que ambos modelos son alternativas fuertes: el árbol por su desempeño numérico y la red neuronal por su capacidad de capturar relaciones complejas de forma flexible.

En general, las redes neuronales demostraron ser modelos sólidos para este problema, especialmente porque logran capturar relaciones no lineales entre las variables. Estos resultados pueden apoyar a SmartStay Advisors en la estimación de precios, clasificación de propiedades y toma de decisiones estratégicas basadas en datos.

12. Anexo: repositorios y alcance

El informe se integró a partir de las entregas relacionadas con el conjunto de datos de propiedades de Airbnb, principalmente desde el análisis exploratorio hasta la comparación final de modelos. El archivo de Laboratorio 2 contiene un análisis sobre películas, por lo que no se integró al cuerpo principal del informe para mantener coherencia con la consultoría de Airbnb.

- Laboratorio 3: <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Laboratorio3>
- Laboratorio 5: <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Laboratorio5>
- Laboratorio 7: <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Laboratorio7>
- Laboratorio 8: <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Laboratorio8>
- Laboratorio 9: <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Laboratorio9>
- Repositorio general: <https://github.com/Ninaswiftie09/Mineria-de-Datos>