

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Minería de datos

Semestre I – 2026



## Laboratorio 9

Integrantes:

Ciprian Jimenez, Mishell Rosa Elvira – 231169

Nájera Marakovits, Ingrid Nina Alessandra - 231088

Ramírez Velásquez, Diego Alejandro – 23601

**Link del repositorio:** <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Laboratorio9>

## **Introducción**

En este avance se trabajó con el conjunto de datos de propiedades de Airbnb utilizado en las entregas anteriores. El objetivo principal fue preparar los datos para construir modelos de Redes Neuronales Artificiales orientados a clasificación. Para esto, se tomó como variable respuesta una categoría creada a partir del precio de las propiedades, dividiéndolas en tres grupos: baratas, medias y caras.

Además, se entrenaron dos modelos de redes neuronales con diferentes estructuras internas y funciones de activación. Luego, ambos modelos se usaron para predecir la categoría de precio de las propiedades del conjunto de prueba.

## **Preparación de los conjuntos de entrenamiento y prueba**

Para mantener una comparación justa con los modelos desarrollados anteriormente, se separó la base de datos en un conjunto de entrenamiento y un conjunto de prueba. El conjunto de entrenamiento se utilizó para que los modelos aprendieran los patrones de los datos, mientras que el conjunto de prueba se reservó para evaluar qué tan bien podían clasificar propiedades nuevas.

Después de limpiar y preparar las variables, el conjunto de entrenamiento quedó formado por 53,372 registros y 48 variables predictoras. Por otro lado, el conjunto de prueba quedó formado por 22,874 registros y las mismas 48 variables predictoras.

Esta división permite evaluar los modelos con datos que no fueron usados durante el entrenamiento, lo cual es importante para saber si el modelo realmente aprendió patrones generales y no solo memorizó los datos.

## **Creación de la variable respuesta**

La variable respuesta utilizada para esta parte del laboratorio fue una categoría basada en el precio de las propiedades. Primero, el precio original se limpió porque venía en formato de texto, con símbolos como el signo de dólar y comas. Luego, el precio se convirtió a formato numérico para poder trabajar con él.

Después de esto, los precios se dividieron en tres categorías:

| <b>Categoría</b> | <b>Descripción</b>                  |
|------------------|-------------------------------------|
| barata           | Propiedades con precios bajos       |
| media            | Propiedades con precios intermedios |
| cara             | Propiedades con precios altos       |

Tabla I

La distribución de la variable respuesta en los conjuntos de entrenamiento y prueba fue la siguiente:

| <b>Categoría</b> | <b>Entrenamiento</b> | <b>Prueba</b> |
|------------------|----------------------|---------------|
| barata           | 17,982               | 7,707         |
| media            | 17,607               | 7,546         |
| cara             | 17,783               | 7,621         |

Tabla II

Como se puede observar, las tres categorías quedaron bastante balanceadas. Esto es positivo porque evita que el modelo aprenda a favorecer solamente una categoría. Si una categoría tuviera muchos más datos que las demás, el modelo podría obtener buenos resultados aparentes solo por predecir siempre la clase mayoritaria.

### Modelos de redes neuronales para clasificación

Se entrenaron dos modelos de Redes Neuronales Artificiales para clasificar las propiedades según su categoría de precio. Ambos modelos usan la misma variable respuesta, pero tienen topologías y funciones de activación diferentes.

El primer modelo tiene una estructura más sencilla. Está compuesto por dos capas ocultas, una de 64 neuronas y otra de 32 neuronas. En ambas capas se utilizó la función de activación ReLU. Esta función es común en redes neuronales porque ayuda a que el modelo aprenda relaciones no lineales de forma eficiente.

El segundo modelo tiene una estructura más profunda. Está compuesto por tres capas ocultas, con 128, 64 y 32 neuronas respectivamente. En este caso, se utilizó la función de activación tanh. Esta función transforma los valores a un rango entre -1 y 1, lo cual puede ayudar en algunos problemas, aunque también puede hacer que el entrenamiento sea más lento.

La comparación general de las arquitecturas utilizadas fue la siguiente:

| <b>Modelo</b> | <b>Capas ocultas</b> | <b>Función de activación</b> | <b>Tiempo de entrenamiento</b> |
|---------------|----------------------|------------------------------|--------------------------------|
| RNA 1         | 64, 32               | ReLU                         | 43.55 segundos                 |
| RNA 2         | 128, 64, 32          | tanh                         | 99.59 segundos                 |

El segundo modelo tardó más en entrenarse porque tiene una arquitectura más grande y más capas. Esto significa que tiene más parámetros internos que ajustar durante el entrenamiento. Sin embargo, un modelo más complejo no siempre garantiza resultados mucho mejores.

### **Predicción de la categoría de precio**

Después del entrenamiento, ambos modelos se utilizaron para predecir la categoría de precio de las propiedades del conjunto de prueba. Las predicciones se compararon con la categoría real para calcular la exactitud general de cada modelo.

Los resultados obtenidos fueron los siguientes:

| <b>Modelo</b> | <b>Exactitud</b> |
|---------------|------------------|
| RNA 1         | 0.7425           |
| RNA 2         | 0.7468           |

El modelo RNA 2 obtuvo una exactitud ligeramente mayor que el modelo RNA 1. Sin embargo, la diferencia entre ambos modelos fue pequeña. Esto significa que el segundo modelo clasificó un poco mejor, pero también necesitó más tiempo de procesamiento.

En términos prácticos, el modelo RNA 1 puede considerarse una alternativa más eficiente porque logró un resultado muy parecido al del segundo modelo, pero con un tiempo de entrenamiento bastante menor. Por otro lado, el modelo RNA 2 puede ser útil si se busca obtener la mayor exactitud posible, aunque el aumento en desempeño no fue tan grande.

### **Matrices de confusión de los modelos de clasificación**

Para evaluar con mayor detalle el desempeño de los modelos de redes neuronales, se construyeron las matrices de confusión correspondientes a cada uno. Estas matrices permiten observar no solo la exactitud general, sino también en qué casos específicos los modelos aciertan o se equivocan.

Para el modelo RNA 1, la matriz de confusión fue la siguiente:




Figura 1. matriz de confusión modelo RNA 1




Figura 2. matriz de confusión modelo RNA 2

A partir de estos resultados, se pueden hacer varias observaciones importantes:

- Ambos modelos tienen un buen desempeño en general, ya que la mayor cantidad de predicciones se encuentra en la diagonal principal, lo que indica que clasifican correctamente una gran parte de las propiedades.
- En ambas redes neuronales, la categoría **barata** es la que mejor se clasifica, con una alta cantidad de aciertos y relativamente pocos errores.
- La categoría **cara** también presenta un buen nivel de clasificación, aunque en ambos modelos existe una confusión considerable con la categoría **media**.
- La categoría **media** es la más difícil de clasificar correctamente. Esto se observa porque tiene una mayor cantidad de errores distribuidos hacia las categorías **barata** y **cara**.

- En ambos modelos, el error más común ocurre entre las categorías **media** y **cara**, lo cual sugiere que los límites entre estos dos grupos no están claramente definidos en los datos.

Comparando ambos modelos, se observa que:

- El modelo RNA 2 mejora ligeramente la clasificación de la categoría **barata**, reduciendo algunos errores en comparación con el modelo RNA 1.
- Sin embargo, el modelo RNA 2 incrementa algunos errores en la clasificación de la categoría **cara**, especialmente al confundirla con **media**.

En general, ambos modelos presentan patrones de error similares, lo que indica que las dificultades en la clasificación están más relacionadas con la estructura de los datos que con el modelo específico utilizado.

## Comparación de los modelos de clasificación

Para evaluar el desempeño de los modelos de redes neuronales, se realizó una comparación considerando tres aspectos principales: la efectividad, el tiempo de procesamiento y el tipo de errores cometidos por cada modelo.

### Efectividad de los modelos

La efectividad de los modelos se evaluó utilizando la exactitud obtenida sobre el conjunto de prueba. Los resultados fueron los siguientes:

- RNA 1: 0.7425
- RNA 2: 0.7468

El modelo RNA 2 obtuvo una exactitud ligeramente superior al modelo RNA 1. Sin embargo, la diferencia entre ambos modelos es pequeña, lo que indica que ambos tienen un desempeño similar en términos de clasificación general.

### Tiempo de procesamiento

En cuanto al tiempo de entrenamiento, se observaron las siguientes diferencias:

- RNA 1: 43.55 segundos
- RNA 2: 99.59 segundos

El modelo RNA 2 requiere más del doble de tiempo de entrenamiento que el modelo RNA 1. Esto se debe a que tiene una arquitectura más compleja, con más capas y neuronas, lo que incrementa la cantidad de parámetros que deben ajustarse durante el proceso de aprendizaje.

### Análisis de errores

El análisis de las matrices de confusión permite identificar en qué casos los modelos cometen más errores.

En ambos modelos, la mayor cantidad de errores ocurre entre las categorías **media** y **cara**, lo que indica que estas clases son más difíciles de separar. Esto puede deberse a que los precios intermedios y altos tienen características similares en el conjunto de datos.

Asimismo, la categoría **media** es la más problemática, ya que presenta errores tanto hacia **barata** como hacia **cara**. Esto sugiere que esta categoría se encuentra en una zona de transición entre las otras dos.

Por otro lado, la categoría **barata** es la que mejor se clasifica en ambos modelos, con una alta cantidad de aciertos y pocos errores. Esto indica que las propiedades más económicas tienen características más diferenciadas dentro del conjunto de datos.

Al comparar ambos modelos, se observa que:

- RNA 2 mejora ligeramente la clasificación de propiedades baratas.
- RNA 1 presenta un comportamiento más equilibrado en la clasificación de las demás categorías.
- Ambos modelos comparten patrones de error similares, lo que sugiere que las limitaciones provienen principalmente de los datos y no del modelo.

### **Conclusión de la comparación**

En general, el modelo RNA 2 presenta un desempeño ligeramente mejor en términos de exactitud. Sin embargo, este incremento es pequeño en comparación con el aumento significativo en el tiempo de entrenamiento.

Por esta razón, el modelo RNA 1 puede considerarse una opción más eficiente, ya que logra un rendimiento muy similar con un menor costo computacional. No obstante, si se busca maximizar la exactitud sin considerar el tiempo de procesamiento, el modelo RNA 2 sería la mejor opción.

### **Análisis de sobreajuste de los modelos**

Para evaluar si los modelos presentan sobreajuste, se comparó la exactitud obtenida en el conjunto de entrenamiento con la obtenida en el conjunto de prueba.

Los resultados fueron los siguientes:

- RNA 1:
  - Entrenamiento: 0.7843
  - Prueba: 0.7425
  -

- RNA 2:
  - Entrenamiento: 0.7938
  - Prueba: 0.7468

Al analizar estos valores, se observa que en ambos modelos la exactitud en entrenamiento es ligeramente mayor que en el conjunto de prueba. Sin embargo, la diferencia entre ambos valores es relativamente pequeña, aproximadamente entre 4% y 5%.

Esto indica que los modelos presentan una leve tendencia al sobreajuste, lo cual es esperado en modelos de redes neuronales, pero no es lo suficientemente significativo como para afectar gravemente su capacidad de generalización.

Además, el uso de técnicas como el **early stopping** contribuye a controlar este comportamiento, evitando que los modelos continúen entrenando una vez que dejan de mejorar en datos no vistos.

En general, se concluye que ambos modelos logran un buen equilibrio entre aprendizaje y generalización, por lo que no presentan problemas graves de sobreajuste.

### Ajustes de parámetros del modelo de clasificación

Para esta etapa, se seleccionó el modelo RNA 2 como base para realizar el ajuste de parámetros, ya que fue el que obtuvo la mayor exactitud en el conjunto de prueba.

Se realizó un ajuste en algunos hiperparámetros del modelo, incluyendo el incremento en el número de iteraciones máximas, así como modificaciones en la tasa de aprendizaje y el parámetro de regularización. Estos cambios buscan mejorar la capacidad de aprendizaje del modelo sin generar sobreajuste.

Después de realizar el entrenamiento del modelo ajustado, se obtuvo una nueva exactitud de:

- RNA 2 tuneado: **0.7473**

Al comparar este resultado con el modelo original (0.7468), se observa que la mejora es muy pequeña. Esto indica que el modelo original ya se encontraba cerca de su mejor desempeño con la configuración inicial.

Además, el uso de técnicas como el **early stopping** contribuye a evitar el sobreentrenamiento, lo que limita mejoras adicionales sin afectar la capacidad de generalización.

En general, se concluye que el modelo puede ajustarse ligeramente, pero no presenta mejoras significativas. Esto sugiere que la calidad del modelo está más influenciada por las características de los datos que por pequeños cambios en los hiperparámetros.

### Selección de la variable respuesta para regresión



Para esta etapa se seleccionó como variable de respuesta el precio numérico de las propiedades (price\_num). A diferencia de la fase anterior, donde se trabajó con una variable categorica, en este caso se busca predecir directamente un valor continuo.

Se utilizaron los mismos conjuntos de entrenamiento y prueba definidos previamente, con el fin de mantener consistencia en la comparación de los modelos y asegurar que los resultados sean comparables entre diferentes técnicas.

### **Modelos de RNA para regresión**

Se construyeron dos modelos de redes neuronales con el objetivo de predecir el precio de las propiedades.

El primer modelo representa una arquitectura más sencilla, dos capas ocultas de 64 y 32 neuronas, respectivamente, y utiliza una función de activación ReLu. Este modelo busca capturar relaciones no lineales de manera eficiente sin un alto costo computacional.

El segundo modelo tiene una arquitectura mas profunda, con tres capas ocultas de 128, 64 y 32 neuronas, respectivamente, utilizando la función de activación tanh. Esta estructura más compleja permite modelar relaciones más sofisticadas en los datos, aunque implica un mayor tiempo de entrenamiento.

Ambos modelos fueron entrenados utilizando el mismo conjunto de datos y preposicionamiento, lo que permite realizar una comparación justa de su desempeño en la predicción del precio de las propiedades.

### **Comparación de los modelos de regresión**

Para evaluar el desempeño de los modelos de redes neuronales en la predicción del precio de las propiedades, se utilizaron tres métricas: el error cuadrático medio (RMSE), el error absoluto medio (MAE) y el coeficiente de determinación ( $R^2$ ).

Los resultados obtenidos fueron los siguientes:

- RNA 1:
  - RMSE: 1892.32
  - MAE: 393.56
  - $R^2$ : 0.8012
- RNA 2:
  - RMSE: 4219.66
  - MAE: 553.67
  - $R^2$ : 0.0116

Al analizar estos resultados, se observa que el modelo RNA 1 presenta un desempeño considerablemente mejor que el modelo RNA 2 en todas las métricas evaluadas.

El modelo RNA 1 logra un valor de  $R^2$  cercano a 0.80, lo que indica que es capaz de explicar aproximadamente el 80% de la variabilidad del precio de las propiedades. Además, presenta errores relativamente bajos en comparación con el segundo modelo.

Por otro lado, el modelo RNA 2 muestra un desempeño muy bajo, con un  $R^2$  cercano a 0, lo que indica que prácticamente no logra explicar la variabilidad de los datos. Asimismo, presenta errores significativamente más altos, lo que evidencia una mala capacidad de predicción.

Esta diferencia puede atribuirse a la mayor complejidad del modelo RNA 2 y al uso de la función de activación tanh, que en este caso no logró capturar adecuadamente las relaciones presentes en los datos.

### **Conclusión de la comparación**

En base a los resultados obtenidos, se concluye que el modelo RNA 1 es claramente superior para la predicción del precio de las propiedades. El modelo RNA 2 no resulta adecuado para este problema, ya que no logra generar predicciones precisas.

### **Análisis de sobreajuste mediante curva de aprendizaje**

Para evaluar el comportamiento del modelo de regresión, se generó una curva de aprendizaje utilizando el coeficiente de determinación ( $R^2$ ).

Al analizar la gráfica obtenida, se observa que el desempeño del modelo en validación presenta una alta variabilidad, incluyendo valores extremadamente bajos de  $R^2$  en algunos tamaños del conjunto de entrenamiento.

Estos valores negativos indican que, en ciertos casos, el modelo predice peor que un modelo base simple (como la media), lo que evidencia una falta de estabilidad en el proceso de aprendizaje.

Por otro lado, la curva de entrenamiento se mantiene relativamente estable, lo que sugiere que el modelo logra ajustarse a los datos de entrenamiento, pero no generaliza de manera consistente en todos los subconjuntos de validación.

Este comportamiento no corresponde a un sobreajuste clásico, sino más bien a una sensibilidad del modelo frente a la variabilidad de los datos y a la complejidad del problema de regresión.

En general, se concluye que, aunque el modelo presenta un buen desempeño global en el conjunto de prueba, su comportamiento durante la validación cruzada no es completamente estable, lo que sugiere que podrían existir factores en los datos que dificultan una generalización uniforme.




Figura 3. Curva de aprendizaje

### Ajuste de parámetros del modelo de regresión

Para esta etapa, se seleccionó el modelo RNA 1 como base para el ajuste de parámetros, ya que fue el que obtuvo el mejor desempeño en la predicción del precio de las propiedades.

Se realizaron ajustes en algunos hiperparámetros, incluyendo el incremento en el número máximo de iteraciones, así como modificaciones en la tasa de aprendizaje y el parámetro de regularización. Estos cambios buscan mejorar la capacidad del modelo para capturar patrones en los datos sin generar sobreajuste.

Después de entrenar el modelo ajustado, se obtuvieron los siguientes resultados:

- RMSE: 1872.36
- MAE: 368.17
- $R^2$ : 0.8054

Al comparar estos resultados con el modelo original, se observa una mejora ligera pero consistente en todas las métricas. Esto indica que el ajuste de parámetros permitió al modelo capturar mejor las relaciones en los datos.

Sin embargo, la mejora no es muy grande, lo que sugiere que el modelo original ya se encontraba en una configuración bastante adecuada. Además, el uso de técnicas como el **early stopping** ayuda a evitar el sobreentrenamiento, manteniendo un buen equilibrio entre ajuste y generalización.

En general, se concluye que el modelo puede mejorar mediante ajustes en sus parámetros, pero los cambios en el desempeño son moderados.

## **Comparación del modelo de redes neuronales con modelos anteriores**

Para evaluar la eficiencia del modelo de redes neuronales, se compararon sus resultados con los obtenidos en laboratorios anteriores utilizando distintos algoritmos de clasificación y regresión.

### **Comparación en clasificación**

En la tarea de clasificación, el modelo de redes neuronales obtuvo una exactitud de aproximadamente **0.7468**, superando a todos los modelos evaluados previamente.

Entre los modelos anteriores, el mejor desempeño fue obtenido por Random Forest, con una exactitud cercana a **0.709**, seguido por el modelo SVM con kernel RBF, con un valor cercano a **0.698**. Otros modelos como regresión logística, árbol de decisión y KNN presentaron desempeños inferiores, mientras que Naive Bayes obtuvo los resultados más bajos.

Esto indica que el modelo de redes neuronales logra capturar relaciones más complejas en los datos, permitiendo una mejor clasificación de las propiedades en categorías de precio.

### **Comparación en regresión**

En la tarea de regresión, el modelo de redes neuronales obtuvo un valor de  $R^2 \approx 0.805$ , lo que indica una alta capacidad para explicar la variabilidad del precio de las propiedades.

Al comparar con los modelos anteriores, se observa que el árbol de regresión obtuvo un valor similar ( $R^2 \approx 0.816$ ), mientras que modelos como SVR ( $R^2 \approx 0.572$ ), KNN ( $R^2 \approx 0.526$ ) y Random Forest ( $R^2 \approx 0.338$ ) presentaron un desempeño menor.

El modelo Naive Bayes mostró un desempeño muy bajo, con valores negativos de  $R^2$ , lo que indica que no es adecuado para este problema.

### **Comparación de tiempo de procesamiento**

En cuanto al tiempo de procesamiento, las redes neuronales requieren un mayor tiempo de entrenamiento en comparación con modelos más simples como regresión logística o árboles de decisión. Sin embargo, su costo computacional es comparable al de modelos más complejos como Random Forest y SVM.

Esto refleja un trade-off entre precisión y costo computacional, donde las redes neuronales ofrecen mejores resultados a cambio de un mayor tiempo de entrenamiento.

### **Conclusión de la comparación**

En general, los modelos de redes neuronales mostraron un desempeño superior en clasificación y competitivo en regresión. En clasificación, superan claramente a los modelos tradicionales, mientras que en regresión alcanzan resultados similares a los mejores modelos evaluados.

Esto sugiere que las redes neuronales son una alternativa sólida para este conjunto de datos, especialmente cuando se busca capturar relaciones no lineales complejas entre las variables.

### **Comparación del modelo de redes neuronales para clasificación**

Para evaluar el desempeño del modelo de redes neuronales en la tarea de clasificación, se compararon sus resultados con los obtenidos por los algoritmos utilizados en las entregas anteriores.

El modelo de redes neuronales alcanzó una exactitud de **0.7468**, lo que representa el mejor desempeño entre todos los modelos evaluados.

En comparación, los resultados de los modelos anteriores fueron los siguientes:

- Random Forest: aproximadamente 0.709
- SVM (RBF): aproximadamente 0.698
- Regresión logística: aproximadamente 0.682
- Árbol de decisión: aproximadamente 0.662
- KNN: aproximadamente 0.6519
- Naive Bayes: aproximadamente 0.505

Al analizar estos resultados, se observa que el modelo de redes neuronales supera claramente a todos los algoritmos tradicionales. La diferencia es especialmente notable frente a modelos más simples como Naive Bayes y KNN, pero también se mantiene superior frente a modelos más avanzados como SVM y Random Forest.

Este mejor desempeño puede explicarse por la capacidad de las redes neuronales para modelar relaciones no lineales complejas entre las variables, lo que les permite capturar patrones más profundos en los datos.

Sin embargo, es importante considerar que este aumento en desempeño viene acompañado de un mayor costo computacional, ya que el entrenamiento de redes neuronales requiere más tiempo en comparación con otros modelos.

### **Conclusión**

En base a la comparación realizada, se concluye que el modelo de redes neuronales es el mejor modelo para la tarea de clasificación en este conjunto de datos, ya que logra la mayor exactitud sin presentar problemas significativos de sobreajuste.

### **Comparación del modelo de redes neuronales para regresión**

Para evaluar el desempeño del modelo de redes neuronales en la predicción del precio de las propiedades, se compararon sus resultados con los obtenidos por los algoritmos de regresión utilizados en las entregas anteriores.

El modelo de redes neuronales obtuvo un valor de  $R^2 \approx 0.805$ , lo que indica una alta capacidad para explicar la variabilidad del precio.

En comparación, los resultados de los modelos anteriores fueron los siguientes:

- Árbol de regresión:  $R^2 \approx 0.816$
- SVR (RBF):  $R^2 \approx 0.572$
- KNN:  $R^2 \approx 0.526$
- Random Forest:  $R^2 \approx 0.338$
- Regresión lineal:  $R^2$  bajo
- Naive Bayes:  $R^2$  negativo

Al analizar estos resultados, se observa que el modelo de redes neuronales presenta un desempeño muy competitivo, superando claramente a la mayoría de los modelos evaluados. Sin embargo, el árbol de regresión obtuvo un valor ligeramente superior de  $R^2$ .

Es importante considerar que el desempeño del árbol de regresión podría estar influenciado por factores como la complejidad del modelo o posibles problemas de sobreajuste, lo cual se ha observado en análisis anteriores. En contraste, el modelo de redes neuronales muestra un comportamiento más equilibrado, con buen desempeño y mejor capacidad de generalización.

Además, el modelo de redes neuronales logra superar a modelos más complejos como SVR y Random Forest, lo que indica que es capaz de capturar de manera efectiva relaciones no lineales en los datos.

## **Conclusión**

En general, el modelo de redes neuronales se posiciona como una de las mejores opciones para la predicción del precio, con un desempeño cercano al mejor modelo evaluado. Aunque el árbol de regresión presenta un valor ligeramente superior de  $R^2$ , las redes neuronales ofrecen un mejor equilibrio entre precisión y generalización, lo que las convierte en una alternativa sólida para este problema.

## **Selección final de modelos y análisis de generalización**

Después de evaluar los distintos algoritmos utilizados durante las entregas del proyecto, se realizó una comparación general para determinar cuáles modelos son más adecuados para el conjunto de datos de propiedades de Airbnb. Para esta decisión se consideraron tanto las métricas de desempeño como la estabilidad de los modelos y su posible nivel de sobreajuste.

En la tarea de clasificación, el objetivo fue predecir la categoría del precio de las propiedades, dividiéndolas en baratas, medias y caras. La métrica principal utilizada fue la exactitud, ya que permite medir la proporción de clasificaciones correctas realizadas por cada modelo. Los resultados comparativos fueron los siguientes:

| <b>Modelo de clasificación</b> | <b>Métrica principal</b> | <b>Resultado aproximado</b> | <b>Observación</b>                                                          |
|--------------------------------|--------------------------|-----------------------------|-----------------------------------------------------------------------------|
| RNA                            | Accuracy                 | 0.7468                      | Mejor desempeño general en clasificación                                    |
| Random Forest                  | Accuracy                 | 0.7090                      | Segundo mejor modelo, buen desempeño pero inferior a RNA                    |
| SVM con kernel RBF             | Accuracy                 | 0.6980                      | Buen desempeño, aunque menor que RNA y Random Forest                        |
| Regresión logística            | Accuracy                 | 0.6820                      | Modelo estable, pero con menor capacidad para capturar relaciones complejas |
| Árbol de decisión              | Accuracy                 | 0.6620                      | Desempeño moderado, con posible sensibilidad al sobreajuste                 |
| KNN                            | Accuracy                 | 0.6519                      | Desempeño menor, sensible a la escala y distribución de los datos           |
| Naive Bayes                    | Accuracy                 | 0.5050                      | Menor desempeño, poco adecuado para este problema                           |

A partir de estos resultados, se concluye que el mejor modelo para clasificación es la red neuronal artificial. Este modelo obtuvo la mayor exactitud y mostró una mejor capacidad para capturar relaciones no lineales entre las variables del conjunto de datos. Esto es importante porque el precio de una propiedad no depende de una sola característica, sino de la interacción entre ubicación, tipo de alojamiento, capacidad, disponibilidad, número de reseñas y otras variables.

Aunque Random Forest y SVM también mostraron buenos resultados, no alcanzaron el desempeño de la red neuronal. Por esta razón, la RNA se considera el modelo más adecuado para clasificar propiedades en categorías de precio. Sin embargo, es importante tomar en cuenta que este modelo requiere mayor tiempo de entrenamiento que modelos más simples, por lo que existe un intercambio entre precisión y costo computacional.

En la tarea de regresión, el objetivo fue predecir directamente el precio numérico de las propiedades. Para esta comparación se utilizó principalmente el coeficiente de determinación  $R^2$ , ya que permite medir qué proporción de la variabilidad del precio logra explicar cada modelo. También se consideraron los errores de predicción cuando estaban disponibles.

| Modelo de regresión | Métrica principal | Resultado aproximado | Observación                                                         |
|---------------------|-------------------|----------------------|---------------------------------------------------------------------|
| Árbol de regresión  | $R^2$             | 0.816                | Mejor valor de $R^2$ , aunque puede presentar riesgo de sobreajuste |
| RNA                 | $R^2$             | 0.805                | Desempeño muy competitivo y mejor equilibrio general                |
| SVR con kernel RBF  | $R^2$             | 0.572                | Desempeño intermedio                                                |
| KNN                 | $R^2$             | 0.526                | Desempeño moderado, sensible a la distribución de los datos         |
| Random Forest       | $R^2$             | 0.338                | Bajo desempeño en comparación con RNA y árbol de regresión          |
| Regresión lineal    | $R^2$             | Bajo                 | Limitada para capturar relaciones no lineales                       |
| Naive Bayes         | $R^2$             | Negativo             | No adecuado para predicción de precios continuos                    |

En regresión, el árbol de regresión obtuvo el valor de  $R^2$  más alto, con aproximadamente 0.816. Sin embargo, la red neuronal obtuvo un resultado muy cercano, con un  $R^2$  aproximado de 0.805. Esta diferencia es pequeña, por lo que la selección del mejor modelo no debe basarse únicamente en la métrica, sino también en la capacidad de generalización.

Considerando lo anterior, el árbol de regresión puede considerarse el mejor modelo si se toma únicamente el valor de  $R^2$ . No obstante, la red neuronal representa una alternativa más equilibrada, ya que mantiene un desempeño muy alto y tiene mayor capacidad para modelar relaciones complejas sin depender de divisiones rígidas de los datos. Por esta razón, para una aplicación de consultoría donde se busca estabilidad y capacidad de generalización, la red neuronal puede considerarse una de las mejores opciones para predecir el precio de las propiedades.



## Comparación del nivel de sobreajuste

Además del desempeño en prueba, se analizó el nivel de sobreajuste de los modelos. El sobreajuste ocurre cuando un modelo aprende demasiado bien los datos de entrenamiento, pero pierde capacidad para generalizar correctamente a datos nuevos. Por esta razón, no siempre el modelo con la métrica más alta es necesariamente el más recomendable.

| Modelo              | Tipo de problema | Nivel de sobreajuste estimado | Justificación                                                                                                                    |
|---------------------|------------------|-------------------------------|----------------------------------------------------------------------------------------------------------------------------------|
| RNA clasificación   | Clasificación    | Bajo a moderado               | La diferencia entre entrenamiento y prueba fue pequeña, por lo que no se observan problemas graves de sobreajuste                |
| Random Forest       | Clasificación    | Moderado                      | Puede capturar relaciones complejas, pero también puede ajustarse demasiado si no se controla la profundidad o número de árboles |
| SVM RBF             | Clasificación    | Moderado                      | Puede generalizar bien, aunque es sensible a la selección de parámetros                                                          |
| Regresión logística | Clasificación    | Bajo                          | Es un modelo más simple y estable, aunque con menor desempeño                                                                    |
| Árbol de decisión   | Clasificación    | Alto                          | Los árboles individuales pueden memorizar patrones específicos del conjunto de entrenamiento                                     |
| KNN                 | Clasificación    | Moderado                      | Es sensible a la distribución de los datos y a la selección del número de vecinos                                                |
| Naive Bayes         | Clasificación    | Bajo                          | No presenta alto sobreajuste, pero su desempeño fue el más bajo                                                                  |
| Árbol de regresión  | Regresión        | Moderado a alto               | Aunque obtuvo el mayor $R^2$ , los árboles de regresión pueden ajustarse demasiado a patrones específicos                        |
| RNA regresión       | Regresión        | Moderado                      | La curva de aprendizaje mostró                                                                                                   |

|                  |           |          |                                                                                                   |
|------------------|-----------|----------|---------------------------------------------------------------------------------------------------|
|                  |           |          | cierta inestabilidad, pero el desempeño global fue alto                                           |
| SVR RBF          | Regresión | Moderado | Puede presentar buen control del sobreajuste si los parámetros están bien ajustados               |
| KNN              | Regresión | Moderado | Puede ser sensible a valores atípicos y a la escala de las variables                              |
| Random Forest    | Regresión | Moderado | Puede reducir sobreajuste frente a un árbol individual, aunque en este caso su desempeño fue bajo |
| Regresión lineal | Regresión | Bajo     | Tiene menor riesgo de sobreajuste, pero no captura bien relaciones no lineales                    |
| Naive Bayes      | Regresión | Bajo     | No mostró sobreajuste relevante, pero tampoco fue adecuado para este tipo de predicción           |

En clasificación, la red neuronal se mantiene como el mejor modelo, ya que combina la mayor exactitud con un nivel de sobreajuste controlado. Aunque su exactitud en entrenamiento fue ligeramente mayor que en prueba, la diferencia no fue lo suficientemente grande como para indicar un problema serio de generalización. Además, el uso de early stopping ayudó a controlar el entrenamiento y evitar que el modelo continuara ajustándose innecesariamente a los datos.

En regresión, la decisión es más equilibrada. El árbol de regresión obtuvo el mayor  $R^2$ , pero su naturaleza lo hace más propenso al sobreajuste, especialmente si no se controla su profundidad. Por otro lado, la red neuronal obtuvo un  $R^2$  muy cercano y mostró un comportamiento más flexible para capturar relaciones no lineales. Aunque la curva de aprendizaje evidenció cierta inestabilidad en validación, el desempeño final sobre el conjunto de prueba fue alto.

Por lo tanto, considerando tanto las métricas como el sobreajuste, se concluye que la red neuronal es el mejor modelo para clasificación. Para regresión, el árbol de regresión obtuvo el mejor resultado numérico, pero la red neuronal es una alternativa más robusta y equilibrada. En un contexto de consultoría, donde no solo importa obtener una buena métrica sino también contar con un modelo estable para datos nuevos, se recomienda priorizar la red neuronal como modelo general para el conjunto de datos, especialmente por su buen desempeño tanto en clasificación como en predicción de precios.

## Conclusión

En conclusión, los modelos desarrollados permitieron analizar y predecir el comportamiento de los precios de las propiedades de Airbnb. Para la tarea de clasificación, la Red Neuronal Artificial fue el mejor modelo, ya que obtuvo la mayor exactitud al clasificar las propiedades en baratas, medias y caras. Aunque presentó algunos errores en la categoría media, su desempeño general fue superior al de los modelos usados en entregas anteriores.

Para la predicción del precio numérico, el árbol de regresión obtuvo el mejor  $R^2$ , pero la red neuronal presentó un resultado muy cercano y más equilibrado en términos de generalización. Por ello, se considera que la RNA es una de las mejores alternativas para este conjunto de datos.

En general, las redes neuronales demostraron ser modelos sólidos para este problema, especialmente porque logran capturar relaciones complejas entre las variables. Estos resultados pueden apoyar a SmartStay Advisors en la estimación de precios, clasificación de propiedades y toma de decisiones estratégicas basadas en datos.