

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Minería de Datos

Semestre I – 2026



Laboratorio 2

Integrantes:

Ciprian Jimenez, Mishell Rosa Elvira – 231169

Nájera Marakovits, Ingrid Nina Alessandra - 231088

Ramírez Velásquez, Diego Alejandro – 23601

1. Clustering

Link del repositorio: <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Laboratorio2>

- **Preprocesamiento**

Se trabajó con el dataset de películas movies_2026.csv, el cual tiene 19,883 registros y 28 columnas.

Para preparar los datos para clustering, primero se eliminaron variables que no aportan al agrupamiento porque son identificadores, texto, fechas sin transformar o variables categóricas no codificadas. Estas variables no son adecuadas para calcular distancias entre observaciones.

- **Variables eliminadas**

- id
 - genres
 - homePage
 - productionCompany
 - productionCompanyCountry
 - productionCountry
 - director
 - actors
 - actorsPopularity
 - actorsCharacter
 - originalTitle
 - title
 - originalLanguage
 - releaseDate
 - Video

- **Variables utilizadas para clustering**

- budget
 - revenue
 - runtime
 - popularity
 - voteAvg
 - voteCount
 - genresAmount
 - productionCoAmount
 - productionCountriesAmount
 - actorsAmount
 - castWomenAmount
 - castMenAmount
 - ReleaseYear

- **Manejo de valores nulos**

Se revisaron valores faltantes en las variables seleccionadas. Se encontraron nulos en:

- castWomenAmount: 37
- castMenAmount: 162
- releaseYear: 2

Las demás variables no presentaron nulos.

Para asegurar consistencia en el análisis, se eliminaron las filas con valores faltantes. Después de esto, el dataset quedó con 19,719 registros y 13 variables.

- **Estandarización de datos**

Finalmente, se aplicó estandarización a las variables numéricas para que todas quedaran en la misma escala. Esto es importante en clustering porque variables con valores grandes podrían dominar el cálculo de distancias si no se escalan.

- **Tendencia al agrupamiento**

Antes de aplicar algoritmos de clustering, se evaluó si los datos presentan una estructura agrupable.

- **Estadístico de Hopkins**

Se calculó el estadístico de Hopkins y se obtuvo:


- Hopkins = 0.9869

Este valor es muy cercano a 1, lo cual indica una fuerte tendencia al agrupamiento. Esto sugiere que los datos no están distribuidos de forma aleatoria y que sí tiene sentido aplicar técnicas de clustering.

- **VAT (Visual Assessment of Tendency)**

También se generó una visualización tipo VAT para analizar visualmente la estructura de agrupamiento.

Figura 1. Gráfico VAT




En el gráfico VAT se observan zonas y bloques con cambios de intensidad, lo que sugiere la presencia de grupos naturales dentro de los datos. Aunque no se ven bloques perfectamente definidos, la visualización sí refuerza el resultado del estadístico de Hopkins y apoya la idea de que el dataset tiene estructura para clustering.

- **Número de clústeres**

Para estimar el número adecuado de clústeres, se utilizó el método del codo, calculando la inercia para valores de k entre 1 y 10.

Figura 2. Gráfico de codo



En la gráfica del codo se observa una disminución fuerte de la inercia entre $k = 1$ y $k = 4$, y a partir de ese punto la mejora comienza a ser menor y más gradual.

- **Justificación del número de clústeres**

Con base en la forma de la curva, se identifica un punto de inflexión alrededor de $k = 4$, por lo que se propone usar 4 clústeres como cantidad inicial para el análisis.

Esta elección permite un buen balance entre:

- reducir la inercia
- evitar usar demasiados grupos
- mantener una interpretación más clara de los resultados

- **k-medias y clustering jerárquico**

Para el clustering jerárquico se utilizó el método de enlace Ward (ward linkage), el cual minimiza la varianza dentro de los clusters en cada fusión.

Como métrica de distancia se utilizó la distancia euclidiana, ya que los datos fueron previamente estandarizados.

Se seleccionó Ward debido a que tiende a generar grupos más compactos y es comparable conceptualmente con K-Means, que también minimiza la varianza intra-cluster.

Tamaño de los clusters

K-Means:

- Cluster 2: 8,656 películas
- Cluster 0: 6,710 películas
- Cluster 1: 3,856 películas
- Cluster 3: 497 películas


Jerárquico:

- Cluster 4: 8,585 películas
- Cluster 1: 8,393 películas
- Cluster 2: 2,396 películas
- Cluster 3: 345 películas

Comparación

- Ambos métodos generan un grupo muy grande y uno muy pequeño.
- K-Means presenta una distribución ligeramente más balanceada.
- El jerárquico tiende a formar un cluster muy dominante.

- **calidad del agrupamiento**



Se evaluó la calidad del agrupamiento mediante el índice de silueta.

Silhouette K-Means: 0.3197

Silhouette Jerárquico: 0.3286

Aunque los valores de silueta son positivos y superiores a 0.3, no pueden considerarse excelentes.

Valores cercanos a 1 indican separación clara entre grupos, mientras que valores cercanos a 0 indican solapamiento.

En este caso (~ 0.32), existe una estructura de agrupamiento moderada, pero con cierto solapamiento entre clusters.

Sin embargo, para un dataset tan grande y con variables económicas altamente correlacionadas, este nivel de silueta es aceptable para fines exploratorios y permite obtener insights útiles sobre el mercado cinematográfico.

Interpretación

Ambos valores se encuentran en el rango 0.3 – 0.5, lo que indica:

- Existe estructura de agrupamiento.
- La separación es moderada.
- No hay clusters completamente separados, pero sí diferenciación clara.

El clustering jerárquico presenta un valor ligeramente mayor (0.3286), por lo que muestra una separación marginalmente mejor.

Sin embargo, dado que la diferencia es pequeña, se puede optar por K-Means debido a:

- Mayor estabilidad
- Mayor simplicidad interpretativa
- Mejor balance en tamaños de grupos

• Interpretación los grupos

	budget	revenue	runtime	popularity	voteAvg	voteCount	genresAmount	productionCoAmount	productionCountriesAmount	actorsAmount	castWomenAmount	castMenAmount
cluster_kmeans												
0	2.468372e+06	4.679009e+06	89.023994	36.891875	6.430225	276.726677	2.400745	2.424441	1.760209	13.909985	3.978390	24101.776155
1	2.719439e+07	6.920589e+07	110.485477	36.799680	6.629798	1808.845695	2.742998	3.848548	1.512189	40.636670	10.183351	35.024896
2	5.355115e+03	1.484243e+03	25.400531	0.523389	0.361139	0.194085	1.174561	0.608364	0.666474	3.387015	0.449284	36.841266
3	1.316976e+08	5.507711e+08	123.223340	244.592698	7.008491	9259.418511	3.219316	3.824950	1.498994	61.712274	13.334004	31.338028

castWomenAmount	castMenAmount	releaseYear	cluster_jerarquico
3.978390	24101.776155	2015.525484	3.834277
10.183351	35.024896	2001.133558	3.050052
0.449284	36.841266	2025.203212	1.164164
13.334004	31.338028	2010.861167	2.000000

Cluster 2 – Producciones muy pequeñas / datos atípicos

- Budget promedio: 5,355
- Revenue promedio: 1,484
- Runtime promedio: 25 minutos
- Popularidad: 0.52
- VoteAvg: 0.36
- VoteCount: prácticamente 0
- Año promedio: 2025

Este grupo representa producciones extremadamente pequeñas o posiblemente registros incompletos.

Podrían tratarse de cortometrajes, proyectos no comerciales o datos poco consolidados.

Cluster 0 – Producciones pequeñas comerciales

- Budget: 2.4 millones
- Revenue: 4.6 millones
- Runtime: 89 minutos

- VoteAvg: 6.43
- VoteCount: 276
- Año promedio: 2015

Representa películas de bajo presupuesto con desempeño comercial moderado

Cluster 1 – Producciones mediana

- Budget: 27 millones
- Revenue: 69 millones
- Runtime: 110 minutos
- VoteAvg: 6.62
- VoteCount: 1,808
- Año promedio: 2001

Películas comerciales con inversión considerable y buen retorno.

Cluster 3 – Blockbusters

- Budget: 131 millones
- Revenue: 550 millones
- Runtime: 123 minutos
- Popularidad: 244
- VoteAvg: 7.00
- VoteCount: 9,259
- Año promedio: 2010

Este grupo representa grandes producciones de alto presupuesto e impacto comercial.

Interpretación categórica de clusters

```

Dimensiones df_final: (19719, 29)

cluster  genres
0        Drama      415
        Comedy      285
        Documentary  271
        Horror      186
        Horror|Thriller 163
1        Comedy      201
        Drama      180
        Comedy|Romance 105
        Drama|Romance  100
        Comedy|Drama   70
2        Documentary 1547
        Drama      1101
        Comedy      518
        Animation    273
        Horror      253
3        Action|Adventure|Science Fiction 25
        Action|Adventure|Fantasy         18
        Science Fiction|Action|Adventure 12
        Adventure|Action|Science Fiction 12
        Adventure|Fantasy|Action          10
Name: count, dtype: int64

cluster  originalLanguage
0        en      4304
        ja      539
        es      422
1        en     3414
        ja      132
        fr      107
2        en     3645
        es      763
        fr      723
3        en      491
        ja         2
        zh         1
Name: count, dtype: int64

cluster  productionCountry
0        United States of America 2387
        Japan                     486
        United Kingdom            182
1        United States of America 2243
        United Kingdom|United States of America 188
        Japan                     120
2        US                       668
        FR                       350
        GB                       307
3        United States of America 327
        United Kingdom|United States of America 51
        Germany|United States of America 11
Name: count, dtype: int64

cluster  year_bin
0        2016-2023  2745
        2010-2015  1347
        2000-2009  1038
        1981-1999   272
        1900-1980    30
1        2000-2009  1126
        1981-1999   819
        2010-2015   736
        2016-2023   734
        1900-1980   441
2        2016-2023    32
        2010-2015    10
        2000-2009     7
        1981-1999     0
        1900-1980     0
3        2010-2015   161
        2016-2023   159
        2000-2009   127
        1981-1999    44
        1900-1980     3
Name: count, dtype: int64

```

Además del análisis de las variables numéricas, se analizaron variables categóricas para caracterizar con mayor profundidad los grupos obtenidos mediante K-Means. Se estudiaron los géneros predominantes, el idioma original, el país de producción y el rango temporal de estreno.

Cluster 0 – Producciones pequeñas comerciales recientes

- Este cluster está compuesto principalmente por películas de:
- Géneros predominantes: Drama, Comedy y Documentary.
- Idioma dominante: Inglés (en), seguido por japonés (ja) y español (es).
- País de producción principal: United States of America, seguido por Japón y Reino Unido.
- Periodo de estreno más frecuente: 2016–2023.

Interpretación:

Este grupo representa producciones comerciales pequeñas relativamente recientes, con fuerte presencia del mercado estadounidense y predominio de géneros narrativos tradicionales como drama y comedia. La alta concentración en años recientes sugiere contenido contemporáneo con participación moderada del público.

Cluster 1 – Producciones medianas con perfil internacional

- Este cluster presenta las siguientes características:
- Géneros predominantes: Comedy, Drama, Comedy|Romance y Drama|Romance.
- Idioma dominante: Inglés, con presencia secundaria de japonés y francés.
- País de producción principal: United States of America y coproducciones Reino Unido–Estados Unidos.
- Distribución temporal: Mayor concentración entre 2000–2009 y 1981–1999.

Interpretación:

Este grupo representa películas de presupuesto medio con enfoque en géneros comerciales amplios y emocionalmente accesibles (comedia y romance). La distribución temporal más dispersa sugiere estabilidad histórica de este tipo de producción en el mercado.

Cluster 2 – Producciones muy pequeñas / contenido documental reciente

Este cluster muestra un perfil muy particular:

- Género dominante: Documentary (claramente predominante), seguido por Drama y Comedy.
- Idioma dominante: Inglés, con presencia significativa de español y francés.
- Países frecuentes: US, FR y GB.
- Periodo dominante: 2016–2023.

Interpretación:

Este grupo está compuesto principalmente por producciones documentales recientes de bajo presupuesto. La fuerte concentración temporal reciente indica un crecimiento moderno del contenido documental y de nicho. Este cluster podría representar producciones digitales o de plataformas de streaming con menor inversión pero alta segmentación temática.

Cluster 3 – Blockbusters de acción internacional

Este es el cluster más claramente diferenciado:

- Géneros predominantes: combinaciones de Action, Adventure y Science Fiction.
- Idioma dominante: Inglés (casi absoluto).

- País de producción principal: United States of America, con coproducciones internacionales.
- Periodo dominante: 2010–2015 y 2016–2023.

Interpretación:

Este cluster representa grandes producciones comerciales internacionales (blockbusters), caracterizadas por géneros de alto impacto visual y narrativo. La fuerte presencia del mercado estadounidense y la concentración en la última década confirman su alineación con el modelo moderno de franquicias y cine de espectáculo.

2. Reglas de asociación

- **Preparación de datos para A priori**

A priori necesita datos en formato de items (presencia o ausencia). Para lograrlo, cada película se representó como una transacción formada por categorías derivadas de variables numéricas.

- **Discretización de variables numéricas**

Las variables numéricas se discretizaron en tres rangos usando cuantiles para convertirlas en categorías tipo bajo, medio y alto. Luego, cada categoría se transformó a formato binario (one hot), para que A priori pueda contar combinaciones frecuentes.

Se usaron: budget, revenue, runtime, popularity, voteAvg, voteCount y releaseYear.”

Esto ayuda a que sea reproducible.

Tabla 1. Ejemplo de discretización por cuantiles (muestra)

budget	revenue	runtime	popularity	voteAvg	voteCount	releaseYear
budget=(0.999, 3000000.0]	revenue=(-0.001, 9761430.0]	runtime=(0.999, 94.0]	popularity=(0.999, 7.205]	voteAvg=(0.999, 5.58]	voteCount=(0.999, 193.0]	releaseYear=(2016.0, 2023.0]
budget=(0.999, 3000000.0]	revenue=(-0.001, 9761430.0]	runtime=(0.999, 94.0]	popularity=(0.999, 7.205]	voteAvg=(0.999, 5.58]	voteCount=(0.999, 193.0]	releaseYear=(2016.0, 2023.0]
budget=(0.999, 3000000.0]	revenue=(-0.001, 9761430.0]	runtime=(0.999, 94.0]	popularity=(0.999, 7.205]	voteAvg=(0.999, 5.58]	voteCount=(0.999, 193.0]	releaseYear=(2016.0, 2023.0]
budget=(0.999, 3000000.0]	revenue=(-0.001, 9761430.0]	runtime=(0.999, 94.0]	popularity=(0.999, 7.205]	voteAvg=(0.999, 5.58]	voteCount=(0.999, 193.0]	releaseYear=(2016.0, 2023.0]
budget=(0.999, 3000000.0]	revenue=(-0.001, 9761430.0]	runtime=(94.0, 107.0]	popularity=(0.999, 7.205]	voteAvg=(5.58, 6.62]	voteCount=(0.999, 193.0]	releaseYear=(2016.0, 2023.0]

budget=(0.999, 3000000.0]	revenue=(-0.001, 9761430.0]	runtime=(0.999, 94.0]	popularity=(0.999, 7.205]	voteAvg=(0.999, 5.58]	voteCount=(0.999, 193.0]	releaseYear=(2016.0, 2023.0]
budget=(0.999, 3000000.0]	revenue=(-0.001, 9761430.0]	runtime=(0.999, 94.0]	popularity=(0.999, 7.205]	voteAvg=(0.999, 5.58]	voteCount=(0.999, 193.0]	releaseYear=(2016.0, 2023.0]
budget=(0.999, 3000000.0]	revenue=(-0.001, 9761430.0]	runtime=(0.999, 94.0]	popularity=(0.999, 7.205]	voteAvg=(0.999, 5.58]	voteCount=(0.999, 193.0]	releaseYear=(2016.0, 2023.0]
budget=(3000000.0, 18000000.0]	revenue=(9761430.0, 60600000.0]	runtime=(94.0, 107.0]	popularity=(7.205, 16.712]	voteAvg=(5.58, 6.62]	voteCount=(193.0, 30788.0]	releaseYear=(2016.0, 2023.0]
budget=(0.999, 3000000.0]	revenue=(-0.001, 9761430.0]	runtime=(0.999, 94.0]	popularity=(0.999, 7.205]	voteAvg=(0.999, 5.58]	voteCount=(0.999, 193.0]	releaseYear=(2016.0, 2023.0]

• Ejecución de A priori

Con los datos ya en formato binario, se aplicó A priori para encontrar itemsets frecuentes. Se probaron diferentes valores de soporte mínimo para comparar patrones comunes contra patrones más específicos.

```
Archivos generados:
- apriori_discretizacion_muestra.csv
- apriori_items_muy_frecuentes.csv
- apriori_itemsets_sup0.05_conf0.6.csv
- apriori_reglas_top_sup0.05_conf0.6.csv
- apriori_itemsets_sup0.03_conf0.7.csv
- apriori_reglas_top_sup0.03_conf0.7.csv
- apriori_itemsets_sup0.02_conf0.8.csv
- apriori_reglas_top_sup0.02_conf0.8.csv
PS C:\Users\ninan\OneDrive\Documentos\Escritorio\UVG\VII SEMESTRE\Minería de Datos\RStudio\Minería-de-Datos>
```

• Reglas de asociación y métricas

A partir de los itemsets frecuentes se generaron reglas de asociación. Para evaluar reglas se usaron soporte, confianza y lift. Se priorizaron reglas con lift mayor a 1 porque indican asociaciones más fuertes que lo esperado por azar.

• Resultados por configuración (soporte/confianza)

Se evaluaron tres configuraciones:

- soporte 0.05 y confianza 0.60
- soporte 0.03 y confianza 0.70
- soporte 0.02 y confianza 0.80

Con soporte más alto se obtienen reglas más generales y frecuentes. Al bajar el soporte aparecen reglas más específicas, pero con menor cobertura. Al subir la confianza mínima, se reducen reglas, pero las que quedan tienden a ser más fuertes. A continuación, se presentan las reglas principales para cada configuración.

Tabla 2. Top reglas (support=0.05, confidence=0.60)

antecedents	consequents	support	confidence	lift
popularity_popularity=(7.205, 16.712]	voteCount_voteCount=(193.0, 30788.0]	0.129	0.835	2.507
popularity_popularity=(0.999, 7.205], voteAvg_voteAvg=(0.999, 5.58]	voteCount_voteCount=(0.999, 193.0]	0.086	0.629	2.058
releaseYear_releaseYear=(2016.0, 2023.0]	voteCount_voteCount=(0.999, 193.0]	0.197	0.608	1.987
revenue_revenue=(60600000.0, 1106000000.0]	voteCount_voteCount=(193.0, 30788.0]	0.065	0.781	2.347
revenue_revenue=(9761430.0, 60600000.0], voteAvg_voteAvg=(5.58, 6.62]	voteCount_voteCount=(193.0, 30788.0]	0.061	0.747	2.244
revenue_revenue=(9761430.0, 60600000.0], voteCount_voteCount=(193.0, 30788.0]	voteAvg_voteAvg=(5.58, 6.62]	0.061	0.725	2.153
runtime_runtime=(107.0, 400.0]	voteCount_voteCount=(193.0, 30788.0]	0.055	0.721	2.165
voteAvg_voteAvg=(5.58, 6.62]	voteCount_voteCount=(193.0, 30788.0]	0.172	0.716	2.150
voteAvg_voteAvg=(6.62, 10.0]	voteCount_voteCount=(193.0, 30788.0]	0.060	0.703	2.110
revenue_revenue=(9761430.0, 60600000.0]	voteCount_voteCount=(193.0, 30788.0]	0.144	0.692	2.076
releaseYear_releaseYear=(1901.999, 2016.0]	voteCount_voteCount=(193.0, 30788.0]	0.188	0.671	2.013
releaseYear_releaseYear=(2016.0, 2023.0], voteAvg_voteAvg=(0.999, 5.58]	voteCount_voteCount=(0.999, 193.0]	0.078	0.667	2.181
popularity_popularity=(16.712, 11474.647]	voteCount_voteCount=(193.0, 30788.0]	0.044	0.861	2.585
revenue_revenue=(60600000.0, 1106000000.0], voteAvg_voteAvg=(6.62, 10.0]	voteCount_voteCount=(193.0, 30788.0]	0.028	0.777	2.332
budget_budget=(18000000.0, 380000000.0]	voteCount_voteCount=(193.0, 30788.0]	0.056	0.753	2.260

Tabla 3. Top reglas (support=0.03, confidence=0.70)

antecedents	consequents	support	confidence	lift
popularity_popularity=(16.712, 11474.647], releaseYear_releaseYear=(1901.999, 2016.0]	voteCount_voteCount=(193.0, 30788.0]	0.069	0.898	2.696

popularity_popularity=(16.712, 11474.647], voteAvg_voteAvg=(5.58, 6.62]	voteCount_voteCount=(19 3.0, 30788.0]	0.106	0.883	2.65 2
releaseYear_releaseYear=(1901. 999, 2016.0], runtime_runtime=(107.0, 400.0]	voteCount_voteCount=(19 3.0, 30788.0]	0.102	0.862	2.58 9
popularity_popularity=(16.712, 11474.647], runtime_runtime=(107.0, 400.0]	voteCount_voteCount=(19 3.0, 30788.0]	0.037	0.857	2.57 4
releaseYear_releaseYear=(1901. 999, 2016.0], voteAvg_voteAvg=(6.62, 10.0]	voteCount_voteCount=(19 3.0, 30788.0]	0.159	0.839	2.51 9
popularity_popularity=(16.712, 11474.647], voteAvg_voteAvg=(6.62, 10.0]	voteCount_voteCount=(19 3.0, 30788.0]	0.067	0.825	2.47 5
revenue_revenue=(60600000.0, 1106000000.0], voteAvg_voteAvg=(5.58, 6.62]	voteCount_voteCount=(19 3.0, 30788.0]	0.055	0.818	2.45 2
budget_budget=(18000000.0, 380000000.0], voteAvg_voteAvg=(5.58, 6.62]	voteCount_voteCount=(19 3.0, 30788.0]	0.064	0.809	2.42 7
revenue_revenue=(60600000.0, 1106000000.0], releaseYear_releaseYear=(1901. 999, 2016.0]	voteCount_voteCount=(19 3.0, 30788.0]	0.064	0.802	2.40 6
revenue_revenue=(60600000.0, 1106000000.0], runtime_runtime=(107.0, 400.0]	voteCount_voteCount=(19 3.0, 30788.0]	0.041	0.799	2.39 6
budget_budget=(18000000.0, 380000000.0], revenue_revenue=(60600000.0, 1106000000.0]	voteCount_voteCount=(19 3.0, 30788.0]	0.045	0.797	2.39 0
budget_budget=(18000000.0, 380000000.0], runtime_runtime=(107.0, 400.0]	voteCount_voteCount=(19 3.0, 30788.0]	0.045	0.790	2.36 9
budget_budget=(18000000.0, 380000000.0], releaseYear_releaseYear=(1901. 999, 2016.0]	voteCount_voteCount=(19 3.0, 30788.0]	0.088	0.787	2.36 0
runtime_runtime=(107.0, 400.0], voteAvg_voteAvg=(6.62, 10.0]	voteCount_voteCount=(19 3.0, 30788.0]	0.080	0.786	2.35 7
popularity_popularity=(7.205, 16.712], runtime_runtime=(107.0, 400.0]	voteCount_voteCount=(19 3.0, 30788.0]	0.106	0.778	2.33 3

Tabla 4. Top reglas (support=0.02, confidence=0.80)

antecedents	consequents	support	confidence	lift
popularity_popularity=(16.712, 11474.647], releaseYear_releaseYear=(1901.999, 2016.0], voteAvg_voteAvg=(5.58, 6.62]	voteCount_voteCount=(193.0, 30788.0]	0.051	0.921	2.764
popularity_popularity=(16.712, 11474.647], releaseYear_releaseYear=(1901.999, 2016.0], runtime_runtime=(107.0, 400.0]	voteCount_voteCount=(193.0, 30788.0]	0.026	0.913	2.739
popularity_popularity=(16.712, 11474.647], revenue_revenue=(60600000.0, 1106000000.0]	voteCount_voteCount=(193.0, 30788.0]	0.037	0.901	2.702
popularity_popularity=(16.712, 11474.647], runtime_runtime=(107.0, 400.0], voteAvg_voteAvg=(5.58, 6.62]	voteCount_voteCount=(193.0, 30788.0]	0.031	0.895	2.685
budget_budget=(18000000.0, 380000000.0], popularity_popularity=(16.712, 11474.647]	voteCount_voteCount=(193.0, 30788.0]	0.021	0.892	2.677
popularity_popularity=(16.712, 11474.647], runtime_runtime=(107.0, 400.0], voteAvg_voteAvg=(6.62, 10.0]	voteCount_voteCount=(193.0, 30788.0]	0.021	0.871	2.614
popularity_popularity=(16.712, 11474.647], voteAvg_voteAvg=(5.58, 6.62], voteCount_voteCount=(193.0, 30788.0]	releaseYear_releaseYear=(1901.999, 2016.0]	0.020	0.800	2.850
popularity_popularity=(16.712, 11474.647], voteAvg_voteAvg=(6.62, 10.0], voteCount_voteCount=(193.0, 30788.0]	releaseYear_releaseYear=(1901.999, 2016.0]	0.020	0.841	2.992
revenue_revenue=(60600000.0, 1106000000.0], voteAvg_voteAvg=(5.58, 6.62]	voteCount_voteCount=(193.0, 30788.0]	0.055	0.818	2.452

revenue_revenue=(60600000.0, 1106000000.0], voteAvg_voteAvg=(6.62, 10.0]	voteCount_voteCount=(193.0, 30788.0]	0.030	0.839	2.519
budget_budget=(18000000.0, 380000000.0], voteAvg_voteAvg=(5.58, 6.62]	voteCount_voteCount=(193.0, 30788.0]	0.064	0.809	2.427
budget_budget=(18000000.0, 380000000.0], voteAvg_voteAvg=(6.62, 10.0]	voteCount_voteCount=(193.0, 30788.0]	0.039	0.832	2.496
budget_budget=(18000000.0, 380000000.0], revenue_revenue=(60600000.0, 1106000000.0]	voteCount_voteCount=(193.0, 30788.0]	0.045	0.797	2.390
budget_budget=(18000000.0, 380000000.0], releaseYear_releaseYear=(1901.999, 2016.0], voteAvg_voteAvg=(6.62, 10.0]	voteCount_voteCount=(193.0, 30788.0]	0.062	0.853	2.559
budget_budget=(18000000.0, 380000000.0], runtime_runtime=(107.0, 400.0], voteAvg_voteAvg=(6.62, 10.0]	voteCount_voteCount=(193.0, 30788.0]	0.021	0.842	2.527

- **Ítems muy frecuentes (filtrado) y discusión**

Se identificaron ítems demasiado frecuentes y se removieron antes de ejecutar A priori. En este caso, se removieron los ítems con frecuencia mayor a 0.80 (presentes en más del 80% de los registros), ya que tienden a generar reglas poco informativas. La Tabla 5 muestra los ítems removidos. Las reglas reportadas en las Tablas 2–4 corresponden a la ejecución de A priori después de aplicar este filtrado.

Tabla 5. Ítems removidos por alta frecuencia

ítem	frecuencia
budget_budget=(0.999, 3000000.0]	0.807
revenue_revenue=(-0.001, 9761430.0]	0.806

- **Interpretación de reglas más relevantes**

Las reglas con mayor lift y buena confianza muestran asociaciones consistentes entre características de visibilidad, desempeño y participación del público. En

general, las reglas apuntan a que películas con mayor popularidad, mayores ingresos o mejor calificación tienden a acumular un mayor conteo de votos, lo cual refleja mayor interacción.

- En las Tablas 2 y 3 se observa que cuando la popularidad se encuentra en rangos medio o alto, es común que el conteo de votos esté en el rango medio-alto. Esto sugiere que la visibilidad de una película se relaciona con una mayor participación de la audiencia.
- También aparecen reglas donde años de estreno más antiguos se asocian con un conteo de votos mayor. Esto puede explicarse porque las películas con más tiempo disponible suelen acumular votos a lo largo de los años (Tabla 2 y Tabla 3).
- Otras reglas muestran que variables asociadas al rendimiento y recepción, como ingresos altos o calificación promedio media-alta/alta, se relacionan con un conteo de votos medio-alto. Esto indica que películas con mejor desempeño o mejor valoración tienden a generar más interacción (Tablas 2–4).
- Al comparar configuraciones, con soporte más alto (Tabla 2) predominan reglas más generales y frecuentes, mientras que con soporte más bajo y confianza más alta (Tabla 4) aparecen reglas más específicas que combinan varias condiciones en el antecedente, manteniendo alta confianza, pero con menor cobertura.

En conjunto, estas reglas son útiles para perfilar películas con alta interacción del público y entender combinaciones frecuentes de características que tienden a aparecer juntas.

3. PCA:




Figura matriz de correlación

La matriz de correlación muestra la existencia de correlaciones moderadas y altas entre variables del conjunto de datos. Por ejemplo, se observa una fuerte correlación positiva entre el presupuesto (budget) y los ingresos (revenue), así como entre la cantidad total de actores (actorsAmount) y la cantidad de actrices (castWomenAmount).

Asimismo, se identifican correlaciones entre voteCount y revenue, lo que sugiere que las películas con mayores ingresos tienden a recibir mayor participación de los usuarios. La presencia de estas correlaciones indica redundancia en la información, lo cual justifica la aplicación del análisis de componentes principales para reducir la dimensionalidad del conjunto de datos.

Evaluación de la pertinencia del PCA

El primer componente concentra altas cargas positivas en variables como **budget**, **revenue**, **voteCount**, **actorsAmount**, **castWomenAmount** y **runtime**.

Esto indica que estas variables tienden a moverse en la misma dirección: películas con mayor presupuesto suelen tener mayor duración, mayor tamaño de elenco y mayor cantidad de votos recibidos.

Este componente puede interpretarse como una **dimensión de escala económica y magnitud de producción**, donde valores altos representan producciones grandes, con fuerte inversión y alta participación del público.


Dado que explica aproximadamente el 37% de la varianza total, se trata de la dimensión más influyente del conjunto de datos

Para determinar si era adecuado aplicar el análisis de componentes principales, se calcularon el KMO y el test de esfericidad de Bartlett.

El kmo obtenido fue de 0.835, lo cual indica una adecuación muestral buena. Este valor sugiere que las variables comparten suficiente varianza común para justificar la aplicación del PCA.

Por otra parte, el test de esfericidad de Bartlett arrojó un valor de chi-cuadrado de **115646.63** con un **p-value = 0.0** ($p < 0.05$). Esto indica que se rechaza la hipótesis nula de matriz identidad, confirmando que existen correlaciones significativas entre las variables.


Análisis del Scree Plot



El Scree Plot muestra que el primer componente explica aproximadamente el 37% de la varianza total, seguido de una disminución considerable en los siguientes componentes. A partir del segundo componente, la reducción de varianza explicada se vuelve más gradual.

Esto indica que los primeros componentes concentran la mayor parte de la información relevante del conjunto de datos.

Análisis de varianza acumulada:



Como se observa en la Figura, la proporción de varianza explicada aumenta progresivamente a medida que se agregan componentes principales.

Se determinó que con **6 componentes principales** se supera el **80% de la varianza total explicada**, lo cual permite reducir las 13 variables numéricas originales a 6 dimensiones principales sin perder una cantidad significativa de información.

Por esta razón, se decidió trabajar con 6 componentes, ya que ofrecen un equilibrio adecuado entre reducción de dimensionalidad y conservación de información relevante del conjunto de datos.

Interpretación de los componentes principales;

	PC1	PC2	PC3	PC4	PC5	PC6
budget	0.317591	0.374853	0.184288	-0.033435	0.146339	0.110544
revenue	0.296062	0.449611	0.240745	-0.073789	0.184321	-0.008897
runtime	0.330201	-0.237072	-0.103228	0.029171	-0.052254	-0.012084
popularity	0.108472	0.108374	0.164757	0.926107	-0.218600	-0.170695
voteAvg	0.320402	-0.297108	-0.107519	0.101019	0.153213	-0.113093
voteCount	0.322250	0.360771	0.165543	-0.131059	0.113072	-0.031185
genresAmount	0.260002	-0.180990	-0.149739	0.184765	0.598901	0.180720
productionCoAmount	0.273419	-0.193172	-0.136356	0.090329	-0.079937	0.706981
productionCountriesAmount	0.090765	-0.376183	0.557976	-0.096924	-0.106314	0.175147
actorsAmount	0.376069	0.035528	-0.109227	-0.150959	-0.378068	-0.105396
castWomenAmount	0.344773	-0.060638	-0.029368	-0.145249	-0.530630	-0.065152
castMenAmount	0.001400	-0.311949	0.649939	-0.059870	0.124402	-0.165804
releaseYear	-0.270715	0.238998	0.209162	0.091479	-0.203664	0.581939

Con base en el análisis de la varianza acumulada se determinó que

- Componente 1 (pc1) Magnitud de producción y participación:
- Componente 2 (pc2) Desempeño comercial:
 Este componente está dominado por **revenue**, **budget** y **voteCount**, lo que sugiere que captura una dimensión asociada al rendimiento financiero y al impacto comercial.
 Aunque está relacionado con el primer componente, este eje separa específicamente el éxito económico, diferenciando películas con alto retorno comercial frente a aquellas con menor desempeño.
 Este componente refuerza la idea de que el comportamiento del mercado cinematográfico está fuertemente determinado por variables financieras.
- Componente 3 (pc3) Producción Internacional y Composición del elenco:
 El componente presenta cargas importantes en **castMenAmount** y **productionCountriesAmount**, lo que indica una dimensión relacionada con la composición del elenco y la diversidad internacional de la producción.
 Este componente puede reflejar diferencias estructurales entre producciones más locales y producciones con participación internacional más amplia.

- **Componente 4 (pc4) Popularidad.**
El cuarto componente está fuertemente dominado por la variable **popularity**, lo que indica que esta dimensión captura el nivel de visibilidad o tendencia reciente de la película.
Esto sugiere que la popularidad funciona como una dimensión relativamente independiente de las variables económicas tradicionales.
- **Componente 5 (pc5) Diversidad de géneros:**
El quinto componente está principalmente influenciado por **genresAmount**, lo que representa la diversidad de géneros asociados a cada película.
Esta dimensión distingue producciones más especializadas de aquellas que combinan múltiples géneros.
- **Componente 6 (pc6) Complejidad Industrial y Temporal:**
Este componente presenta altas cargas en **productionCoAmount** y **releaseYear**, lo que sugiere una dimensión relacionada con la evolución temporal y la complejidad industrial de las producciones.
Esto puede reflejar cambios estructurales en la industria cinematográfica a lo largo del tiempo.

Relación entre el PCA y el análisis de clustering

Los resultados del análisis de componentes principales permiten explicar la estructura observada en el clustering.

El primer componente, asociado a la escala económica y magnitud de producción, coincide directamente con la diferenciación principal encontrada en los clusters. En el análisis de agrupamiento se identificaron claramente grupos que separan producciones pequeñas, producciones medianas y blockbusters.

Esto indica que la segmentación natural del mercado cinematográfico está fuertemente determinada por variables económicas como presupuesto, ingresos y nivel de participación del público.

Asimismo, la existencia de componentes independientes asociados a popularidad y diversidad temática sugiere que existen dimensiones adicionales que pueden generar subsegmentaciones dentro de cada grupo principal.

En conjunto, el PCA confirma que la estructura detectada por el clustering no es arbitraria, sino que responde a dimensiones latentes reales del mercado cinematográfico, principalmente dominadas por la escala de producción y el desempeño comercial.

4. Otros Algoritmos:

Selección del algoritmo

Se seleccionó t-SNE (t-Distributed Stochastic Neighbor Embedding) como algoritmo adicional de aprendizaje no supervisado. Esta técnica permite reducir dimensionalidad preservando la estructura local de los datos, lo cual es útil para visualizar relaciones no lineales entre variables como presupuesto, ingresos y popularidad.

Debido al tamaño del dataset, se utilizó una muestra aleatoria de 2,000 observaciones para evitar sobrecarga computacional, manteniendo representatividad del conjunto original.

Resultados obtenidos

La visualización bidimensional muestra:

- Separación clara del cluster de blockbusters.
- Cierta solapamiento entre producciones pequeñas y medianas.
- Estructura continua del mercado cinematográfico.
- Interpretación y relevancia

t-SNE confirma que el mercado no está dividido en fronteras rígidas, sino que presenta una transición gradual entre escalas de producción.

La técnica permite:

- Detectar nichos
- Identificar películas atípicas
- Visualizar estructura compleja no capturada completamente por PCA

5. Hallazgos y Conclusiones:

- **Hallazgos del clustering:**

El análisis de agrupamiento permitió identificar una segmentación natural del mercado cinematográfico en 4 grandes grupos diferenciados principalmente por la magnitud económica de las producciones.

Se identificaron los siguientes perfiles:

- **Producciones muy pequeñas o atípicas:** películas con presupuestos y recaudaciones extremadamente bajas, baja duración y mínima interacción del público. Representan proyectos no comerciales o registros con escasa consolidación.
- **Producciones pequeñas comerciales:** películas de bajo presupuesto con rendimiento moderado y participación aceptable del público.
- **Producciones medianas:** películas con inversión considerable, buen retorno financiero y mayor interacción en términos de votos.
- **Blockbusters:** grupo reducido, pero altamente rentable, caracterizado por presupuestos elevados, ingresos muy altos, alta popularidad y fuerte participación del público.

El análisis de la silueta mostró una estructura de agrupamiento moderado, lo cual es razonable considerando el tamaño del dataset y la correlación entre variables económicas. La segmentación confirma que el mercado cinematográfico está fuertemente estructurado por niveles de inversión y retorno.

- **Hallazgos del Análisis de Componentes Principales:**

El PCA permitió reducir 13 variables numéricas a 6 componentes principales conservando más del 80% de la varianza total, lo que representa una reducción significativa de dimensionalidad sin pérdida de información.

El primer componente, que explica aproximadamente el 37% de la varianza, está asociado principalmente a variables económicas como presupuesto, ingresos y participación del público, lo que conforma que la dimensión dominante del dataset es la escala de producción y el desempeño comercial.

Los resultados del PCA respaldan los hallazgos del clustering, ya que la principal diferenciación entre grupos también estuvo determinada por variables financieras y de interacción del público. Esto demuestra que la estructura identificada no es arbitraria, sino que responde a dimensiones latentes reales del mercado cinematográfico.

- **Hallazgos de las reglas de asociación:**

Las reglas de asociación evidenciaron patrones consistentes entre popularidad, ingresos, calificación promedio y conteo de votos.

Se observó que:

- Películas con mayor popularidad tienden a presentar mayor conteo de votos.

- Películas con ingresos altos y calificaciones medias-altas se asocian frecuentemente con mayor interacción del público.
- Películas más antiguas tienden a acumular mayor cantidad de votos, lo cual puede explicarse por mayor tiempo de exposición.

Las reglas con mayor lift (>2) indican asociaciones significativamente más fuertes que el azar, lo que refuerza la relación entre visibilidad, desempeño comercial y participación del público.

En conjunto, estas reglas permiten perfilar características típicas de películas con alta interacción y mayor impacto en la audiencia.

Hallazgo adicional mediante t-SNE

La aplicación de t-SNE permitió validar visualmente la segmentación obtenida mediante clustering. Se observó una separación clara del grupo de blockbusters y una transición gradual entre producciones pequeñas y medianas, lo que confirma que la principal estructura del mercado está determinada por la escala económica.

Este resultado refuerza la idea de que las producciones de alta inversión presentan características distintivas dentro del mercado, mientras que los segmentos intermedios comparten atributos similares, lo cual puede representar oportunidades estratégicas para optimizar inversión con menor riesgo.

- **Conclusiones generales:**

El análisis integral del dataset revela que el mercado cinematográfico puede segmentarse principalmente por escala económica y desempeño comercial.

La mayoría de las películas pertenecen a categorías de baja o mediana inversión, mientras que un grupo reducido de producciones concentra altos niveles de ingresos y participación. Esto sugiere una estructura desigual donde pocos proyectos generan gran parte del impacto económico.

La fuerte correlación entre presupuesto, ingresos y participación del público indica que la inversión continúa siendo un factor determinante en el éxito comercial, aunque la popularidad y la calificación también juegan un papel relevante.

- **Recomendaciones para CineVision Studios**

En base a los hallazgos obtenidos, se sugieren las siguientes estrategias:

- Evaluar cuidadosamente el nivel de inversión según el tipo de proyecto, considerando que los blockbusters representan alto riesgo, pero alto retorno.
- Priorizar estrategias de marketing que aumenten la popularidad inicial, dado que esta variable se relaciona fuertemente con la interacción del público.
- Analizar combinaciones de características asociadas a alta participación (ingresos altos + buena calificación + duración mayor).

- Considerar análisis adicionales sobre subsegmentos dentro de producciones medianas, ya que podrían representar oportunidades de crecimiento con menor riesgo financiero.