

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Minería de datos

Semestre I – 2026



## Laboratorio 3

Integrantes:

Ciprian Jimenez, Mishell Rosa Elvira – 231169

Nájera Marakovits, Ingrid Nina Alessandra - 231088

Ramírez Velásquez, Diego Alejandro – 23601

**Enlace del repositorio:** <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Laboratorio3>

**Enlace del documento en línea:** [Laboratorio 3.docx](#)

## **Preparación y comprensión de los datos:**

### **1. Descripción del conjunto de datos**

El conjunto de datos utilizado corresponde a listados de propiedades de Airbnb e incluye información sobre características de las viviendas, disponibilidad, reseñas y precios. Inicialmente, el dataset contenía 171,748 observaciones y 80 variables, incluyendo numéricas, categóricas y de texto.

El objetivo principal del análisis es identificar los patrones en los datos que permitan comprender los factores asociados al precio de las propiedades y construir posteriormente modelos predictivos que permitan estimar dicho valor.

### **2. Identificación de la variable respuesta**

Para el desarrollo del análisis se definió como variable respuesta el precio de las propiedades, representado por la variable price.

Esta variable indica el valor del alojamiento ofrecido en la plataforma y constituye el elemento principal que se busca analizar y posteriormente predecir mediante modelos de regresión. Durante la inspección del dataset se observó que la variable estaba almacenada como texto y contenía símbolos monetarios y separadores de miles, lo cual impedía su uso directo en análisis estadístico. Se realizó una limpieza y transformación para convertirla a formato numérico.

En primer lugar, se realizó una inspección general del dataset utilizando funciones de exploración como head(), info() y describe(). Esto permitió identificar el tipo de cada variable, el número de observaciones y la presencia de valores faltantes.

Posteriormente, se procedió a limpiar la variable **price**, eliminando los símbolos monetarios (\$) y los separadores de miles (,) presentes en los registros. Después de esta limpieza, la variable fue convertida a formato numérico para permitir su análisis estadístico y su uso en modelos de regresión.


### **4. Manejo de valores faltantes**

En el análisis inicial se identificaron registros sin información de precio. Debido a que price es la variable respuesta del modelo, estas observaciones no pueden utilizarse en el análisis.

Por esta razón, se eliminaron las filas que presentaban valores faltantes en esta variable, conservando únicamente observaciones con información válida de precio. Después de este proceso, el conjunto de datos quedó reducido a 76,246 observaciones.


## 5. Análisis descriptivo de price

Una vez realizada la limpieza del dataset, se llevó a cabo un análisis descriptivo de la variable precio utilizando estadísticas básicas y visualizaciones gráficas.



*Gráfico 1. Distribución de  $\log(\text{price})$*

El histograma del precio mostró una **distribución fuertemente asimétrica hacia la derecha**, con una gran concentración de propiedades en rangos de precio bajos y una cola larga hacia valores altos.




*Gráfico 2. Boxplot Price*

El diagrama de caja (boxplot) confirmó la presencia de **numerosos valores extremos**, lo cual indica que existe un pequeño grupo de propiedades con precios considerablemente mayores al resto del mercado.

# Relaciones cuantitativas con el precio

Con el fin de complementar el análisis descriptivo y categórico, se estudió la relación entre las variables numéricas del dataset y el precio de las propiedades. Para ello, se trabajó con las observaciones que contaban con precio válido, obteniendo un total de 76,246 registros. Además, debido a la fuerte asimetría de la variable precio, se construyó también una transformación logarítmica, `log_price`, con el objetivo de estabilizar la varianza y facilitar la identificación de relaciones más claras con las variables explicativas.

## 1. Matriz de correlación




|                                              | corr_price | corr_log price |
|----------------------------------------------|------------|----------------|
| accommodates                                 | 0.0997     | 0.5157         |
| availability_30                              | -0.0208    | 0.0067         |
| availability_365                             | -0.0381    | -0.0164        |
| availability_60                              | -0.0277    | -0.0365        |
| availability_90                              | -0.0346    | -0.0684        |
| availability_eoy                             | -0.0369    | -0.0798        |
| bathrooms                                    | 0.0797     | 0.4655         |
| bedrooms_num                                 | 0.0516     | 0.4233         |
| beds_num                                     | -0.0208    | 0.3769         |
| calculated_host_listings_count               | 0.0675     | 0.2434         |
| calculated_host_listings_count_entire_homes  | 0.0271     | 0.2275         |
| calculated_host_listings_count_private_rooms | 0.1543     | -0.0015        |
| calculated_host_listings_count_shared_rooms  | -0.0070    | -0.0863        |
| estimated_occupancy_l365d                    | -0.1079    | -0.2436        |
| latitude                                     | -0.0283    | -0.1757        |


Se construyó una matriz de correlación entre las principales variables numéricas del conjunto de datos, considerando tanto `price_clean` como `log_price`. Esta comparación permitió verificar que la transformación logarítmica ofrece relaciones más interpretables que el precio original, el cual presenta una distribución altamente sesgada y afectada por valores extremos.

Los resultados muestran que, al analizar la correlación con `log_price`, las variables numéricas más relacionadas con el precio fueron `accommodates` ( $r = 0.5157$ ), `bathrooms` ( $r = 0.4655$ ), `bedrooms_num` ( $r = 0.4233$ ) y `beds_num` ( $r = 0.3769$ ). En contraste, `estimated_occupancy_l365d` presentó una relación negativa moderada ( $r = -0.2436$ ), lo que sugiere que una mayor ocupación estimada no necesariamente se asocia con precios más altos.

En términos prácticos, estos resultados indican que las características asociadas al tamaño y capacidad del alojamiento son las que mejor explican el comportamiento del precio entre las variables numéricas analizadas. Por lo tanto, propiedades con mayor capacidad, más baños, más dormitorios y más camas tienden a presentar precios más altos.

## 2. Relaciones bivariadas





Para profundizar en estas asociaciones, se elaboraron gráficos de dispersión entre las variables numéricas más relevantes y el precio, tanto en su escala original como en escala logarítmica. Los scatterplots mostraron que la relación entre price\_clean y las variables explicativas se ve

afectada por una elevada dispersión y por la presencia de outliers. En cambio, al utilizar `log_price`, las tendencias se observan de forma más estable y cercana a un patrón lineal.

Visualmente, `accommodates`, `bathrooms`, `bedrooms_num` y `beds_num` mostraron tendencias positivas claras con `log_price`. Esto implica que, a medida que aumenta la capacidad o el tamaño de la propiedad, también tiende a incrementarse el precio. Por su parte, `estimated_occupancy_l365d` mostró una tendencia negativa, aunque con mayor dispersión, por lo que su aporte explicativo parece menor que el de las variables estructurales del alojamiento.


### 3. Correlación de Pearson y Spearman

|   | variable                  | spearman_log_price |
|---|---------------------------|--------------------|
| 0 | price_clean               | 1.0000             |
| 6 | price_clean               | 1.0000             |
| 1 | accommodates              | 0.5955             |
| 2 | bathrooms                 | 0.5197             |
| 4 | beds_num                  | 0.5093             |
| 3 | bedrooms_num              | 0.5031             |
| 5 | estimated_occupancy_l365d | -0.2594            |

Con el objetivo de evaluar no solo relaciones lineales, sino también asociaciones monótonas, se complementó el análisis con la correlación de Spearman. Los resultados confirmaron el mismo patrón observado con Pearson. Excluyendo la variable `price_clean` como predictor, las asociaciones monotónicas más fuertes con `log_price` fueron `accommodates` ( $\rho = 0.5955$ ), `bathrooms` ( $\rho = 0.5197$ ), `beds_num` ( $\rho = 0.5093$ ) y `bedrooms_num` ( $\rho = 0.5031$ ). Nuevamente, `estimated_occupancy_l365d` presentó una relación negativa más débil ( $\rho = -0.2594$ ).

Estos resultados refuerzan la idea de que las variables relacionadas con la capacidad y el tamaño físico de la propiedad son buenos predictores cuantitativos del precio. Además, el hecho de que Spearman arroje valores incluso ligeramente mayores que Pearson en algunas variables sugiere que estas relaciones son monotónicas y relativamente estables, aunque no perfectamente lineales.

### 4. Pruebas de normalidad y transformación



|   | variable    | shapiro_stat | p_value | skewness | kurtosis |
|---|-------------|--------------|---------|----------|----------|
| 0 | price_clean | 0.1212       | 0.0000  | 9.5934   | 93.4422  |
| 1 | log_price   | 0.8818       | 0.0000  | 1.8099   | 6.9942   |

Para evaluar la distribución del precio, se aplicó la prueba de Shapiro-Wilk sobre una muestra de 5,000 observaciones para price\_clean y log\_price. En ambos casos se rechazó la hipótesis de normalidad ( $p = 0.0000$ ). Sin embargo, la comparación de asimetría y curtosis mostró una mejora sustancial al aplicar la transformación logarítmica. En price\_clean, la asimetría fue de 9.5934 y la curtosis de 93.4422, lo cual evidencia una distribución extremadamente sesgada y con colas pesadas. En log\_price, estos valores se redujeron a 1.8099 y 6.9942, respectivamente.

Los histogramas también muestran que price\_clean se concentra fuertemente en valores bajos y presenta una cola larga hacia la derecha, mientras que log\_price adopta una forma mucho más compacta y cercana a una distribución simétrica. Aunque la prueba formal sigue rechazando normalidad, la transformación logarítmica mejora notablemente la distribución y resulta más adecuada para análisis posteriores y para la construcción de modelos predictivos.

## 5. Interpretación técnica

En conjunto, el análisis cuantitativo permite concluir que las variables numéricas más útiles para explicar el precio son aquellas asociadas con la dimensión y capacidad del alojamiento. En particular, accomodates destaca como la variable más fuertemente relacionada con log\_price, seguida de bathrooms, bedrooms\_num y beds\_num. Esto tiene sentido desde el punto de vista del mercado, ya que propiedades capaces de alojar a más personas y con mejores condiciones de espacio tienden a ofrecerse a precios superiores.

Desde el punto de vista matemático, el uso de log\_price se justifica porque reduce la influencia de valores extremos, disminuye la asimetría de la variable respuesta y permite



identificar relaciones más limpias entre precio y predictores numéricos. Por ello, para modelado posterior, resulta más conveniente trabajar con `log_price` que con el precio original.

## **Ingeniería de características**

A partir del análisis exploratorio de las variables numéricas, se seleccionaron aquellas que presentan una relación más clara con el precio de las propiedades y que representan características del alojamiento.

- `Accommodates`: número de personas que puede alojar la propiedad.
- `Bathrooms`: número de baños disponibles.
- `Bedrooms_num`: número de dormitorios.
- `Beds_num`: número de camas.

Estas variables fueron elegidas porque muestran las correlaciones más altas con la variable respuesta y porque representan directamente el tamaño y la capacidad de alojamiento.

Desde el punto de vista del mercado de hospedaje, propiedades que tienen una mayor capacidad y las mejores condiciones de espacios suelen ofrecerse a precios más altos, porque estas variables constituyen buenos predictores iniciales para la construcción de modelos de regresión que permitan estimar el precio de las propiedades.

Durante el proceso se revisó la variable `bathrooms`, identificándose algunos registros con valor 0, lo cual puede representar alojamientos sin baño privado o información no especificada por el anfitrión; debido a que estos casos representan una proporción muy pequeña en el dataset, se mantuvieron en el análisis.

## **División del dataset**

Para hacer una evaluación correcta del desempeño de los modelos predictivos, el conjunto de datos fue dividido en 2 subconjuntos: un conjunto de entrenamiento y un conjunto de prueba.

El conjunto de entrenamiento se utiliza para ajustar los modelos de regresión; muestra que el conjunto de prueba permite evaluar la capacidad del modelo para generalizar a datos no observados.

Se utilizó una división del 70% de los datos para entrenamiento y el 30% para prueba. Además, se fijó una semilla aleatoria de 42 para garantizar que la partición del dataset sea reproducible.

Después de la división, el conjunto de entrenamiento quedó conformado por 53,222 observaciones, mientras que el conjunto de prueba contiene 22,810 observaciones.

## **Segmentación y patrones del mercado**

Para esta parte se analizó la relación entre distintas variables categóricas y el precio de las propiedades, así como la formación de grupos mediante técnicas de agrupamiento exploratorio. Debido a la presencia de valores extremos en la variable precio, primero se trabajó con una limpieza local para esta sección, conservando únicamente observaciones con precio válido y acotando los valores extremos para facilitar una interpretación más estable de los resultados. Después de este filtrado, el análisis se realizó sobre 75,129 observaciones.

## 1. Variables categóricas vs precio

Se analizaron las variables categóricas `room_type`, `property_type_top`, `host_is_superhost`, `instant_bookable`, `city` y `neighbourhood_group_cleansed` para evaluar su relación con el precio de las propiedades. Para esta parte se trabajó con una limpieza local del precio, conservando únicamente observaciones con precio válido y acotando valores extremos para facilitar una interpretación más estable. Después del filtrado, el análisis se realizó sobre 75,129 observaciones.

Las distribuciones muestran que el precio cambia según el tipo de alojamiento, el tipo de propiedad y la ubicación. En general, los espacios completos y las propiedades ubicadas en zonas más demandadas presentan precios más altos, mientras que los cuartos privados y compartidos concentran precios menores.

*Tabla 1. Variables categóricas analizadas*

| Variable                                  | Número de categorías | Valores nulos |
|-------------------------------------------|----------------------|---------------|
| <code>room_type</code>                    | 4                    | 0             |
| <code>property_type_top</code>            | 13                   | 0             |
| <code>host_is_superhost</code>            | 3                    | 0             |
| <code>instant_bookable</code>             | 2                    | 0             |
| <code>city</code>                         | 7                    | 0             |
| <code>neighbourhood_group_cleansed</code> | 9                    | 37,796        |

*Gráfico 1. Distribución del precio según `room_type`*





Gráfico 2. Distribución del precio según city



## 2. Comparación de medias y medianas

La comparación de medias y medianas confirma que existen diferencias importantes de precio entre categorías. En room\_type, las categorías con valores más altos fueron Hotel room y Entire home/apt, mientras que Private room y Shared room presentaron precios considerablemente menores. Esto sugiere que el nivel de privacidad y el tipo de espacio ofrecido influyen de forma importante en el valor del alojamiento.

En property\_type\_top, los mayores valores se observaron en Private room in resort, Entire home y Room in hotel. En cambio, Private room in home y Private room in rental unit mostraron las medianas más bajas. También se observó que los anuncios con instant\_bookable y los de anfitriones superhost tienden a presentar precios medianos más altos. A nivel geográfico, Rhode Island y Hawaii destacaron como las ciudades con medianas más elevadas.

Tabla 2. Precio por tipo de habitación

| room_type       | count  | mean   | median | std    |
|-----------------|--------|--------|--------|--------|
| Hotel room      | 290    | 394.46 | 278.0  | 373.17 |
| Entire home/apt | 65,143 | 317.30 | 203.0  | 394.19 |
| Private room    | 9,484  | 160.01 | 84.0   | 229.29 |
| Shared room     | 212    | 52.43  | 41.0   | 81.50  |

Tabla 3. Precio por tipo de propiedad

| property_type_top         | count  | mean   | median | std    |
|---------------------------|--------|--------|--------|--------|
| Private room in resort    | 573    | 493.61 | 361.0  | 404.86 |
| Entire home               | 16,217 | 425.74 | 280.0  | 473.64 |
| Room in hotel             | 1,444  | 375.35 | 261.0  | 340.95 |
| Entire townhouse          | 1,614  | 333.60 | 257.0  | 296.42 |
| Entire serviced apartment | 813    | 361.30 | 253.0  | 330.29 |
| Entire cottage            | 746    | 256.42 | 219.5  | 156.35 |

|                             |        |        |       |        |
|-----------------------------|--------|--------|-------|--------|
| Entire condo                | 19,355 | 331.67 | 217.0 | 399.19 |
| Entire rental unit          | 20,321 | 236.77 | 168.0 | 300.40 |
| Other                       | 5,061  | 270.57 | 144.0 | 440.05 |
| Entire guesthouse           | 1,681  | 145.82 | 118.0 | 115.46 |
| Entire guest suite          | 1,595  | 136.91 | 115.0 | 93.04  |
| Private room in home        | 3,654  | 90.74  | 67.0  | 113.90 |
| Private room in rental unit | 2,055  | 80.41  | 60.0  | 86.23  |

*Tabla 4. Precio según superhost y reserva inmediata*

| Variable          | Categoría | count  | mean   | median | std    |
|-------------------|-----------|--------|--------|--------|--------|
| host_is_superhost | t         | 39,018 | 322.09 | 200.0  | 416.74 |
| host_is_superhost | f         | 34,086 | 272.39 | 181.0  | 338.48 |
| host_is_superhost | 2025      | 2,025  | 227.66 | 144.0  | 268.79 |
| instant_bookable  | t         | 32,957 | 329.48 | 208.0  | 428.66 |
| instant_bookable  | f         | 42,172 | 271.61 | 176.0  | 336.14 |


*Tabla 5. Precio por ciudad*

| city                  | count  | mean   | median | std    |
|-----------------------|--------|--------|--------|--------|
| Rhode Island          | 4,934  | 365.59 | 270.0  | 378.02 |
| Hawaii                | 32,399 | 371.86 | 228.0  | 467.97 |
| Boston, Massachusetts | 3,463  | 245.25 | 203.0  | 193.48 |
| San Diego, California | 11,270 | 258.33 | 175.0  | 279.95 |
| Chicago, Illinois     | 7,751  | 207.15 | 152.0  | 233.63 |
| Austin, Texas         | 10,459 | 219.56 | 134.0  | 319.69 |
| Washington, D.C.      | 4,853  | 164.61 | 124.0  | 167.75 |

*Tabla 6. Precio por neighbourhood\_group\_cleansed*

| neighbourhood_group_cleansed | count | mean   | median | std    |
|------------------------------|-------|--------|--------|--------|
| Washington                   | 1,631 | 457.74 | 375.0  | 359.16 |
| Kauai                        | 5,543 | 450.57 | 302.0  | 471.48 |
| Newport                      | 1,714 | 424.96 | 299.0  | 452.27 |
| Maui                         | 9,932 | 472.42 | 260.0  | 592.22 |
| Bristol                      | 194   | 307.37 | 231.0  | 246.28 |
| Hawaii                       | 7,971 | 309.16 | 198.0  | 399.99 |
| Honolulu                     | 8,953 | 267.38 | 177.0  | 306.54 |
| Kent                         | 152   | 188.35 | 152.5  | 135.93 |
| Providence                   | 1,243 | 193.57 | 132.0  | 233.40 |

*Gráfico 3. Distribución del precio según property\_type\_top*



### 3. ANOVA

Para complementar la comparación descriptiva se aplicó una prueba ANOVA de un factor. En todas las variables categóricas analizadas se obtuvieron valores p menores a 0.05, por lo que se concluye que existen diferencias estadísticamente significativas en el precio entre sus categorías.

Las variables con mayor capacidad de diferenciación fueron city, room\_type y property\_type\_top, ya que presentaron los mayores valores del estadístico F. Esto refuerza la idea de que la ubicación, el tipo de habitación y el tipo de propiedad son factores importantes en la variación del precio.

En la variable host\_is\_superhost se detectó una categoría anómala adicional, por lo que la interpretación sustantiva se centró principalmente en las categorías válidas t y f.

*Tabla 7. Resultados de ANOVA para variables categóricas vs precio*

| Variable                     | F          | p_value      |
|------------------------------|------------|--------------|
| room_type                    | 517.306328 | 0.000000e+00 |
| property_type_top            | 455.541092 | 0.000000e+00 |
| neighbourhood_group_cleansed | 203.565528 | 0.000000e+00 |
| city                         | 529.117006 | 0.000000e+00 |
| instant_bookable             | 430.268081 | 2.632163e-95 |
| host_is_superhost            | 190.601430 | 2.704931e-83 |

### 4. Agrupamiento exploratorio


Después del análisis categórico se realizó un agrupamiento exploratorio con k-means sobre variables numéricas relacionadas con capacidad, tamaño, reseñas, disponibilidad y permanencia mínima. Para seleccionar el número de grupos se compararon el método del codo y el silhouette score.

La mejor solución fue de 3 clusters, ya que presentó el mayor silhouette score, con un valor aproximado de 0.294. Además, esta cantidad de grupos permite una segmentación interpretable del mercado, separando propiedades más económicas, propiedades intermedias y propiedades premium.


*Tabla 8. Evaluación del número de clusters*

| k | inercia      | silhouette |
|---|--------------|------------|
| 2 | 21913.623957 | 0.266267   |
| 3 | 19015.497719 | 0.294217   |
| 4 | 17121.794849 | 0.205409   |
| 5 | 15333.243177 | 0.217197   |

*Gráfico 4. Método del codo para selección del número de clusters.*



*Gráfico 5. Silhouette score según número de clusters.*



## 5. Caracterización de clusters

La solución final generó tres grupos con tamaños distintos. El cluster 0 quedó conformado por 9,633 observaciones, el cluster 1 por 18,917 y el cluster 2 por 46,579.

El cluster 0 agrupa propiedades de tamaño moderado, con capacidad media de 3.62 personas, alrededor de 1.17 baños, 1.23 dormitorios y 1.92 camas. También muestra una cantidad muy alta de reseñas y una estancia mínima baja. Por ello puede interpretarse como un segmento más económico y de alta rotación.

El cluster 1 representa el segmento premium. Sus propiedades son las más grandes, con capacidad media de 8.54 personas, 2.67 baños, 3.43 dormitorios y 4.99 camas. Además, presenta una permanencia mínima más alta y el mayor nivel de precio entre los tres grupos.

El cluster 2 reúne la mayor cantidad de observaciones y presenta propiedades de tamaño similar al cluster 0, pero con menos reseñas y una permanencia mínima mucho más alta. Este grupo parece corresponder a un segmento intermedio o económico-medio, con una orientación más marcada hacia estancias largas.

*Tabla 9. Tamaño de los clusters*

| Cluster | Cantidad de observaciones |
|---------|---------------------------|
| 0       | 9,633                     |
| 1       | 18,917                    |
| 2       | 46,579                    |

*Tabla 10. Caracterización numérica de clusters*

| Cluster | accommodates | bathrooms | bedrooms_num | beds_num | minimum_nights | number_of_reviews | review_scores_rating | availability_365 |
|---------|--------------|-----------|--------------|----------|----------------|-------------------|----------------------|------------------|
| 0       | 3.62         | 1.17      | 1.23         | 1.92     | 2.70           | 234.80            | 4.86                 | 214.67           |
| 1       | 8.54         | 2.67      | 3.43         | 4.99     | 6.57           | 35.07             | 4.85                 | 236.59           |
| 2       | 3.52         | 1.26      | 1.25         | 1.83     | 12.15          | 26.26             | 4.77                 | 232.92           |

*Tabla 11. Moda de variables categóricas por cluster*

| Cluster | room_type       | city   | host_is_superhost | instant_bookable | property_type_top  |
|---------|-----------------|--------|-------------------|------------------|--------------------|
| 0       | Entire home/apt | Hawaii | t                 | f                | Entire rental unit |
| 1       | Entire home/apt | Hawaii | t                 | f                | Entire home        |
| 2       | Entire home/apt | Hawaii | f                 | f                | Entire rental unit |

## 6. Relación grupos-precio


Al comparar el precio entre clusters se observa una separación clara. El cluster 1 concentra las propiedades con mayor valor, mientras que el cluster 0 reúne las opciones más económicas. El cluster 2 ocupa una posición intermedia.

Esto confirma que la segmentación obtenida no es arbitraria, sino que captura diferencias reales del mercado. En otras palabras, los clusters encontrados representan perfiles distintos de propiedades y estos perfiles también se distinguen por su nivel de precio.

*Tabla 12. Precio por cluster*

| Cluster | count  | mean   | median | std    |
|---------|--------|--------|--------|--------|
| 0       | 9,633  | 159.21 | 135.0  | 102.31 |
| 1       | 18,917 | 553.94 | 372.0  | 580.98 |
| 2       | 46,579 | 221.14 | 166.0  | 240.64 |

*Gráfico 6. Distribución del precio por cluster.*



## 7. Interpretación de negocio

Desde una perspectiva de negocio, los resultados sugieren que el mercado puede dividirse en tres segmentos principales: un segmento económico y de alta rotación, un segmento premium compuesto por propiedades más grandes y completas, y un segmento intermedio asociado a estancias más largas.

Las propiedades con mayor precio tienden a ser Entire home/apt, Entire home y otros tipos de alojamiento con características más exclusivas, como Private room in resort y Room in hotel. Además, la ubicación también marca diferencias claras, ya que Rhode Island, Hawaii, Washington y Kauai presentan medianas más altas que otras zonas del conjunto analizado.

En general, variables como room\_type, property\_type\_top, city e instant\_bookable muestran una relación importante con el precio. Por su parte, el agrupamiento permitió identificar perfiles de oferta útiles para entender la segmentación del mercado y apoyar futuras decisiones de fijación de precios o recomendación de propiedades.



## Modelos básicos para predicción del precio

En esta etapa se construyeron modelos básicos de regresión para predecir el precio de las propiedades. Aunque la variable original de interés es price, para el modelado se utilizó log\_price, ya que esta transformación reduce la asimetría de la distribución, disminuye el efecto de valores extremos y permite obtener relaciones más estables con las variables explicativas. Para ello se trabajó con un conjunto de 76,032 observaciones limpias y se dividió la información en entrenamiento (53,222 registros) y prueba (22,810 registros).

### 1. Modelo de regresión lineal simple

Como modelo base se utilizó una regresión lineal simple, tomando accommodates como variable explicativa y log\_price como variable respuesta. Esta variable fue seleccionada porque representa la capacidad del alojamiento y, además, en el análisis previo mostró una relación importante con el precio.

El modelo estimado fue el siguiente:

$$\log\_price = 4.5604 + 0.1713(\text{accommodates})$$


El intercepto de 4.5604 representa el valor esperado de log\_price cuando accommodates es igual a 0, mientras que el coeficiente de 0.1713 indica que, por cada persona adicional que puede alojar una propiedad, el log\_price aumenta en promedio en 0.1713 unidades. Esto sugiere una relación positiva entre la capacidad del alojamiento y el precio.

En cuanto al desempeño, el modelo obtuvo un  $R^2$  de 0.2690 en entrenamiento y 0.2595 en prueba, lo que indica que explica aproximadamente el 26% de la variabilidad del precio transformado. Además, en el conjunto de prueba se obtuvo un MAE de 0.5616 y un RMSE de 0.8472. Estos resultados muestran que el modelo simple logra captar una parte del comportamiento del precio, aunque su capacidad explicativa sigue siendo limitada al depender de una sola variable.

Tabla 13. Métricas del modelo de regresión lineal simple

| Métrica                         | Valor  |
|---------------------------------|--------|
| Intercepto                      | 4.5604 |
| Coeficiente de accommodates     | 0.1713 |
| (R <sup>2</sup> ) entrenamiento | 0.2690 |
| (R <sup>2</sup> ) prueba        | 0.2595 |
| MAE prueba                      | 0.5616 |
| RMSE prueba                     | 0.8472 |

Gráfico 7. Regresión lineal simple entre accommodates y log\_price



## 2. Modelo de regresión lineal múltiple

Posteriormente se ajustó un modelo de regresión lineal múltiple para mejorar la capacidad explicativa del modelo simple. En este caso se utilizaron como variables predictoras accommodates, bedrooms, beds y bathrooms, ya que todas representan características estructurales del alojamiento que pueden influir en el precio.

El modelo múltiple mejoró el desempeño respecto al modelo simple. Se obtuvo un  $R^2$  de 0.3034 en entrenamiento y 0.2823 en prueba, lo que significa que el modelo explica cerca del 28% de la variabilidad del log\_price en datos no vistos. Asimismo, en el conjunto de prueba se obtuvo un MAE de 0.5493 y un RMSE de 0.8340. Aunque la mejora no es extremadamente grande, sí evidencia que incluir varias características del alojamiento permite representar mejor el comportamiento del precio.

Los coeficientes estimados muestran que bathrooms y accommodates tienen un efecto positivo sobre el precio transformado, mientras que bedrooms y beds aparecen con coeficientes negativos al mantener constantes las demás variables. Este resultado no necesariamente implica que más habitaciones o más camas reduzcan el precio en términos reales, sino que puede deberse a la relación existente entre variables de tamaño y capacidad dentro del mismo modelo.

Tabla 14. Métricas del modelo de regresión lineal múltiple

| Métrica                 | Valor  |
|-------------------------|--------|
| ( $R^2$ ) entrenamiento | 0.3034 |
| ( $R^2$ ) prueba        | 0.2823 |
| MAE prueba              | 0.5493 |

|             |        |
|-------------|--------|
| RMSE prueba | 0.8340 |
|-------------|--------|

*Tabla 15. Coeficientes del modelo de regresión lineal múltiple*

| Variable     | Coeficiente |
|--------------|-------------|
| bathrooms    | 0.2597      |
| accommodates | 0.1819      |
| bedrooms     | -0.0390     |
| beds         | -0.1001     |

De forma general, el modelo múltiple resulta mejor que el modelo simple, ya que presenta mayor capacidad explicativa y menores errores de predicción. Por lo tanto, puede considerarse una mejor aproximación inicial al problema de predicción del precio.

### 3. Análisis de correlación y multicolinealidad

Además del ajuste de los modelos, se evaluó la relación entre las variables predictoras mediante la matriz de correlación y el factor de inflación de la varianza (VIF). Este análisis es importante porque, cuando dos o más variables explicativas están fuertemente relacionadas entre sí, puede surgir multicolinealidad y afectar la interpretación de los coeficientes.

La matriz de correlación mostró asociaciones entre las variables relacionadas con el tamaño y la capacidad del alojamiento, especialmente entre accommodates, bedrooms, beds y bathrooms. Esto es razonable, ya que propiedades más grandes suelen tener más habitaciones, más camas y más baños.

Para cuantificar esta relación se calculó el VIF de cada predictor. Los resultados obtenidos fueron: accommodates = 4.4303, bedrooms = 4.1604, beds = 3.7628 y bathrooms = 2.5756. En general, valores de VIF superiores a 5 sugieren multicolinealidad moderada y valores por encima de 10 indican un problema severo. En este caso, aunque sí existe correlación entre las variables, no se observa una multicolinealidad severa.

*Tabla 16. Factor de inflación de la varianza (VIF)*


| Variable     | VIF    |
|--------------|--------|
| accommodates | 4.4303 |
| bedrooms     | 4.1604 |
| beds         | 3.7628 |
| bathrooms    | 2.5756 |

Adicionalmente, el resumen estadístico del modelo OLS mostró un  $R^2$  ajustado de 0.303 y un valor de significancia global del modelo igual a 0.00, lo que indica que el modelo en conjunto es estadísticamente significativo. Asimismo, los coeficientes

estimados resultaron significativos, por lo que las variables incluidas aportan información útil para explicar el precio transformado.

En síntesis, el análisis de correlación y multicolinealidad muestra que las variables seleccionadas están relacionadas entre sí, pero no al nivel de invalidar el modelo. Por ello, el modelo múltiple puede utilizarse como una base razonable para la predicción, aunque todavía existe espacio para comparar su desempeño con modelos más avanzados en la siguiente etapa del laboratorio.

*Gráfico 8. Matriz de correlación de las variables del modelo*



#### 4. Modelos regularizados

Con el objetivo de mejorar la capacidad predictiva del modelo y evaluar alternativas más robustas frente a la posible multicolinealidad entre variables, se implementaron modelos de regresión regularizada. En particular, se evaluaron los modelos Ridge, Lasso y ElasticNet, los cuales incorporan penalizaciones sobre los coeficientes del modelo para evitar sobreajuste y mejorar la estabilidad de las estimaciones.

Para el entrenamiento de los modelos se utilizaron las variables predictoras seleccionadas previamente en el análisis exploratorio:

- accommodates
- bathrooms
- bedrooms
- beds
- estimated\_occupancy\_l365d

Gráfico 9. variables predictoras

|   | accommodates | bathrooms | bedrooms | beds | estimated_occupancy_l365d |
|---|--------------|-----------|----------|------|---------------------------|
| 0 | 3            | 1.0       | 1.0      | 2.0  | 150                       |
| 1 | 2            | 1.0       | 1.0      | 2.0  | 84                        |
| 2 | 2            | 1.0       | 1.0      | 1.0  | 8                         |
| 3 | 3            | 2.0       | 2.0      | 2.0  | 30                        |
| 4 | 2            | 1.0       | 1.0      | 1.0  | 180                       |

Como variable respuesta se utilizó  $\log\_price$ , ya que la transformación logarítmica reduce la asimetría de la distribución del precio y permite obtener relaciones más estables entre las variables.

Antes de entrenar los modelos, las variables predictoras fueron estandarizadas utilizando StandardScaler, debido a que los métodos de regularización son sensibles a la escala de las variables.

### Evaluación en test set

Los modelos se evaluaron utilizando el conjunto de prueba mediante las métricas RMSE (Root Mean Squared Error) y  $R^2$ , las cuales permiten medir el error de predicción y la proporción de variabilidad explicada por el modelo.

Tabla 17. Comparación de modelos regularizados

| Modelo     | RMSE          | $R^2$         |
|------------|---------------|---------------|
| Ridge      | 0.8186        | 0.3217        |
| Lasso      | 0.8189        | 0.3213        |
| ElasticNet | <b>0.8184</b> | <b>0.3220</b> |


El RMSE representa el error promedio de predicción del modelo, mientras que  $R^2$  indica qué proporción de la variabilidad del precio transformado puede ser explicada por las variables incluidas en el modelo.

### Comparación de modelos

Los resultados muestran que los tres modelos presentan un desempeño muy similar. Sin embargo, ElasticNet obtiene el mejor resultado, ya que presenta el menor RMSE y el mayor valor de  $R^2$  en el conjunto de prueba.

Esto sugiere que la combinación de penalización L1 y L2 utilizada por ElasticNet permite capturar de manera más equilibrada la relación entre las variables predictoras y el precio, especialmente considerando que variables como *accommodates*, *bedrooms*, *beds* y *bathrooms* presentan cierta correlación entre sí.

*Gráfico 10. Comparación de RMSE entre modelos regularizados*



## **Conclusión**

Los modelos regularizados presentan una ligera mejora respecto a los modelos de regresión lineal evaluados anteriormente. El modelo ElasticNet obtuvo el mejor desempeño entre los modelos comparados, alcanzando un  $R^2$  de aproximadamente 0.32 en el conjunto de prueba.

Esto indica que el modelo logra explicar alrededor del 32% de la variabilidad del logaritmo del precio, lo cual representa una mejora respecto al modelo lineal múltiple evaluado previamente. No obstante, aún existe una proporción importante de variabilidad que no es explicada por las variables incluidas, lo que sugiere que otros factores como la ubicación específica, características del anfitrión o atributos adicionales del alojamiento podrían mejorar el poder predictivo del modelo en análisis futuros.