

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Minería de Datos

Semestre I – 2026



Laboratorio 4

Integrantes:

Ciprian Jimenez, Mishell Rosa Elvira – 231169

Nájera Marakovits, Ingrid Nina Alessandra - 231088

Ramírez Velásquez, Diego Alejandro – 23601

Enlace al repositorio: <https://github.com/Ninaswiftie09/Mineria-de-Datos.git>

Árboles de regresión (modelo base)

Descripción del modelo

Se utilizó el conjunto de datos previamente limpiado en el laboratorio anterior. Para mantener consistencia en la evaluación, se empleó la misma división de datos en entrenamiento (80%) y prueba (20%), utilizando un `random\_state` fijo.

La variable objetivo seleccionada fue el precio (`price`), mientras que como variables predictoras se utilizaron únicamente variables numéricas. Se excluyó la variable `log\_price` para evitar fuga de información, ya que está directamente relacionada con la variable objetivo.

Se entrenó un modelo de árbol de regresión sin restricciones en la profundidad, con el objetivo de establecer un modelo base para futuras comparaciones.

Resultados

Los resultados obtenidos en el conjunto de prueba fueron los siguientes:

- RMSE: 1852.16

- R^2 : 0.8159

El valor de RMSE indica que, en promedio, las predicciones del modelo presentan un error de aproximadamente 1852 unidades en el precio. Por otro lado, el coeficiente de determinación (R^2) muestra que el modelo es capaz de explicar el 81.59% de la variabilidad del precio, lo que representa un buen ajuste inicial.




Gráfico 1. valor de RMSE

La gráfica de valores reales vs predichos muestra que los puntos no se alinean completamente sobre la diagonal esperada, lo que indica la presencia de errores en las predicciones.

Se observa que el modelo tiene un mejor desempeño en valores bajos del precio, mientras que en valores altos presenta mayor dispersión y errores significativos. Además, existen casos donde el modelo subestima considerablemente el precio.

Este comportamiento sugiere que el modelo no generaliza adecuadamente en todo el rango de valores y podría estar sobreajustando los datos, debido a que no se estableció un límite en la profundidad del árbol.

Árboles de regresión: optimización y comparación del modelo

Evaluación de modelos con diferentes profundidades

Se entrenaron múltiples modelos de árboles de regresión variando el parámetro `max_depth`, con el objetivo de analizar cómo la complejidad del modelo afecta su desempeño.

Los resultados obtenidos fueron los siguientes:

Profundidad	RMSE
3	259.53
5	77.55
10	37.43

Como se observa, al aumentar la profundidad del árbol, el error disminuye significativamente. Esto indica que modelos más complejos logran capturar mejor las relaciones presentes en los datos.

Estos resultados coinciden con la gráfica generada, donde se aprecia una reducción pronunciada del RMSE conforme aumenta la profundidad del árbol

Selección del mejor modelo

El modelo con mejor desempeño fue el árbol de regresión con profundidad 10, ya que obtuvo el menor error:

$$\text{RMSE} = 37.43$$

Este modelo logra un buen balance entre complejidad y capacidad predictiva, permitiendo capturar patrones más detallados en los datos sin perder capacidad de generalización en el conjunto de prueba.

Comparación con regresión lineal

Se comparó el mejor árbol de regresión con un modelo de regresión lineal, obteniendo los siguientes resultados:

- Árbol de regresión (depth = 10): **RMSE = 37.43**
- Regresión lineal: **RMSE = 4297.59**

La diferencia en el error es considerablemente grande. El modelo de regresión lineal presenta un desempeño significativamente peor en comparación con el árbol de regresión.

Esto sugiere que la relación entre las variables no es puramente lineal, y que el árbol de decisión es capaz de capturar relaciones no lineales y complejas que el modelo lineal no logra representar adecuadamente.




Gráfico 2 . RME vs profundidad del árbol

Análisis de overfitting y underfitting

El comportamiento observado en los modelos permite analizar los conceptos de underfitting y overfitting:

- Underfitting:**
 El modelo con profundidad 3 presenta un RMSE alto (259.53), lo que indica que es demasiado simple y no logra capturar la complejidad de los datos.
- Mejora progresiva:**
 Al aumentar la profundidad a 5, el error disminuye considerablemente, lo que indica que el modelo está aprendiendo mejor las relaciones en los datos.
- Modelo óptimo:**
 Con profundidad 10 se obtiene el mejor resultado, logrando el menor error en el conjunto de prueba.
- Overfitting (posible):**
 Aunque no se observa directamente en estos resultados, profundidades muy altas pueden llevar a que el modelo se ajuste demasiado a los datos de entrenamiento, perdiendo capacidad de generalización.

Conclusión de la sección

En conclusión, el árbol de regresión demostró ser significativamente superior al modelo de regresión lineal para la predicción del precio de los alojamientos. La optimización del parámetro de profundidad permitió identificar un modelo que reduce considerablemente el error de predicción.

El análisis evidencia la importancia de ajustar la complejidad del modelo, ya que modelos demasiado simples no capturan los patrones relevantes, mientras que modelos más profundos pueden mejorar notablemente el desempeño si se controlan adecuadamente.

Clasificación de propiedades según categoría de precio mediante árbol de decisión

- **Definición del problema**

En esta sección se desarrolló un modelo de clasificación con el objetivo de predecir la categoría de precio de cada alojamiento. Para ello, la variable price se transformó en una variable categórica con tres niveles: Económica, Intermedia y Cara. Posteriormente, se entrenó un árbol de clasificación utilizando las variables numéricas del dataset, excluyendo price, ya que esta fue utilizada únicamente para construir la variable objetivo.

- **Definición de las categorías de precio**

Las categorías de precio se definieron a partir de los terciles de la distribución de la variable price. Este criterio permitió formar grupos relativamente balanceados y basados en la distribución real de los datos, evitando elegir límites arbitrarios. De esta manera, los alojamientos se clasificaron en tres grupos: Económica, Intermedia y Cara.

Tabla 1. Definición de categorías de precio

Categoría	Rango de precio
Económica	$\text{price} \leq 143.00$
Intermedia	$143.00 < \text{price} \leq 268.00$
Cara	$\text{price} > 268.00$

- **Distribución de las clases**

Tabla 2. Distribución de registros por categoría

Categoría	Cantidad de registros	Porcentaje
Económica	25689	33.69%
Intermedia	25153	32.99%
Cara	25404	33.32%

La distribución de registros por categoría muestra que las tres clases quedaron bastante balanceadas. Esto es conveniente para el entrenamiento del árbol de clasificación, ya que reduce el sesgo hacia una sola clase y permite que el modelo aprenda de forma más uniforme.

- **Preparación de los datos**

Para mantener consistencia con la parte de regresión, se utilizó el mismo conjunto de entrenamiento y prueba previamente definido. El modelo de clasificación trabajó con 60,996 observaciones para entrenamiento y 15,250 observaciones para prueba. Además, se excluyó la variable price de las variables predictoras para evitar fuga de información, ya que esta sirvió como base para construir la variable categórica objetivo.

- **Resultados del modelo de clasificación**

Tabla 3. Desempeño general del árbol de clasificación

Métrica	Valor
Accuracy	0.8746

Tabla 4. Métricas por clase del modelo

Clase	Precision	Recall	F1-score	Support
Cara	0.88	0.88	0.88	5051
Económica	0.91	0.90	0.91	5085
Intermedia	0.83	0.84	0.84	5114

El árbol de clasificación obtuvo un accuracy de 0.8746, lo que indica que clasificó correctamente aproximadamente el 87.46% de las observaciones del conjunto de prueba. En general, el desempeño fue bueno en las tres categorías, aunque la clase Intermedia presentó valores ligeramente menores de precisión y recall en comparación con las demás. Esto sugiere que dicha categoría resulta más difícil de separar, probablemente porque comparte características con las clases vecinas.

- **Matriz de confusión**




Gráfico 3. matriz de confusión

La matriz de confusión muestra que la mayoría de las predicciones correctas se concentran en la diagonal principal, lo que confirma un buen desempeño general del modelo. Sin embargo, los principales errores se presentan en la categoría Intermedia, que en algunos casos fue clasificada como Cara o como Económica. Esto era esperable, ya que las observaciones intermedias suelen compartir características con ambas categorías extremas.

- **Análisis de errores**

Tabla 5. Errores de clasificación por categoría real y predicha

Real	Predicho como Cara	Predicho como Económica	Predicho como Intermedia
Económica	129	0	374
Intermedia	472	347	0
Cara	0	103	488

El modelo cometió 1913 errores de clasificación en el conjunto de prueba. La mayor parte de estos errores se concentra en la categoría Intermedia, especialmente cuando fue confundida con Cara o con Económica. Esto refuerza la idea de que la categoría intermedia representa una zona de transición entre los precios bajos y altos, por lo que su separación resulta más compleja para el árbol.

- **Visualización del árbol**




Gráfico 4. árbol

La visualización del árbol permite observar las reglas de decisión utilizadas por el modelo para clasificar los alojamientos. Los primeros niveles son los más importantes, ya que contienen las divisiones principales entre categorías. Una ventaja de este enfoque es que no solo permite predecir, sino también interpretar qué variables contribuyen más a diferenciar entre alojamientos económicos, intermedios y caros.

• Conclusión

En conclusión, el árbol de clasificación logró un buen desempeño al predecir la categoría de precio de los alojamientos, alcanzando un accuracy de 87.46%. Las clases quedaron balanceadas gracias al uso de terciles, lo que ayudó a entrenar un modelo más estable. Aunque la categoría Intermedia presentó la mayor cantidad de confusiones, los resultados generales muestran que el modelo es útil para segmentar alojamientos según su nivel de precio de manera interpretable.