

Evaluación de modelos de clasificación
UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería
Minería de datos
Semestre I – 2026



**Laboratorio 6: Evaluación de modelos KNN para
regresión y clasificación**

Integrantes:

Ciprian Jimenez, Mishell Rosa Elvira – 231169
Nájera Marakovits, Ingrid Nina Alessandra - 231088
Ramírez Velásquez, Diego Alejandro – 23601

Enlace del repo: <https://github.com/Ninaswiftie09/Mineria-de-Datos>

Modelo de regresión KNN para la predicción del precio

Se implementó un modelo de regresión utilizando el algoritmo K Nearest Neighbors (KNN) con el objetivo de predecir el precio de los alojamientos.

Para garantizar la comparabilidad con los modelos desarrollados en entregas anteriores, se utilizó el mismo conjunto de datos de entrenamiento y prueba.

El modelo se entrenó utilizando las variables numéricas del conjunto de datos previamente procesado, y se empleó un valor de $k = 5$ vecinos. Posteriormente, se realizaron predicciones sobre el conjunto de prueba, obteniendo estimaciones del precio para cada observación.

Análisis del desempeño del modelo KNN

Se evaluó el desempeño del modelo KN utilizando las métricas RMSE, MAE y R^2 .

El modelo obtuvo un RMSE de 2971.54, un MAE de 536.39 y un R^2 de 0.5260.

Estos resultados indican que el modelo presenta un error considerable en la predicción del precio de los alojamientos. En particular, el valor de RMSE muestra que existen desviaciones importantes entre los valores reales y los predichos, especialmente en aquellos casos donde los precios se elevan. Por otro lado, el MAE indica que, en promedio, el error absoluto de las predicciones es de aproximadamente 536 unidades monetarias.

El valor de R^2 de 0.5260 sugiere que el modelo logra explicar alrededor del 52.6% de la variabilidad del precio, lo cual representa un desempeño moderado. Esto indica que, aunque el modelo es capaz de capturar cierta relación entre las variables predictoras y el precio, aún existe una proporción significativa de la variación que no se explica.

El comportamiento del modelo se debe a la naturaleza del algoritmo KNN, el cual basa sus predicciones en los valores de los vecinos más cercanos. Esto le permite capturar relaciones no lineales en los datos; sin embargo, su desempeño depende fuertemente de la distribución de los datos y de la presencia de valores extremos. En este caso, la alta dispersión en la variable precio afecta la precisión del modelo, ya que los valores altos tienden a ser subestimados.

En general, el modelo KNN logra un desempeño aceptable, pero presenta limitaciones en la predicción precisa del precio, especialmente en presencia de alta variabilidad en los datos.




Figura 1. Comparación entre datos reales y predichos

Comparación del modelo KNN con modelos previos

Para comparar el desempeño del modelo KNN de regresión con los modelos desarrollados en entregas anteriores, se tomó como métrica principal el RMSE, ya que esta fue la medida reportada de forma consistente en todos los modelos. También se consideraron el MAE y el coeficiente de determinación R^2 cuando estuvieron disponibles. La comparación se realizó bajo las mismas condiciones generales de entrenamiento y prueba utilizadas en las entregas pasadas, con el objetivo de mantener consistencia en la evaluación.

Modelo	RMSE	MAE	R^2
Regresión lineal	4297.59	—	—
Árbol de regresión (depth = 10)	37.43	—	—
Naive Bayes	4347.22	664.50	-0.0145
KNN	2971.54	536.39	0.5260




Figura 2. Comparación del RMSE entre modelos de regresión

En el gráfico se observa que el árbol de regresión con profundidad 10 obtuvo el menor RMSE, por lo que fue el modelo con mejor desempeño. El modelo KNN presentó un error menor que la regresión lineal y que naive bayes, pero mayor que el árbol de regresión. Esto indica que KNN tuvo un rendimiento intermedio dentro de los modelos evaluados.

Los resultados muestran que el modelo con mejor desempeño fue el árbol de regresión con profundidad 10, ya que obtuvo el menor RMSE. En contraste, la regresión lineal y Naive Bayes presentaron los errores más altos, lo que indica una baja capacidad para predecir correctamente el precio de los alojamientos. El modelo KNN obtuvo un desempeño intermedio: logró superar a la regresión lineal y a Naive Bayes, pero todavía quedó lejos del rendimiento alcanzado por el árbol de regresión. En términos generales, esto sugiere que KNN logra capturar parte de la relación entre las variables predictoras y el precio, aunque sigue mostrando limitaciones importantes cuando existen valores altos o una gran dispersión en los datos.

Modelo de clasificación KNN para categorías de precio

Se implementó un modelo de clasificación utilizando el algoritmo K Nearest Neighbors (KNN) con el objetivo de clasificar los alojamientos en categorías de precio: barata, media y cara.

Para ello, la variable continua *price* fue transformada en una variable categórica mediante la división en tres intervalos, permitiendo agrupar los alojamientos según su rango de precio.

El modelo fue entrenado utilizando las variables numéricas del conjunto de datos previamente procesado. Asimismo, se aplicó normalización a las variables para asegurar que todas tuvieran la misma escala, lo cual es fundamental para el correcto funcionamiento del algoritmo KNN. Se utilizó un valor de $k = 5$ vecinos y se realizaron predicciones sobre el conjunto de prueba.

Evaluación del modelo en el conjunto de prueba

Para medir el rendimiento del modelo de clasificación KNN en el conjunto de prueba, se usaron métricas adecuadas para problemas de clasificación con muchas clases: precisión, precisión macro, recuperación macro y F1 macro. El modelo base obtuvo un accuracy de 0.6233, una precisión macro de 0.6181, un recall macro de 0.6238 y un F1 macro de 0.6186. Estos resultados indican que el modelo logró clasificar correctamente una proporción aceptable de los alojamientos dentro de las categorías barata, media y cara.

En términos generales, el desempeño del modelo puede considerarse moderado. El accuracy muestra que el modelo acertó en una parte significativa de los casos, mientras que las métricas macro permiten observar que el comportamiento entre las distintas clases fue relativamente equilibrado. Sin embargo, todavía existen errores de clasificación entre categorías cercanas, lo cual sugiere que hay cierto traslape entre los grupos de precio.

En conclusión, el modelo KNN base sí logró generar clasificaciones útiles en el conjunto de prueba, aunque todavía presentaba margen de mejora. Por esta razón, posteriormente se aplicaron análisis adicionales como la matriz de confusión, la validación cruzada y el tuneo de hiperparámetros para mejorar su desempeño.

Matriz de confusión del modelo de clasificación

Se utilizó una matriz de confusión para analizar el desempeño del modelo de clasificación KNN en cada una de las categorías de precio.

A partir de la matriz obtenida, se observa que el modelo presenta un desempeño adecuado en la clasificación de cada una de las categorías, aunque con ciertos errores entre clases. En la diagonal principal se encuentran los aciertos del modelo, donde se clasificaron correctamente 3645 observaciones como *barata*, 3070 como *media* y 2136 como *cara*.

Sin embargo, también se identifican errores importantes. Por ejemplo, varias observaciones de la clase *barata* se clasificaron como *media* (605 casos) y *cara* (835 casos).

De igual forma, la clase *media* tiene confusión tanto con *barata* como con *cara*, y la clase *cara* también tiene errores importantes cuando es catalogada de *barata* y *media*.

Estos resultados indican que el modelo tiene dificultades para distinguir completamente entre las categorías, especialmente en los límites entre clases. Esto se debe a la similitud de características entre los diferentes rangos de precio, lo que provoca solapamiento entre las clases.

En general, la matriz de confusión muestra que el modelo logra capturar patrones importantes en los datos, pero aún presenta errores de clasificación que afectan su precisión en algunas categorías.




Figura 3. Matriz de confusión para KNN con categorías de precio.

Análisis de sobreajuste del modelo KNN

Se analizó el comportamiento del modelo de KNN con el objetivo de determinar si presenta sobreajuste. Para ello, se consideró el desempeño del modelo en el conjunto de entrenamiento y en el conjunto de prueba.

En este caso, el modelo se evaluó utilizando un conjunto de prueba independiente, lo que permite medir su capacidad de generalización. Los resultados obtenidos muestran que el modelo mantiene un desempeño consistente en los datos de prueba, lo cual sugiere que no existe un sobreajuste significativo.

Sin embargo, debido a la naturaleza del algoritmo KNN, el modelo puede ser sensible al valor del parámetro k . Valores reducidos de k pueden provocar sobreajuste, ya que el modelo se ajusta demasiado a los datos de entrenamiento. En este caso, al utilizar $k = 5$, se logra un equilibrio adecuado entre la capacidad de ajuste y la generalización del modelo.

En resumen, el modelo no muestra pruebas claras de sobreajuste, aunque su rendimiento podría mejorarse con ajustes de hiperparámetros o técnicas adicionales de validación.

Validación cruzada del modelo KNN

Con el objetivo de evaluar la estabilidad del modelo de clasificación, se aplicó validación cruzada estratificada de 3 particiones al algoritmo KNN. Los resultados obtenidos fueron consistentes entre los distintos pliegues, ya que el accuracy promedio fue de 0.6179 con una desviación estándar de 0.0008, mientras que el F1 macro promedio fue de 0.6121 con una desviación estándar de 0.0010. Al comparar estos resultados con el accuracy del modelo base en el conjunto de prueba, que fue de 0.6233, se observa que el rendimiento es muy similar. Esto indica que el modelo presenta un comportamiento estable y que sus resultados no dependen únicamente de una sola partición de los datos. En general, la validación cruzada confirma que el modelo base tiene una capacidad de generalización aceptable, aunque todavía existe margen de mejora mediante ajuste de hiperparámetros.

Tabla 2. Resultados de la validación cruzada del modelo KNN

Métrica	Valor
Accuracy CV promedio	0.6179
Accuracy CV desviación estándar	0.0008
F1 macro CV promedio	0.6121
F1 macro CV desviación estándar	0.0010
Accuracy del modelo base en prueba	0.6233

Tuneo de hiperparámetros del modelo KNN

En KNN, algunos de los hiperparámetros que pueden ajustarse son el número de vecinos más cercanos, el tipo de ponderación de los vecinos y la métrica de distancia utilizada. En este caso, se realizó un proceso de tuneo tanto para el modelo de regresión como para el de clasificación, probando distintos valores de número de vecinos, pesos uniformes o por distancia, y distancia Manhattan o euclidiana. En ambos casos, la mejor combinación encontrada fue utilizar 9 vecinos, pesos por distancia y distancia Manhattan. Esto sugiere que el modelo logra un mejor desempeño cuando se da mayor importancia a los vecinos más cercanos y se utiliza una métrica de distancia más sensible a diferencias individuales entre variables.

Resultados del tuneo en el modelo de regresión

En el modelo de regresión, el tuneo sí permitió mejorar los resultados. El modelo base había obtenido un RMSE de 3552.73, un MAE de 631.95 y un R^2 de 0.3225. Después del ajuste de hiperparámetros, el modelo tuneado alcanzó un RMSE de 3231.90, un MAE de 576.76 y un R^2 de 0.4393. Esto indica que el modelo ajustado redujo el error de predicción y logró explicar una mayor proporción de la variabilidad del precio. Por lo tanto, el tuneo fue beneficioso para esta tarea, ya que permitió obtener un modelo más preciso que el utilizado inicialmente.

Tabla 3. Comparación entre el modelo KNN base y el modelo KNN tuneado para regresión

Modelo	RMSE	MAE	R ²
KNN base	3552.73	631.95	0.3225
KNN tuneado	3231.90	576.76	0.4393

Resultados del tuneo en el modelo de clasificación

En el modelo de clasificación también se observó una mejora después del tuneo. El modelo base obtuvo un accuracy de 0.6233, un precision macro de 0.6181, un recall macro de 0.6238 y un F1 macro de 0.6186. Por su parte, el modelo tuneado alcanzó un accuracy de 0.6519, un precision macro de 0.6509, un recall macro de 0.6523 y un F1 macro de 0.6515. Estos resultados muestran que el ajuste de hiperparámetros permitió mejorar el desempeño general del clasificador, especialmente en el balance entre precisión y recuperación de las tres categorías de precio. En términos generales, el tuneo ayudó a que el modelo clasificara de mejor manera los alojamientos dentro de cada grupo.

Tabla 4. Comparación entre el modelo KNN base y el modelo KNN tuneado para clasificación

Modelo	Accuracy	Precision macro	Recall macro	F1 macro
KNN base	0.6233	0.6181	0.6238	0.6186
KNN tuneado	0.6519	0.6509	0.6523	0.6515

Comparación final del modelo KNN con otros modelos de clasificación

Finalmente, se comparó el desempeño del modelo KNN tuneado con otros modelos de clasificación desarrollados en entregas anteriores: árbol de decisión, random forest y naive bayes. Para esta comparación se utilizaron las métricas accuracy, precision macro, recall macro, F1 macro y tiempo total de procesamiento. Los resultados muestran que el modelo con mejor desempeño fue Random Forest, ya que obtuvo un accuracy de 0.7281 y un F1 macro de 0.7265. En segundo lugar se ubicó el árbol de decisión, con un accuracy de 0.6698 y un F1 macro de 0.6681. El modelo KNN tuneado alcanzó un accuracy de 0.6519 y un F1 macro de 0.6515, por lo que quedó por debajo de Random Forest y del árbol de decisión, aunque superó claramente a Naive Bayes, que fue el modelo con peor rendimiento, con un accuracy de 0.3428 y un F1 macro de 0.3419.

En cuanto al tiempo de procesamiento, el modelo más lento fue KNN, con un tiempo total de 8.1959 segundos. Por el contrario, Naive Bayes fue el más rápido, con 0.0669 segundos, seguido por el árbol de decisión con 0.3694 segundos y Random Forest con 2.1101 segundos. Esto muestra que, aunque KNN logró mejorar después del tuneo y obtuvo resultados aceptables, su costo computacional fue mayor que el de los otros algoritmos evaluados. Por esta razón, KNN puede considerarse una alternativa útil, pero no fue el mejor modelo final dentro de los evaluados en esta consultoría.

Tabla 5. Comparación final entre modelos de clasificación

Modelo	Accuracy	Precision macro	Recall macro	F1 macro	Tiempo total (s)
Random Forest	0.7281	0.7262	0.7285	0.7265	2.1101
Árbol de decisión	0.6698	0.6688	0.6701	0.6681	0.3694
KNN	0.6519	0.6509	0.6523	0.6515	8.1959
Naive Bayes	0.3428	0.3431	0.3426	0.3419	0.0669




Figura 3. Comparación de F1 macro entre modelos de clasificación

En la Figura 3 se observa que Random Forest obtuvo el valor más alto de F1 macro, por lo que fue el modelo con mejor equilibrio entre precisión y recall. El árbol de decisión ocupó el segundo lugar, seguido por KNN. Naive Bayes presentó el resultado más bajo, lo que confirma que fue el modelo con menor capacidad de clasificación entre los evaluados.




Figura 4. Comparación del tiempo de procesamiento entre modelos de clasificación

En la Figura 4 se observa que KNN fue el modelo más lento en procesamiento, mientras que Naive Bayes fue el más rápido. Esto permite ver que no siempre el modelo con mejor tiempo es el que mejor clasifica, y que existe un balance entre desempeño predictivo y costo computacional al momento de elegir un algoritmo.

Conclusiones

A partir de los resultados obtenidos, se concluye que el algoritmo KNN fue capaz de generar modelos útiles tanto para regresión como para clasificación. En la tarea de regresión, el tuneo de hiperparámetros permitió mejorar el desempeño del modelo, reduciendo el error y aumentando la capacidad explicativa. Sin embargo, al compararlo con los modelos desarrollados anteriormente, el árbol de regresión siguió siendo el mejor para predecir el precio de los alojamientos.

En la tarea de clasificación, el modelo KNN también mejoró después del tuneo, alcanzando métricas superiores a las del modelo base. Aun así, al realizar la comparación final con otros algoritmos, Random Forest fue el modelo con mejor desempeño general, mientras que KNN fue el más lento en procesar. En conclusión, KNN representó una alternativa válida dentro del análisis, pero no fue el mejor modelo final de la consultoría.