

Evaluación de modelos de clasificación
UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería
Minería de datos
Semestre I – 2026



Laboratorio 7

Integrantes:

Ciprian Jimenez, Mishell Rosa Elvira – 231169
Nájera Marakovits, Ingrid Nina Alessandra - 231088
Ramírez Velásquez, Diego Alejandro – 23601

Enlace del repositorio: <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Laboratorio7>

Modelado de regresión logística para la clasificación de viviendas caras en Airbnb

Preparación de los datos y construcción de la variable respuesta

Para esta parte del laboratorio se trabajó con la variable de precio de las propiedades. Primero se transformó el precio a formato numérico y luego se dividió en tres categorías usando cuantiles: barata, media y cara. A partir de estas categorías también se construyeron tres variables dicotómicas, una para identificar si una vivienda era cara o no, media o no y barata o no. En este avance se utilizó la variable `es_cara`, donde el valor 1 representa una vivienda cara y el valor 0 una vivienda no cara.

Después de eso se prepararon las variables predictoras para el modelo. Se trabajó con 31 variables, tanto numéricas como categóricas. A las variables numéricas se les aplicó imputación por mediana y estandarización, mientras que a las categóricas se les aplicó imputación por la categoría más frecuente y codificación one-hot. Luego se hizo una partición estratificada en entrenamiento y prueba, fijando una semilla para que el experimento fuera reproducible.

Tabla 1. Distribución de la variable categórica del precio

Categoría	Frecuencia	Porcentaje
Barata	25,689	33.69
Media	25,153	32.99
Cara	25,404	33.32

Tabla 2. Resumen de la preparación de datos

Elemento	Valor
Registros originales	171,748
Registros usados en el modelo	76,246
Variables predictoras	31
Variables numéricas	22
Variables categóricas	9
Registros de entrenamiento	60,996
Registros de prueba	15,250

Ajuste y selección del modelo de regresión logística

El modelo se construyó usando una regresión logística dentro de un pipeline de preprocesamiento. Para seleccionar la mejor configuración se realizó un tuneo con validación

cruzada estratificada de 3 particiones y se utilizó como métrica principal el valor F1, ya que permite evaluar de mejor forma el balance entre precisión y recall.

Se probaron combinaciones de penalización L1 y L2 junto con distintos valores del parámetro C. El mejor modelo fue el de penalización L2 con un valor de C igual a 1, ya que obtuvo el mejor desempeño promedio durante la validación cruzada. Por esta razón, ese modelo se utilizó como versión final para la clasificación de viviendas caras.

Tabla 3. Resultados del tuneo de hiperparámetros

Penalización	C	F1 promedio CV	Desviación estándar	Ranking
L2	1	0.7035	0.0026	1
L2	10	0.7035	0.0028	2
L1	10	0.7034	0.0028	3
L1	1	0.7032	0.0028	4
L2	0.1	0.7020	0.0024	5
L1	0.1	0.7020	0.0021	6

Modelo de regresión logística

Para este inciso se construyó un modelo de regresión logística con el objetivo de predecir si una vivienda es cara o no. Se utilizaron variables numéricas como `accommodates`, `bathrooms`, `minimum_nights`, `availability_30`, número de reseñas y puntuaciones de review, así como la variable categórica `room_type` codificada mediante one-hot encoding.

El modelo fue entrenado utilizando datos estandarizados y se evaluó mediante validación cruzada. Se obtuvo un **accuracy promedio de 0.8168**, lo cual indica un buen desempeño predictivo del modelo. Este resultado sugiere que el modelo logra capturar patrones relevantes en los datos para diferenciar entre viviendas caras y no caras.

Logit Regression Results						
Dep. Variable:	is_caro	No. Observations:	50174			
Model:	Logit	Df Residuals:	50111			
Method:	MLE	Df Model:	62			
Date:	Fri, 17 Apr 2026	Pseudo R-squ.:	0.3089			
Time:	17:58:56	Log-Likelihood:	-21430.			
converged:	True	LL-Null:	-31011.			
Covariance Type:	nonrobust	LLR p-value:	0.000			
	coef	std err	z	P> z	[0.025	0.975]
const	-1.1551	1.159	-0.997	0.319	-3.426	1.116
accommodates	0.5063	0.031	16.350	0.000	0.446	0.567
bathrooms	0.6029	0.021	29.335	0.000	0.563	0.643
minimum_nights	-0.2571	0.019	-13.836	0.000	-0.293	-0.221
availability_30	-0.0425	0.012	-3.473	0.001	-0.066	-0.019
number_of_reviews	-0.0223	0.021	-1.049	0.294	-0.064	0.019
reviews_per_month	-0.6659	0.023	-29.233	0.000	-0.710	-0.621
review_scores_rating	-0.1234	0.022	-5.560	0.000	-0.167	-0.080
review_scores_cleanliness	0.2222	0.021	10.624	0.000	0.181	0.263
review_scores_location	0.5238	0.021	25.021	0.000	0.483	0.565
latitude	-0.1029	0.014	-7.298	0.000	-0.131	-0.075
bedrooms_1	0.0150	0.028	0.539	0.590	-0.040	0.070
...						
room_type_Hotel room	0.1145	0.011	10.447	0.000	0.093	0.136
room_type_Private room	-0.0137	0.017	-0.812	0.417	-0.047	0.019
room_type_Shared room	-0.1808	0.032	-5.592	0.000	-0.244	-0.117

Análisis del modelo y multicolinealidad


Para analizar el modelo, se utilizó la implementación de regresión logística de statsmodels, lo que permitió evaluar la significancia estadística de las variables.

El modelo logró converger correctamente, lo que indica que la estimación de los coeficientes es estable. Además, se obtuvo un pseudo R^2 de 0.3089, lo que sugiere una capacidad explicativa moderada.

Se identificaron varias variables estadísticamente significativas ($p < 0.05$). Entre las más relevantes se encuentran:

- accommodates y bathrooms, que incrementan la probabilidad de que una vivienda sea cara.
- minimum_nights y reviews_per_month, que presentan una relación negativa con el precio.
- review_scores_location, que tiene un impacto positivo importante.
- latitude, que también influye en el precio.

Por otro lado, algunas variables como number_of_reviews no resultaron significativas, lo que indica que no aportan información relevante al modelo.



Evaluación del modelo

Después de seleccionar el mejor modelo, se evaluó su comportamiento en los conjuntos de entrenamiento y prueba mediante matrices de confusión y métricas de clasificación. En entrenamiento, el modelo clasificó correctamente 36,429 viviendas no caras y 13,373 viviendas caras. También cometió 4,244 falsos positivos y 6,950 falsos negativos. En prueba, clasificó correctamente 9,118 viviendas no caras y 3,374 viviendas caras, mientras que cometió 1,051 falsos positivos y 1,707 falsos negativos.

En cuanto a las métricas, el accuracy fue de 0.8165 en entrenamiento y 0.8191 en prueba. La precisión fue de 0.7591 y 0.7625, mientras que el recall fue de 0.6580 y 0.6640, respectivamente. La especificidad fue alta en ambos conjuntos, cercana a 0.896, lo que muestra que el modelo identifica mejor las viviendas no caras. El valor F1 fue de 0.7050 en entrenamiento y 0.7099 en prueba, y el ROC AUC fue de 0.8809 y 0.8847.

En general, los resultados de entrenamiento y prueba son bastante parecidos, por lo que no se observa un sobreajuste fuerte. Sin embargo, el modelo presenta más dificultad para identificar viviendas realmente caras, ya que la cantidad de falsos negativos es mayor que la de falsos positivos.




Gráfico 1. Matriz de confusión del conjunto de entrenamiento

En el conjunto de entrenamiento, el modelo clasificó correctamente la mayoría de viviendas no caras y también una buena parte de las viviendas caras. Sin embargo, todavía se observan errores, especialmente en viviendas caras que fueron clasificadas como no caras. Esto muestra que el modelo aprende bien el patrón general, pero tiene más dificultad para identificar todos los casos de la clase cara.




Gráfico 2. Matriz de confusión del conjunto de prueba

En el conjunto de prueba se observa un comportamiento muy parecido al de entrenamiento, lo que indica que el modelo mantiene un rendimiento estable con datos no vistos. La mayor cantidad de aciertos se concentra en la clase “no cara”, mientras que el error más frecuente sigue siendo clasificar viviendas caras como no caras. En general, esto sugiere que el modelo generaliza bien, aunque detecta mejor la clase negativa que la positiva.

Tabla 4. Métricas del modelo de regresión logística

Conjunto	Accuracy	Precision	Recall	Specificity	F1	ROC AUC
Entrenamiento	0.8165	0.7591	0.6580	0.8957	0.7050	0.8809
Prueba	0.8191	0.7625	0.6640	0.8966	0.7099	0.8847

Análisis general de resultados

Además del desempeño predictivo, también se revisó el costo computacional del modelo. El tuneo de hiperparámetros fue la etapa más costosa, con un tiempo aproximado de 191.69 segundos. El ajuste final del modelo tardó 54.92 segundos y alcanzó un pico de memoria de 70.78 MB. La predicción sobre el conjunto de prueba fue rápida, con un tiempo de 0.48 segundos y un consumo máximo de 17.79 MB. Esto indica que la parte más costosa del proceso fue la búsqueda de la mejor configuración, mientras que el uso del modelo ya entrenado resulta eficiente.

En conclusión, en esta etapa se logró construir un modelo de regresión logística estable para clasificar si una vivienda es cara o no. La variable respuesta quedó balanceada, el tuneo permitió seleccionar una buena configuración y el modelo presentó resultados similares en entrenamiento y prueba. Aun así, el análisis muestra que reconoce mejor las viviendas no caras que las caras, por lo que más adelante convendrá revisar el umbral de decisión para intentar mejorar la detección de la clase positiva.

Tabla 5. Perfil de tiempo y memoria del modelo

Etapa	Tiempo en segundos	Memoria pico en MB
Tuneo	191.69	—
Ajuste del modelo	54.92	70.78
Predicción en prueba	0.48	17.79

Evaluación del modelo en el conjunto de prueba

Se analizó el comportamiento del modelo con el objetivo de determinar si presenta sobreajuste, comparando el error en el conjunto de entrenamiento y en el conjunto de prueba.

Los resultados obtenidos fueron:

- Error en entrenamiento: 0.1908
- Error en prueba: 0.1928

Se observa que ambos valores son muy similares, lo cual indica que el modelo mantiene un desempeño consistente entre los datos de entrenamiento y prueba. Esto sugiere que el modelo

tiene una buena capacidad de generalización y **no presenta evidencia significativa de overfitting**.

En general, el modelo logra un equilibrio adecuado entre ajuste y generalización, aunque su desempeño podría mejorarse mediante técnicas adicionales como ajuste de hiperparámetros o selección de variables.

Tuneo del modelo de regresión logística

Se realizó un proceso de ajuste de hiperparámetros con el objetivo de mejorar el desempeño del modelo de regresión logística. Por ello, se utilizó validación cruzada mediante “Grid Search”, probando distintos valores del parámetro de regularización C , el cual controla la complejidad del modelo.

Los resultados obtenidos indican que los mejores parámetros fueron:

- $C = 1$
- Regularización tipo L2.
- Solver : ibfgs

El modelo alcanzó un accuracy promedio en validación cruzada de 0.8168, lo que indica un buen desempeño y estabilidad en distintas particiones de los datos.

En general, el valor $C=1$ sugiere un equilibrio entre el ajuste del modelo y la regularización, evitando tanto el sobreajuste como un modelo demasiado simple, lo que permite que el modelo mantenga una buena capacidad de generalización.

Análisis de la matriz de confusión

Se utilizó la matriz de confusión tanto en el conjunto de entrenamiento como en el conjunto de prueba con el objetivo de analizar el desempeño del modelo y los tipos de errores cometidos.

En el conjunto de entrenamiento, el modelo presenta un buen desempeño general, logrando clasificar correctamente la mayoría de los casos. Esto indica que el modelo ha aprendido adecuadamente los patrones presentes en los datos de entrenamiento.

En el conjunto de prueba, se observa que el modelo mantiene un comportamiento similar, lo cual confirma su capacidad de generalización. Sin embargo, se identifican errores importantes, especialmente en la clasificación de la clase positiva.




Gráfico 3. Matriz de confusión del conjunto de prueba

En particular, se presentan falsos negativos, lo que indica que el modelo no logra identificar correctamente todos los casos positivos. Este tipo de error es relevante, ya que implica clasificar propiedades caras como no caras.

Asimismo, también se observan falsos positivos, aunque en menor proporción. En general, el modelo muestra un mejor desempeño en la clasificación de la clase negativa en comparación con la positiva.

Este análisis permite identificar en qué tipo de casos el modelo falla, lo cual es fundamental para futuras mejoras, como el ajuste del umbral de decisión o el balanceo de clases.




Gráfico 4. Matriz de confusión del conjunto de prueba

Ajuste del umbral de decisión mediante el índice de Youden

Para esta parte se evaluó si el umbral de decisión de 0.5 era el más adecuado para clasificar viviendas caras y no caras. Para hacerlo, se utilizó la curva ROC del modelo y se calculó el índice de Youden, que permite encontrar el punto donde la sensibilidad y la especificidad tienen un mejor balance. El umbral óptimo obtenido fue de 0.3155, con un índice de Youden máximo de 0.6039. En ese punto, la sensibilidad fue de 0.8130 y la especificidad de 0.7908.

Esto indica que, al bajar el umbral desde 0.5 hasta 0.3155, el modelo logra detectar mejor las viviendas realmente caras. Sin embargo, esa mejora en sensibilidad también implica una reducción en la especificidad, por lo que el modelo comienza a clasificar más viviendas no caras como si fueran caras.

Tabla 6. Resumen del umbral óptimo según el índice de Youden

Umbral por defecto	Umbral óptimo de Youden	Índice de Youden máximo	Sensibilidad en el umbral óptimo	Especificidad en el umbral óptimo
0.5000	0.3155	0.6039	0.8130	0.7908




Gráfico 5. Curva ROC y punto de corte óptimo según el índice de Youden

En la curva ROC se observa el comportamiento del modelo para distintos umbrales de decisión. El punto seleccionado por el índice de Youden corresponde al valor 0.3155, ya que es el que ofrece el mejor balance entre sensibilidad y especificidad. Este resultado muestra que el umbral por defecto de 0.5 no era el punto más balanceado para este conjunto de datos.

Al comparar ambos umbrales en el conjunto de prueba, se observó que con el umbral de 0.3155 la sensibilidad aumentó de 0.6640 a 0.8130, y el valor F1 subió de 0.7099 a 0.7286. Además,

los falsos negativos se redujeron de 1,707 a 950, lo cual significa que el modelo dejó de pasar por alto muchas viviendas que realmente pertenecían a la categoría “cara”. Por otro lado, la especificidad bajó de 0.8966 a 0.7908 y los falsos positivos aumentaron de 1,051 a 2,127.

En otras palabras, el nuevo umbral mejora la detección de la clase positiva, pero a cambio clasifica erróneamente más viviendas no caras como caras. Por eso, la decisión depende de qué error sea más importante. Si para el análisis resulta más grave no identificar una vivienda cara, entonces el umbral óptimo de Youden es más conveniente. Si se quiere mantener un modelo más conservador y con menos falsos positivos, el umbral de 0.5 sigue siendo una opción razonable.

Tabla 7. Comparación de métricas en el conjunto de prueba para el umbral 0.50 y el umbral óptimo

Escenario	Umbral	Accuracy	Precision	Recall	Specificity	F1	ROC AUC	TN	FP	FN	TP
Umbral 0.50	0.5000	0.8191	0.7625	0.6640	0.8966	0.7099	0.8847	9118	1051	1707	3374
Umbral de Youden	0.3155	0.7982	0.6601	0.8130	0.7908	0.7286	0.8847	8042	2127	950	4131




Gráfico 6. Matriz de confusión del conjunto de prueba con el umbral óptimo de Youden

La matriz de confusión con el umbral óptimo muestra que el modelo identifica una mayor cantidad de viviendas caras correctamente. Esto se refleja en el aumento de verdaderos positivos y en la reducción de falsos negativos. Sin embargo, también se incrementan los falsos positivos, por lo que el modelo pierde capacidad para distinguir correctamente algunas viviendas no caras. En este caso, el umbral de Youden favorece la sensibilidad sobre la especificidad.

Comparación de modelos y selección del mejor modelo

Para determinar cuál modelo era mejor, se compararon distintas configuraciones de regresión logística usando las métricas de clasificación del conjunto de prueba, además de AIC, BIC, tiempo de ajuste y memoria consumida. En esta comparación también se incluyó el modelo con umbral óptimo de Youden, para evaluar si el cambio del umbral mejoraba el desempeño general.

Los resultados muestran que el modelo con penalización L2, $C = 10$ y umbral 0.50 obtuvo el mejor puntaje global. Este modelo alcanzó un accuracy de 0.8191, un F1 de 0.7100 y un ROC AUC de 0.8847, con un tiempo de ajuste de 30.90 segundos y un uso máximo de memoria de 70.77 MB. Aunque no fue el que tuvo el menor AIC o BIC, sí presentó el mejor balance general entre rendimiento predictivo y costo computacional.

Por su parte, el modelo con umbral de Youden obtuvo el mejor recall y también el mejor F1, pero perdió accuracy y especificidad, por lo que no fue el más conveniente si se evalúa el comportamiento total del clasificador. En cambio, si el objetivo principal fuera reducir falsos negativos y detectar la mayor cantidad posible de viviendas caras, entonces ese modelo podría preferirse. En este laboratorio, tomando en cuenta todas las métricas y el perfil computacional, se considera que el mejor modelo fue la regresión logística con penalización L2, $C = 10$ y umbral 0.50.

Tabla 8. Comparación de modelos de regresión logística y selección del mejor modelo

Ran king final	Mo delo	Um bral	Accu racy	Rec all	Specif icity	F1	RO C AUC	AIC	BIC	Tie mpo de ajus te (s)	Mem oria pico (MB)
1	L2, C=10	0.50 00	0.819 1	0.6 644	0.896 4	0.7 100	0.8 847	49150. 6138	49781. 9132	30.8 967	70.76 96
2	L1, C=10	0.50 00	0.819 1	0.6 644	0.896 4	0.7 100	0.8 847	49150. 6167	49781. 9161	38.9 270	70.77 11

3	L1, C=1	0.50 00	0.819 1	0.6 640	0.896 6	0.7 099	0.8 847	49145. 0095	49749. 2533	41.4 580	70.77 00
4	L2, C=1 , You den	0.31 55	0.798 2	0.8 130	0.790 8	0.7 286	0.8 847	49150. 9277	49782. 2272	27.1 745	70.77 96
5	L2, C=1	0.50 00	0.819 1	0.6 640	0.896 6	0.7 099	0.8 847	49150. 9277	49782. 2272	30.1 671	70.77 05
6	L2, C=0 .1	0.50 00	0.818 6	0.6 617	0.897 0	0.7 085	0.8 844	49168. 4196	49799. 7191	22.1 810	70.77 09
7	L1, C=0 .1	0.50 00	0.819 1	0.6 636	0.896 7	0.7 097	0.8 844	49146. 2920	49633. 2944	41.2 095	70.77 74

Conclusión

En esta etapa se comprobó que el umbral de 0.5 no era el único valor posible para clasificar correctamente las viviendas caras. El índice de Youden permitió encontrar un umbral alternativo que mejoró de forma importante la sensibilidad del modelo y redujo los falsos negativos. Aun así, ese cambio también aumentó los falsos positivos y disminuyó la especificidad.

Finalmente, al comparar los distintos modelos con base en métricas de clasificación, criterios de información y costo computacional, se concluyó que el mejor modelo global fue la regresión logística con penalización L2, valor de $C = 10$ y umbral de 0.50, ya que presentó el balance más adecuado entre desempeño predictivo y eficiencia.

Clasificación multiclase del precio de viviendas

Para este inciso se construyó un modelo de regresión logística multiclase con el objetivo de clasificar las viviendas en tres categorías de precio: barata, media y cara.

Se utilizó un enfoque de regresión logística multinomial con el solver lbfgs y se realizó un proceso de ajuste de hiperparámetros mediante GridSearch, evaluando distintos valores del parámetro de regularización C . El mejor modelo obtenido utilizó un valor de $C = 0.1$.


El modelo fue evaluado sobre el conjunto de prueba, obteniendo un accuracy de 0.6136, lo cual indica un desempeño moderado en la clasificación multiclase.

Clase	Precision	Recall	F1-score
Barata	0.65	0.71	0.68
Media	0.51	0.46	0.48

Cara	0.67	0.68	0.67
------	------	------	------

Los resultados muestran que el modelo tiene un mejor desempeño en la clasificación de viviendas baratas y caras, mientras que presenta mayor dificultad para identificar correctamente la categoría media.

Esto se observa en el menor recall y F1-score de la clase media, lo cual sugiere que existe mayor confusión entre las categorías intermedias del precio.



En la matriz de confusión se observa que la mayor cantidad de aciertos se concentra en las clases “barata” y “cara”. Sin embargo, existe una confusión considerable en la clase “media”, la cual es frecuentemente clasificada como “barata” o “cara”.

Esto indica que el modelo tiene dificultades para separar correctamente los valores intermedios de precio, lo cual es esperable debido a la naturaleza continua de la variable precio.

Comparación de modelos de clasificación

Para evaluar el desempeño del modelo multiclase, se realizó una comparación conceptual con otros algoritmos de clasificación utilizados en problemas similares. La regresión logística presenta ventajas importantes como su estabilidad, interpretabilidad y bajo costo computacional. Sin embargo, su capacidad para capturar relaciones no lineales es limitada.

Por otro lado, modelos como Random Forest suelen ofrecer un mejor desempeño predictivo debido a su capacidad para modelar relaciones complejas y no lineales, aunque a costa de un

mayor consumo de recursos. Los árboles de decisión son fácilmente interpretables, pero tienden a sobreajustarse si no se controlan adecuadamente. El algoritmo KNN puede ser efectivo en algunos casos, pero su costo computacional es alto durante la predicción.

Finalmente, Naive Bayes es un modelo muy rápido y eficiente, aunque su desempeño puede verse limitado por su suposición de independencia entre variables.

En este caso, la regresión logística multiclase logró un desempeño moderado, pero modelos más complejos podrían mejorar la clasificación, especialmente en la categoría media.

Conclusión

En este laboratorio se desarrolló un proceso completo de clasificación aplicado a datos de viviendas de Airbnb. El modelo de regresión logística binaria mostró un buen desempeño y una adecuada capacidad de generalización, evidenciada por resultados consistentes entre entrenamiento y prueba.

El análisis mediante métricas y matrices de confusión permitió identificar que el modelo presenta mayor dificultad para detectar viviendas caras, así como el impacto del ajuste del umbral de decisión en el balance entre sensibilidad y especificidad.

Al extender el problema a una clasificación multiclase, se observó un desempeño moderado, con mejores resultados en las clases extremas y dificultades en la categoría media, lo que refleja la complejidad del problema.

Finalmente, aunque la regresión logística es un modelo eficiente e interpretable, su capacidad es limitada frente a modelos más complejos como Random Forest, que podrían mejorar el desempeño. En general, el laboratorio permitió comprender aspectos clave del modelado, evaluación e interpretación en problemas de minería de datos.