

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Minería de datos

Semestre I – 2026



Laboratorio 9

Integrantes:

Ciprian Jimenez, Mishell Rosa Elvira – 231169

Nájera Marakovits, Ingrid Nina Alessandra - 231088

Ramírez Velásquez, Diego Alejandro – 23601

Link del repositorio: <https://github.com/Ninaswiftie09/Mineria-de-Datos/tree/Laboratorio9>

Introducción

En este avance se trabajó con el conjunto de datos de propiedades de Airbnb utilizado en las entregas anteriores. El objetivo principal fue preparar los datos para construir modelos de Redes Neuronales Artificiales orientados a clasificación. Para esto, se tomó como variable respuesta una categoría creada a partir del precio de las propiedades, dividiéndolas en tres grupos: baratas, medias y caras.

Además, se entrenaron dos modelos de redes neuronales con diferentes estructuras internas y funciones de activación. Luego, ambos modelos se usaron para predecir la categoría de precio de las propiedades del conjunto de prueba.

Preparación de los conjuntos de entrenamiento y prueba

Para mantener una comparación justa con los modelos desarrollados anteriormente, se separó la base de datos en un conjunto de entrenamiento y un conjunto de prueba. El conjunto de entrenamiento se utilizó para que los modelos aprendieran los patrones de los datos, mientras que el conjunto de prueba se reservó para evaluar qué tan bien podían clasificar propiedades nuevas.

Después de limpiar y preparar las variables, el conjunto de entrenamiento quedó formado por 53,372 registros y 48 variables predictoras. Por otro lado, el conjunto de prueba quedó formado por 22,874 registros y las mismas 48 variables predictoras.

Esta división permite evaluar los modelos con datos que no fueron usados durante el entrenamiento, lo cual es importante para saber si el modelo realmente aprendió patrones generales y no solo memorizó los datos.

Creación de la variable respuesta

La variable respuesta utilizada para esta parte del laboratorio fue una categoría basada en el precio de las propiedades. Primero, el precio original se limpió porque venía en formato de texto, con símbolos como el signo de dólar y comas. Luego, el precio se convirtió a formato numérico para poder trabajar con él.

Después de esto, los precios se dividieron en tres categorías:

Categoría	Descripción
barata	Propiedades con precios bajos
media	Propiedades con precios intermedios
cara	Propiedades con precios altos

Tabla I

La distribución de la variable respuesta en los conjuntos de entrenamiento y prueba fue la siguiente:

Categoría	Entrenamiento	Prueba
barata	17,982	7,707
media	17,607	7,546
cara	17,783	7,621

Tabla II

Como se puede observar, las tres categorías quedaron bastante balanceadas. Esto es positivo porque evita que el modelo aprenda a favorecer solamente una categoría. Si una categoría tuviera muchos más datos que las demás, el modelo podría obtener buenos resultados aparentes solo por predecir siempre la clase mayoritaria.

Modelos de redes neuronales para clasificación

Se entrenaron dos modelos de Redes Neuronales Artificiales para clasificar las propiedades según su categoría de precio. Ambos modelos usan la misma variable respuesta, pero tienen topologías y funciones de activación diferentes.

El primer modelo tiene una estructura más sencilla. Está compuesto por dos capas ocultas, una de 64 neuronas y otra de 32 neuronas. En ambas capas se utilizó la función de activación ReLU. Esta función es común en redes neuronales porque ayuda a que el modelo aprenda relaciones no lineales de forma eficiente.

El segundo modelo tiene una estructura más profunda. Está compuesto por tres capas ocultas, con 128, 64 y 32 neuronas respectivamente. En este caso, se utilizó la función de activación tanh. Esta función transforma los valores a un rango entre -1 y 1, lo cual puede ayudar en algunos problemas, aunque también puede hacer que el entrenamiento sea más lento.

La comparación general de las arquitecturas utilizadas fue la siguiente:

Modelo	Capas ocultas	Función de activación	Tiempo de entrenamiento
RNA 1	64, 32	ReLU	43.55 segundos
RNA 2	128, 64, 32	tanh	99.59 segundos

El segundo modelo tardó más en entrenarse porque tiene una arquitectura más grande y más capas. Esto significa que tiene más parámetros internos que ajustar durante el entrenamiento. Sin embargo, un modelo más complejo no siempre garantiza resultados mucho mejores.

Predicción de la categoría de precio

Después del entrenamiento, ambos modelos se utilizaron para predecir la categoría de precio de las propiedades del conjunto de prueba. Las predicciones se compararon con la categoría real para calcular la exactitud general de cada modelo.

Los resultados obtenidos fueron los siguientes:

Modelo	Exactitud
RNA 1	0.7425
RNA 2	0.7468

El modelo RNA 2 obtuvo una exactitud ligeramente mayor que el modelo RNA 1. Sin embargo, la diferencia entre ambos modelos fue pequeña. Esto significa que el segundo modelo clasificó un poco mejor, pero también necesitó más tiempo de procesamiento.

En términos prácticos, el modelo RNA 1 puede considerarse una alternativa más eficiente porque logró un resultado muy parecido al del segundo modelo, pero con un tiempo de entrenamiento bastante menor. Por otro lado, el modelo RNA 2 puede ser útil si se busca obtener la mayor exactitud posible, aunque el aumento en desempeño no fue tan grande.

Matrices de confusión de los modelos de clasificación

Para evaluar con mayor detalle el desempeño de los modelos de redes neuronales, se construyeron las matrices de confusión correspondientes a cada uno. Estas matrices permiten observar no solo la exactitud general, sino también en qué casos específicos los modelos aciertan o se equivocan.

Para el modelo RNA 1, la matriz de confusión fue la siguiente:




Figura 1. matriz de confusión modelo RNA 1




Figura 2. matriz de confusión modelo RNA 2

A partir de estos resultados, se pueden hacer varias observaciones importantes:

- Ambos modelos tienen un buen desempeño en general, ya que la mayor cantidad de predicciones se encuentra en la diagonal principal, lo que indica que clasifican correctamente una gran parte de las propiedades.
- En ambas redes neuronales, la categoría **barata** es la que mejor se clasifica, con una alta cantidad de aciertos y relativamente pocos errores.
- La categoría **cara** también presenta un buen nivel de clasificación, aunque en ambos modelos existe una confusión considerable con la categoría **media**.
- La categoría **media** es la más difícil de clasificar correctamente. Esto se observa porque tiene una mayor cantidad de errores distribuidos hacia las categorías **barata** y **cara**.

- En ambos modelos, el error más común ocurre entre las categorías **media** y **cara**, lo cual sugiere que los límites entre estos dos grupos no están claramente definidos en los datos.

Comparando ambos modelos, se observa que:

- El modelo RNA 2 mejora ligeramente la clasificación de la categoría **barata**, reduciendo algunos errores en comparación con el modelo RNA 1.
- Sin embargo, el modelo RNA 2 incrementa algunos errores en la clasificación de la categoría **cara**, especialmente al confundirla con **media**.

En general, ambos modelos presentan patrones de error similares, lo que indica que las dificultades en la clasificación están más relacionadas con la estructura de los datos que con el modelo específico utilizado.

Comparación de los modelos de clasificación

Para evaluar el desempeño de los modelos de redes neuronales, se realizó una comparación considerando tres aspectos principales: la efectividad, el tiempo de procesamiento y el tipo de errores cometidos por cada modelo.

Efectividad de los modelos

La efectividad de los modelos se evaluó utilizando la exactitud obtenida sobre el conjunto de prueba. Los resultados fueron los siguientes:

- RNA 1: 0.7425
- RNA 2: 0.7468

El modelo RNA 2 obtuvo una exactitud ligeramente superior al modelo RNA 1. Sin embargo, la diferencia entre ambos modelos es pequeña, lo que indica que ambos tienen un desempeño similar en términos de clasificación general.

Tiempo de procesamiento

En cuanto al tiempo de entrenamiento, se observaron las siguientes diferencias:

- RNA 1: 43.55 segundos
- RNA 2: 99.59 segundos

El modelo RNA 2 requiere más del doble de tiempo de entrenamiento que el modelo RNA 1. Esto se debe a que tiene una arquitectura más compleja, con más capas y neuronas, lo que incrementa la cantidad de parámetros que deben ajustarse durante el proceso de aprendizaje.

Análisis de errores

El análisis de las matrices de confusión permite identificar en qué casos los modelos cometen más errores.

En ambos modelos, la mayor cantidad de errores ocurre entre las categorías **media** y **cara**, lo que indica que estas clases son más difíciles de separar. Esto puede deberse a que los precios intermedios y altos tienen características similares en el conjunto de datos.

Asimismo, la categoría **media** es la más problemática, ya que presenta errores tanto hacia **barata** como hacia **cara**. Esto sugiere que esta categoría se encuentra en una zona de transición entre las otras dos.

Por otro lado, la categoría **barata** es la que mejor se clasifica en ambos modelos, con una alta cantidad de aciertos y pocos errores. Esto indica que las propiedades más económicas tienen características más diferenciadas dentro del conjunto de datos.

Al comparar ambos modelos, se observa que:

- RNA 2 mejora ligeramente la clasificación de propiedades baratas.
- RNA 1 presenta un comportamiento más equilibrado en la clasificación de las demás categorías.
- Ambos modelos comparten patrones de error similares, lo que sugiere que las limitaciones provienen principalmente de los datos y no del modelo.

Conclusión de la comparación

En general, el modelo RNA 2 presenta un desempeño ligeramente mejor en términos de exactitud. Sin embargo, este incremento es pequeño en comparación con el aumento significativo en el tiempo de entrenamiento.

Por esta razón, el modelo RNA 1 puede considerarse una opción más eficiente, ya que logra un rendimiento muy similar con un menor costo computacional. No obstante, si se busca maximizar la exactitud sin considerar el tiempo de procesamiento, el modelo RNA 2 sería la mejor opción.

Análisis de sobreajuste de los modelos

Para evaluar si los modelos presentan sobreajuste, se comparó la exactitud obtenida en el conjunto de entrenamiento con la obtenida en el conjunto de prueba.

Los resultados fueron los siguientes:

- RNA 1:
 - Entrenamiento: 0.7843
 - Prueba: 0.7425
 -

- RNA 2:
 - Entrenamiento: 0.7938
 - Prueba: 0.7468

Al analizar estos valores, se observa que en ambos modelos la exactitud en entrenamiento es ligeramente mayor que en el conjunto de prueba. Sin embargo, la diferencia entre ambos valores es relativamente pequeña, aproximadamente entre 4% y 5%.

Esto indica que los modelos presentan una leve tendencia al sobreajuste, lo cual es esperado en modelos de redes neuronales, pero no es lo suficientemente significativo como para afectar gravemente su capacidad de generalización.

Además, el uso de técnicas como el **early stopping** contribuye a controlar este comportamiento, evitando que los modelos continúen entrenando una vez que dejan de mejorar en datos no vistos.

En general, se concluye que ambos modelos logran un buen equilibrio entre aprendizaje y generalización, por lo que no presentan problemas graves de sobreajuste.

Ajustes de parámetros del modelo de clasificación

Para esta etapa, se seleccionó el modelo RNA 2 como base para realizar el ajuste de parámetros, ya que fue el que obtuvo la mayor exactitud en el conjunto de prueba.

Se realizó un ajuste en algunos hiperparámetros del modelo, incluyendo el incremento en el número de iteraciones máximas, así como modificaciones en la tasa de aprendizaje y el parámetro de regularización. Estos cambios buscan mejorar la capacidad de aprendizaje del modelo sin generar sobreajuste.

Después de realizar el entrenamiento del modelo ajustado, se obtuvo una nueva exactitud de:

- RNA 2 tuneado: **0.7473**

Al comparar este resultado con el modelo original (0.7468), se observa que la mejora es muy pequeña. Esto indica que el modelo original ya se encontraba cerca de su mejor desempeño con la configuración inicial.

Además, el uso de técnicas como el **early stopping** contribuye a evitar el sobreentrenamiento, lo que limita mejoras adicionales sin afectar la capacidad de generalización.

En general, se concluye que el modelo puede ajustarse ligeramente, pero no presenta mejoras significativas. Esto sugiere que la calidad del modelo está más influenciada por las características de los datos que por pequeños cambios en los hiperparámetros.

