

Evaluación de modelos de clasificación
UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería
Minería de datos
Semestre I – 2026



Laboratorio 5

Integrantes:

Ciprian Jimenez, Mishell Rosa Elvira – 231169
Nájera Marakovits, Ingrid Nina Alessandra - 231088
Ramírez Velásquez, Diego Alejandro – 23601

Modelo de regresión con Naive Bayes para la predicción del precio de alojamientos

Preparación de los datos

Para esta parte se utilizó el conjunto de datos listings.RData, el cual contiene información de alojamientos disponibles en Airbnb. Inicialmente, el conjunto contaba con 171,748 registros y 80 variables. Luego de limpiar la variable respuesta price, convertir algunos campos a formato numérico y seleccionar únicamente las variables más útiles para el modelo, se trabajó con 76,246 registros y 46 variables.

Posteriormente, los datos se dividieron en conjunto de entrenamiento y prueba, usando una partición de 80% para entrenamiento y 20% para prueba. De esta forma, el modelo se entrenó con 60,996 observaciones y se evaluó con 15,250 observaciones. Después del preprocesamiento y la codificación de variables categóricas, los datos quedaron representados en 119 variables de entrada.

Tabla 1. Resumen del conjunto de datos utilizado

Elemento	Valor
Registros iniciales	171,748
Variables iniciales	80
Registros usados después de limpieza	76,246
Variables usadas para el modelo	46
Observaciones de entrenamiento	60,996
Observaciones de prueba	15,250
Variables finales tras preprocesamiento	119

La Tabla 1 resume el proceso de preparación de los datos. Puede observarse que fue necesario reducir el número de variables y trabajar únicamente con las más relevantes, para facilitar el entrenamiento del modelo y evitar ruido innecesario.

Construcción del modelo de regresión con Naive Bayes

Para predecir el precio de los alojamientos se utilizó un enfoque de Naive Bayes. Como este algoritmo trabaja de forma natural con clases, primero se discretizó la variable price en 10 intervalos usando cuantiles. Después, se entrenó el modelo con esas clases y finalmente se transformaron las predicciones nuevamente a valores continuos usando el precio promedio de cada intervalo.

Este procedimiento permitió adaptar el algoritmo para un problema de regresión. Sin embargo, como se verá en los resultados, el modelo tuvo dificultades para representar correctamente la variación real de los precios, especialmente en los valores más altos.

Resultados del modelo

Para evaluar el desempeño del modelo se usaron las métricas MAE, RMSE, R^2 y MAPE, ya que estas permiten medir el error promedio, la magnitud de los errores grandes y qué tanto logra explicar el modelo la variación de la variable respuesta.

En entrenamiento, el modelo obtuvo un MAE de 636.25, un RMSE de 4262.75, un R^2 de -0.0136 y un MAPE de 49.55%. En prueba, obtuvo un MAE de 664.50, un RMSE de 4347.22, un R^2 de -0.0145 y un MAPE de 51.23%.

Tabla 2. Métricas del modelo de regresión con Naive Bayes

Métrica	Entrenamiento	Prueba
MAE	636.25	664.50
RMSE	4262.75	4347.22
R^2	-0.0136	-0.0145
MAPE (%)	49.55	51.23

La Tabla 2 muestra que el modelo tuvo errores relativamente altos tanto en entrenamiento como en prueba. Además, el valor negativo de R^2 indica que el modelo no logró explicar adecuadamente la variación del precio y que su desempeño fue muy bajo.

Análisis del desempeño del modelo


En general, el modelo de regresión con Naive Bayes no tuvo un buen desempeño para predecir el precio de los alojamientos. Esto se observa principalmente en dos aspectos. Primero, el MAPE en prueba fue de 51.23%, lo que significa que, en promedio, las predicciones se desviaron bastante del valor real. Segundo, el R^2 negativo indica que el modelo no logró capturar bien la relación entre las variables predictoras y el precio.

También se observa que las métricas de entrenamiento y prueba son bastante parecidas. Esto sugiere que el problema principal no parece ser sobreajuste, sino más bien que el modelo no logra ajustarse bien al comportamiento real de los datos. En otras palabras, el algoritmo quedó corto para representar la complejidad del precio.

Una posible razón es que la variable price presenta una distribución muy dispersa. En los datos limpiados, el precio tiene una mediana de 193, pero alcanza valores máximos de 50,123, lo cual muestra la presencia de valores extremos muy altos. Esto hace que el algoritmo tienda a predecir valores más moderados y falle al estimar alojamientos mucho más caros.


Análisis visual de las predicciones

Gráfico 1. Comparación entre precio real y precio predicho por el modelo



En este gráfico se comparan los valores reales contra los valores predichos. Si el modelo funcionara bien, la mayoría de los puntos deberían quedar cerca de la línea diagonal. Sin embargo, se observa que muchos puntos están alejados de esa línea y que las predicciones se concentran en valores relativamente bajos. Esto indica que el modelo tuvo dificultades para ajustarse a precios altos y que en muchos casos subestimó el valor real de los alojamientos.

Gráfico 2. Distribución de errores del modelo de regresión



Este gráfico muestra cómo se distribuyen los errores del modelo. La mayoría de los errores se concentra cerca de cero, pero también aparecen errores muy grandes hacia la derecha. Esto

indica que, aunque en algunos casos el modelo se acercó al valor real, en otros cometió errores bastante altos, especialmente cuando los precios reales eran elevados.

Conclusión

Con base en los resultados obtenidos, se concluye que el modelo de regresión con Naive Bayes no fue suficientemente preciso para predecir el precio de los alojamientos. Aunque el procedimiento permitió generar predicciones y evaluar el comportamiento del algoritmo, las métricas muestran que el desempeño fue bajo y que el modelo no logró representar correctamente la variación del precio en el conjunto de datos.

Aun así, esta parte del análisis fue útil para identificar las limitaciones del algoritmo en un problema de regresión con una variable tan dispersa como el precio. Estos resultados servirán más adelante para compararlo con otros modelos, como regresión lineal y árbol de regresión, y así determinar cuál funciona mejor bajo las mismas condiciones.

Comparación de los modelos de regresión:

Se realizó una comparación entre los modelos de regresión desarrollados en las etapas anteriores: regresión lineal y árbol de regresión, con el objetivo de evaluar su capacidad para predecir el precio de las propiedades utilizando el RMSE como métrica de evaluación.

Los resultados muestran una diferencia significativa en el desempeño de ambos modelos. La regresión lineal presentó un error considerablemente alto, lo que indica que no logra capturar adecuadamente la relación entre variables. Esto se debe a que este modelo asume una relación lineal entre las variables, condición que no se cumple en el dataset, donde existen relaciones más complejas y no lineales.

Por otro lado, el árbol de regresión obtuvo un error menor, evidenciando una mejor capacidad predictiva. Esto se debe a que los árboles de decisión sí pueden modelar relaciones de tipo no lineales y capturar interacciones entre variables sin necesidad de asumir una forma funcional que sea específica.

El modelo Naive Bayes presentó el peor desempeño de los 3 modelos, incluso superior a la regresión lineal. Lo cual explica por qué este modelo asume independencia entre variables y distribuciones normales, condiciones que no se cumplen en el dataset, donde variables como `accommodatesm bedrooms` y `beds` presentan correlación entre sí.

En conclusión, el árbol de regresión es el modelo que presenta el mejor desempeño para la predicción del precio, mientras que Naive Bayes resulta ser el menos adecuado para este problema.

Modelo	RMSE
Regresión lineal	4297.59
Árbol (depth = 10)	37.43
Naive Bayes	4347.22

Tabla 3. Comparación de RMSE de los modelos

Modelo de clasificación: Naive Bayes

Para la clasificación de precios se utilizó el modelo Naive Bayes Gaussiano, el cual es adecuado para variables numéricas continuas.

Antes de entrenar el modelo, se realizó un preprocesamiento de los datos que incluyó:

- Limpieza de la variable price, eliminando símbolos y convirtiéndola a formato numérico
- Eliminación de valores atípicos (outliers) para reducir ruido en los datos
- Creación de una variable categórica del precio (barata, media, cara) utilizando cuantiles
- Selección de variables relevantes como:
 - accommodates
 - bathrooms
 - bedrooms
 - beds
 - review_scores_rating
 - number_of_reviews
 - availability_365
- Eliminación de valores nulos
- Normalización de las variables numéricas mediante StandardScaler

Posteriormente, se dividieron los datos en entrenamiento (80%) y prueba (20%).

Entrenamiento del modelo

Se utilizó el algoritmo **Gaussian Naive Bayes**, el cual modela la distribución de cada variable como una distribución normal y asume independencia entre ellas.

El modelo fue entrenado con el conjunto de entrenamiento y posteriormente se realizaron predicciones sobre el conjunto de prueba.

Evaluación de los modelos en el conjunto de prueba:

- **Evaluación de modelos de clasificación**

Para evaluar la eficiencia de los modelos de clasificación, se utilizaron los datos del conjunto de prueba, y la métrica RMSE , lo que permite analizar la capacidad de generalización de los modelos ante datos no vistos.

El árbol de regresión obtuvo el menor error ($RMSE \approx 37.43$), lo que indica una alta precisión en la predicción del precio. En contraste, la regresión lineal presentó un error considerablemente mayor ($RMSE \approx 4297.59$), evidenciando una baja capacidad para modelar la relación entre las variables.

Por otro lado el modelo de Naive Bayes presentó el peor desempeño ($RMSE \approx 4347.22$), incluso superior al de la regresión lineal. Esto confirma que no es adecuado para este problema, debido a que asume independencia entre variables y distribuciones normales, condiciones que no se cumplen en el dataset.

- **Análisis comparativo de desempeño**

La diferencia en el desempeño entre los modelos se explica principalmente por los supuestos que cada uno realiza y la naturaleza de los datos.

Los modelos basados en árboles presentan un mejor desempeño debido a que no dependen de supuestos estrictos como la independencia entre variables o la normalidad de los datos, lo que les permite adaptarse mejor a relaciones no lineales y patrones complejos.

En contraste, el modelo de Naive Bayes se ve limitado por sus supuestos, los cuales no se cumplen en el dataset, ya que existen correlaciones entre variables y solapamiento entre las clases, especialmente en la categoría intermedia. Esto afecta su capacidad de clasificación y predicción.


- **Conclusión de las evaluaciones:**

En general, los resultados muestran que los modelos basados en árboles son los más eficientes tanto para la predicción como para la clasificación en este problema.

El modelo de Naive Bayes, aunque es simple y computacionalmente eficiente, presenta limitaciones importantes que reducen su desempeño en comparación con modelos más flexibles.

Por lo tanto, se concluye que los modelos de árboles son la mejor opción para este conjunto de datos.

Matriz de confusión



Métricas de clasificación (precision, recall, f1-score)

```
[[3608  197  613]
 [ 717 1868 1283]
 [2220  571 1434]]
```

	precision	recall	f1-score	support
barata	0.55	0.82	0.66	4418
cara	0.71	0.48	0.57	3868
media	0.43	0.34	0.38	4225
accuracy			0.55	12511
macro avg	0.56	0.55	0.54	12511
weighted avg	0.56	0.55	0.54	12511

El modelo obtuvo una precisión global aproximada del 55%, lo cual indica un desempeño moderado.

Análisis de la matriz de confusión

Se identificaron los siguientes comportamientos:

- La clase **barata** fue la mejor clasificada, con un alto número de aciertos
- La clase **media** presentó el peor desempeño, siendo frecuentemente confundida con las otras dos categorías
- La clase **cara** mostró errores importantes, especialmente al ser clasificada como **barata**

El modelo tiende a confundirse principalmente entre:

- media ↔ barata
- media ↔ cara

Esto indica que existe un solapamiento entre las características de estas categorías.

Análisis de errores

Los errores más relevantes del modelo son:

- Clasificar propiedades **caras como baratas**, lo cual puede tener un impacto significativo en decisiones económicas
- Dificultad para identificar correctamente propiedades de precio medio

Estos errores se deben principalmente a:

- La similitud de características entre propiedades de diferentes rangos de precio
- La naturaleza del modelo Naive Bayes, que asume independencia entre variables, lo cual no siempre se cumple en este dataset

Conclusión de esta sección

El modelo Naive Bayes permitió realizar la clasificación de precios de manera eficiente, obteniendo resultados aceptables para un modelo probabilístico simple.

Sin embargo, su desempeño se ve limitado por:

- La complejidad del problema
- El solapamiento entre clases
- La dependencia entre variables

A pesar de estas limitaciones, el modelo cumple con el objetivo de clasificar las propiedades en categorías de precio y permite identificar patrones generales en los datos.