

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Minería de datos

Semestre I – 2026



Laboratorio 5

Integrantes:

Ciprian Jimenez, Mishell Rosa Elvira – 231169

Nájera Marakovits, Ingrid Nina Alessandra - 231088

Ramírez Velásquez, Diego Alejandro – 23601

Comparación de los modelos de regresión:

Se realizó una comparación entre los modelos de regresión desarrollados en las etapas anteriores: regresión lineal y árbol de regresión, con el objetivo de evaluar su capacidad para predecir el precio de las propiedades.

Los resultados muestran una diferencia significativa en el desempeño de ambos modelos. La regresión lineal presentó un error considerablemente alto, lo que indica que no logra capturar adecuadamente la relación entre variables. Esto se debe a que este modelo asume una relación lineal entre las variables, condición que no se cumple en el dataset, donde existen relaciones más complejas y no lineales.

Por otro lado, el árbol de regresión obtuvo un error menor, evidenciando una mejor capacidad predictiva. Esto se debe a que los árboles de decisión sí pueden modelar relaciones de tipo no lineales y capturar interacciones entre variables sin necesidad de asumir una forma funcional que sea específica.

Modelo de clasificación: Naive Bayes

Para la clasificación de precios se utilizó el modelo Naive Bayes Gaussiano, el cual es adecuado para variables numéricas continuas.

Antes de entrenar el modelo, se realizó un preprocesamiento de los datos que incluyó:

- Limpieza de la variable price, eliminando símbolos y convirtiéndola a formato numérico
- Eliminación de valores atípicos (outliers) para reducir ruido en los datos
- Creación de una variable categórica del precio (barata, media, cara) utilizando cuantiles
- Selección de variables relevantes como:
 - accommodates
 - bathrooms
 - bedrooms
 - beds
 - review_scores_rating
 - number_of_reviews
 - availability_365
- Eliminación de valores nulos
- Normalización de las variables numéricas mediante `StandardScaler`

Posteriormente, se dividieron los datos en entrenamiento (80%) y prueba (20%).


Entrenamiento del modelo

Se utilizó el algoritmo **Gaussian Naive Bayes**, el cual modela la distribución de cada variable como una distribución normal y asume independencia entre ellas.

El modelo fue entrenado con el conjunto de entrenamiento y posteriormente se realizaron predicciones sobre el conjunto de prueba.

Evaluación de los modelos en el conjunto de prueba:

Matriz de confusión



Métricas de clasificación (precision, recall, f1-score)

```
[[3608  197  613]
 [ 717 1868 1283]
 [2220  571 1434]]
```

	precision	recall	f1-score	support
barata	0.55	0.82	0.66	4418
cara	0.71	0.48	0.57	3868
media	0.43	0.34	0.38	4225
accuracy			0.55	12511
macro avg	0.56	0.55	0.54	12511
weighted avg	0.56	0.55	0.54	12511

El modelo obtuvo una precisión global aproximada del 55%, lo cual indica un desempeño moderado.

Análisis de la matriz de confusión

Se identificaron los siguientes comportamientos:

- La clase **barata** fue la mejor clasificada, con un alto número de aciertos
- La clase **media** presentó el peor desempeño, siendo frecuentemente confundida con las otras dos categorías

- La clase **cara** mostró errores importantes, especialmente al ser clasificada como **barata**

El modelo tiende a confundirse principalmente entre:

- media ↔ barata
- media ↔ cara

Esto indica que existe un solapamiento entre las características de estas categorías.

Análisis de errores

Los errores más relevantes del modelo son:

- Clasificar propiedades **caras como baratas**, lo cual puede tener un impacto significativo en decisiones económicas
- Dificultad para identificar correctamente propiedades de precio medio

Estos errores se deben principalmente a:

- La similitud de características entre propiedades de diferentes rangos de precio
- La naturaleza del modelo Naive Bayes, que asume independencia entre variables, lo cual no siempre se cumple en este dataset

Conclusión de esta sección

El modelo Naive Bayes permitió realizar la clasificación de precios de manera eficiente, obteniendo resultados aceptables para un modelo probabilístico simple.

Sin embargo, su desempeño se ve limitado por:

- La complejidad del problema
- El solapamiento entre clases
- La dependencia entre variables

A pesar de estas limitaciones, el modelo cumple con el objetivo de clasificar las propiedades en categorías de precio y permite identificar patrones generales en los datos.