

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Minería de datos

Semestre I – 2026



Proyecto 1

Integrantes:

Canastuj Matías, Eliazar José Pablo - 23384

Ciprian Jimenez, Mishell Rosa Elvira – 231169

Lou Schwank, Anthony - 23410

Nájera Marakovits, Ingrid Nina Alessandra - 231088

Ramírez Velásquez, Diego Alejandro – 23601

1. Selección de la variable de respuesta

- **Variable respuesta propuesta**

Se propone como variable respuesta la etapa de vida de la pareja al momento del divorcio. Esta variable se construye a partir del promedio de edad de ambos cónyuges, con el objetivo de representar de manera más general el momento del ciclo de vida en el que ocurre el divorcio.

- **Tipo de variable**

La variable respuesta es cualitativa ordinal, ya que se expresa en categorías con un orden natural. En este caso, las categorías representarían etapas de vida, por ejemplo: temprana, intermedia y tardía.

- **Justificación de la elección**

Se eligió esta variable porque permite analizar si existen patrones sociodemográficos asociados a la etapa de vida en la que ocurre el divorcio. Además, es una variable interpretable y útil para construir modelos predictivos, ya que puede relacionarse con otras variables disponibles en el conjunto de datos, como escolaridad, ocupación, nacionalidad, departamento y temporalidad del registro.

- **Transformaciones realizadas**

Para construir la variable respuesta, primero se toman las edades de ambos cónyuges y se calcula el promedio de edad de la pareja. Posteriormente, este valor numérico se transforma en una variable categórica ordinal, agrupándolo en etapas de vida. Los puntos de corte para definir cada categoría se establecerán con base en la distribución observada en el análisis exploratorio de datos, con el fin de evitar clases demasiado desbalanceadas y mantener una interpretación adecuada.

Adicionalmente, para trabajar con esta variable se contempla revisar registros con valores faltantes o inconsistentes en las edades, ya que estos podrían afectar la construcción correcta de la variable respuesta.

2. Proyectos similares (investigación)

What Tears Couples Apart: A Machine Learning Analysis of Union Dissolution in Germany

Este estudio analiza la disolución de uniones de pareja en Alemania utilizando datos longitudinales provenientes del German Socio-Economic Panel, que incluye información de más de dos mil parejas. Los autores aplican modelos de Random Survival Forests, con el objetivo de identificar los factores que influyen en la probabilidad de ruptura y estimar cuándo es más probable que ocurra. El análisis incorpora variables individuales y de pareja, como satisfacción de vida, condiciones

laborales, distribución del trabajo doméstico y características socioeconómicas, permitiendo modelar relaciones complejas y no lineales en el proceso de disolución.

Predictors of divorce and duration of marriage among first marriage women in Dejene administrative town

(Shita, 2024) Este trabajo examina los factores asociados al divorcio y a la duración del matrimonio en mujeres que contrajeron matrimonio por primera vez en Etiopía. Para ello, utiliza una combinación de regresión logística binaria para modelar la ocurrencia del divorcio y un modelo de supervivencia Gompertz para analizar el tiempo hasta la disolución del matrimonio. El estudio considera variables demográficas, sociales y familiares, como edad al matrimonio, número de hijos, nivel educativo y condiciones del hogar, con el fin de identificar qué factores aumentan el riesgo de divorcio y cómo estos influyen en la duración del vínculo conyugal.

Divorce prediction using machine learning algorithms in Ha'il region

Este estudio analiza la predicción del divorcio mediante el uso de diferentes algoritmos de aprendizaje automático, con el objetivo de comparar su desempeño. Para ello, se utiliza un conjunto de datos basado en evaluaciones de terapia de pareja, que incluye múltiples variables relacionadas con la relación y el comportamiento de los cónyuges.

En la investigación se aplican modelos como redes neuronales artificiales (ANN), Naive Bayes y Random Forest. Los resultados muestran que las redes neuronales alcanzan la mayor precisión, aproximadamente un 96%, lo que evidencia la capacidad de estos modelos para capturar relaciones complejas en los datos y mejorar la predicción del divorcio.

Modelo predictivo de divorcio utilizando Random Forest en datos sociodemográficos

Este trabajo desarrolla un modelo predictivo de divorcio utilizando el algoritmo Random Forest, aplicado a variables sociodemográficas como la edad de los cónyuges, la duración del matrimonio y el número de hijos. El objetivo del estudio es identificar patrones asociados a la disolución del matrimonio y determinar los factores más influyentes. Los resultados evidencian que Random Forest es capaz de capturar relaciones complejas entre variables, logrando un buen desempeño predictivo y permitiendo identificar los principales factores asociados al divorcio en contextos latinoamericanos.

3. Antecedentes

En los últimos años, el análisis del divorcio y la disolución de parejas ha sido abordado mediante distintos enfoques metodológicos que combinan modelos estadísticos tradicionales con técnicas de aprendizaje automático. Estos estudios no solo buscan identificar los factores asociados al divorcio, sino también desarrollar modelos predictivos capaces de capturar patrones complejos en datos sociodemográficos, lo cual resulta clave para problemas de clasificación como el planteado en este proyecto.

Un trabajo relevante en este campo es *“What Tears Couples Apart: A Machine Learning Analysis of Union Dissolution in Germany”*, en el cual se analiza la disolución de parejas utilizando datos longitudinales del German Socio-Economic Panel. Este estudio emplea el algoritmo Random Survival Forest, un modelo basado en árboles que permite capturar relaciones no lineales y manejar múltiples variables simultáneamente. Los resultados muestran que este tipo de modelos tiene una alta capacidad para identificar patrones complejos en la disolución de parejas. Este enfoque es particularmente relevante, ya que evidencia la efectividad de los métodos basados en árboles —como Random Forest y Gradient Boosting— en problemas donde existen interacciones complejas entre variables, tal como ocurre en el conjunto de datos de este proyecto. (Arpino, Le Moglie, & Mencarini, 2022)

Por otro lado, el estudio *“Predictors of divorce and duration of marriage among first married women in Ethiopia: the application of survival and binary logistic regressions”* aborda el problema desde un enfoque estadístico, utilizando regresión logística binaria y modelos de supervivencia. Este trabajo demuestra que variables como la edad, el nivel educativo y el número de hijos influyen significativamente en la probabilidad de divorcio. La relevancia de este estudio radica en el uso de modelos interpretables, lo cual respalda la elección de la regresión logística ordinal en este proyecto, ya que permite analizar cómo las variables influyen en la probabilidad de pertenecer a distintas categorías ordenadas de la variable respuesta. (Shita, 2024)

En el ámbito del aprendizaje automático, el estudio *“Divorce prediction using machine learning algorithms in Ha'il region”* presenta una comparación entre distintos algoritmos, incluyendo redes neuronales artificiales (ANN), Naive Bayes y Random Forest. Los resultados indican que las redes neuronales alcanzan una precisión cercana al 96%, evidenciando su capacidad para capturar relaciones complejas entre variables. Este tipo de resultados refuerza la importancia de considerar modelos capaces de manejar no linealidad e interacciones complejas, como los métodos de Gradient Boosting, los cuales comparten esta capacidad, pero con mejor desempeño en datos tabulares como los utilizados en este proyecto. (Moumen, Shafqat, & Alraqad, 2024).

Asimismo, en el contexto latinoamericano se han desarrollado investigaciones que utilizan algoritmos de aprendizaje automático para analizar el divorcio a partir de variables sociodemográficas. Un ejemplo de ello es el estudio *“Modelo predictivo de divorcio utilizando Random Forest en datos sociodemográficos”*, en el cual se emplea este algoritmo para identificar patrones asociados a la disolución del matrimonio. Los resultados evidencian que Random Forest permite capturar relaciones no lineales y manejar datos heterogéneos de manera eficiente. Este hallazgo es especialmente relevante, ya que el conjunto de datos del presente proyecto presenta características similares, como la combinación de variables categóricas y numéricas, lo cual respalda la selección de modelos basados en árboles dentro de los algoritmos a evaluar. (Gálvez Mora, 2025)

En conjunto, los estudios revisados muestran que no existe un único enfoque para abordar el análisis del divorcio, sino que diferentes tipos de modelos aportan ventajas específicas. Los modelos estadísticos tradicionales ofrecen interpretabilidad, mientras que los algoritmos de aprendizaje automático permiten mejorar el desempeño predictivo al capturar relaciones complejas. Esta evidencia respalda la estrategia adoptada en este proyecto de combinar distintos enfoques, incluyendo modelos interpretables como la regresión logística ordinal y modelos más robustos como Random Forest y Gradient Boosting.

Para el presente proyecto, estos antecedentes son fundamentales, ya que el objetivo es predecir la **etapa de vida de la pareja al momento del divorcio**, lo cual corresponde a un problema de clasificación ordinal. A partir de la literatura revisada, se justifica la selección de algoritmos que permitan tanto interpretar los resultados como capturar patrones complejos en los datos, asegurando así un balance entre explicabilidad y desempeño predictivo.

Para sintetizar los principales enfoques utilizados en los estudios revisados, se presenta la siguiente tabla comparativa:

Estudio	Tipo de Modelo	Variables utilizadas	Aporte principal
What Tears Couples Apart: A Machine Learning Analysis of Union Dissolution in Germany	Random Survival Forest	Variables socioeconómicas y de pareja	Captura relaciones no lineales en la disolución
Predictors of divorce and duration of marriage among first marriage women in Dejne administrative town	Regresión logística + supervivencia	Edad, educación, hijos	Alta interpretabilidad

Divorce prediction using machine learning algorithms in Ha'il region, KSA	ANN, Naive Bayes, Random Forest	Variables de comportamiento de pareja	ANN logra mayor precisión (~96%)
Modelo de predicción de divorcio en el Ecuador basado en algoritmos de aprendizaje de máquina	Random Forest	Variables sociodemográficas	Identificación de factores clave en Latinoamérica

Tabla 1 comparativa de artículos

4. Algoritmos de aprendizaje más útiles

Dado que la variable respuesta propuesta es la etapa de vida de la pareja al momento del divorcio, definida como una variable cualitativa ordinal, el problema a resolver corresponde a una clasificación ordinal. Esta variable fue construida a partir del promedio de edad de ambos cónyuges, agrupado en categorías ordenadas según la distribución observada en el análisis exploratorio.

Además, el conjunto de datos contiene 71,576 observaciones y 23 variables, con una combinación de variables categóricas y numéricas. Entre ellas destacan variables demográficas, geográficas y temporales, así como las edades de ambos cónyuges, que muestran una relación positiva fuerte entre sí. Estas características sugieren que conviene evaluar algoritmos capaces de trabajar bien con datos heterogéneos, posibles relaciones no lineales y clases ordinales.

4.1. Regresión logística ordinal

La regresión logística ordinal es uno de los algoritmos más adecuados para este problema, porque está diseñada específicamente para variables respuesta con categorías ordenadas. A diferencia de una clasificación multiclase tradicional, este modelo sí toma en cuenta que las categorías tienen un orden natural, por ejemplo, etapa temprana, intermedia y tardía.

Su principal ventaja es la interpretabilidad, ya que permite identificar cómo influyen variables como escolaridad, nacionalidad, ocupación, departamento o temporalidad en la probabilidad de que un divorcio ocurra en una etapa de vida más temprana o tardía. Esto es especialmente útil en un proyecto académico, porque no solo interesa predecir, sino también explicar los patrones encontrados.

Sin embargo, este algoritmo puede quedarse corto si la relación entre predictores y variable respuesta es altamente no lineal o si existen interacciones complejas entre muchas variables categóricas. Por ello, resulta conveniente usarlo como un modelo base e interpretable, pero no como única opción.

4.2 Bosques aleatorios (Random Forest)

El algoritmo **Random Forest** también es una muy buena alternativa para este problema. Este método construye múltiples árboles de decisión y combina sus resultados, lo que suele producir modelos más robustos y con mejor capacidad predictiva que un árbol individual.

Su utilidad en este caso radica en que puede capturar relaciones complejas entre variables, manejar interacciones entre atributos demográficos y geográficos, y trabajar bien con grandes volúmenes de datos como el conjunto analizado. También es menos sensible al ruido y al sobreajuste que un árbol de decisión simple.

Otra ventaja importante es que permite obtener medidas de **importancia de variables**, lo cual ayudaría a identificar cuáles factores explican mejor la etapa de vida de la pareja al momento del divorcio. Por ejemplo, podría revelar si la escolaridad, la nacionalidad, el departamento o ciertas variables temporales tienen más peso que otras.

Como limitación, Random Forest no modela explícitamente la naturaleza ordinal de la variable respuesta, sino que la trata como una clasificación categórica general. Aun así, sigue siendo una opción muy útil por su buen desempeño predictivo y su capacidad para manejar estructuras complejas en los datos.

4.3 Gradient Boosting

Los modelos de **Gradient Boosting**, como XGBoost, LightGBM o CatBoost, estos son otra alternativa altamente recomendable. Estos algoritmos construyen árboles secuenciales donde cada nuevo árbol corrige errores del anterior, lo que suele producir muy buen rendimiento predictivo.

Para este proyecto son especialmente útiles porque:

- manejan bien bases de datos grandes,
- capturan relaciones no lineales e interacciones complejas,
- suelen superar en precisión a modelos lineales,
- y pueden adaptarse bien a variables categóricas y numéricas.

Dentro de esta familia, **CatBoost** sería una opción especialmente atractiva si se trabaja con muchas variables categóricas, ya que fue diseñado precisamente para

este tipo de datos. En su conjunto de divorcios, gran parte de las variables disponibles son categóricas, como departamento, municipio, nacionalidad, escolaridad, pueblo, ocupación y grupo étnico. Por ello, un modelo de boosting puede aprovechar de mejor forma la información disponible.

Su principal desventaja es que suele ser menos interpretable que la regresión ordinal y requiere ajuste de hiperparámetros. Sin embargo, si el objetivo principal es obtener la mejor capacidad predictiva posible, probablemente sea uno de los candidatos más fuertes.

4.4 Árbol de decisión

Un **árbol de decisión** también puede considerarse como algoritmo candidato, especialmente por su simplicidad e interpretabilidad. Este modelo genera reglas claras del tipo “si la escolaridad es X y el departamento es Y, entonces la pareja pertenece a cierta etapa de vida”, lo que facilita mucho la explicación de resultados.

No obstante, los árboles individuales suelen ser inestables y más propensos al sobreajuste que métodos ensamblados como Random Forest o Gradient Boosting. Por ello, aunque es valioso como punto de comparación y como modelo fácil de explicar, normalmente no sería la mejor opción final si se busca maximizar desempeño predictivo.

Selección final de los tres algoritmos a utilizar

Con base en las características del problema y del conjunto de datos, se propone trabajar con los siguientes tres algoritmos:

1. Regresión logística ordinal

Se selecciona porque la variable respuesta es ordinal y este modelo aprovecha directamente ese orden. Además, ofrece alta interpretabilidad, lo cual permite explicar los factores asociados a cada etapa de vida.

2. Random Forest

Se selecciona porque puede manejar relaciones no lineales, múltiples variables categóricas y una base de datos grande. También ofrece una medida útil de importancia de variables.

3. Gradient Boosting (preferiblemente CatBoost o XGBoost)

Se selecciona porque suele ofrecer alto rendimiento predictivo en problemas tabulares, especialmente cuando existen muchas variables categóricas y relaciones complejas entre los predictores.

Para sintetizar las características de los algoritmos seleccionados, se presenta la siguiente tabla:

Algoritmo	Tipo	Ventajas	Desventajas	Uso en el proyecto
Regresión logística ordinal	Modelo estadístico	Alta interpretabilidad.	No captura bien relaciones complejas	Modelo base explicativo
Random Forest	Ensamble de árboles	Maneja datos heterogéneos, robustos	No considera ordinalidad	Modelo predictivo principal
Gradient Boosting	Ensamble secuencial	Alta precisión, captura no linealidad	Menos interpretable	Modelo de alto rendimiento.

Tabla 2 . Comparación de algoritmos de aprendizaje seleccionados.

Justificación de la selección

La combinación de estos tres algoritmos permite comparar enfoques complementarios:

- un modelo **estadístico e interpretable** que respeta la naturaleza ordinal de la respuesta,
Un modelo **ensamblado robusto** y fácil de analizar,
y un modelo **más potente predictivamente** para capturar patrones complejos.

De esta forma, la comparación entre los tres permitirá identificar cuál logra el mejor equilibrio entre **interpretabilidad, manejo de la ordinalidad y desempeño predictivo**.

Referencias bibliográficas.

- Arpino, B., Le Moglie, M., & Mencarini, L. (febrero de 2022). What Tears Couples Apart: A Machine Learning Analysis of Union Dissolution in Germany. *Demography*, 59, págs. 161-182.
doi:<https://read.dukeupress.edu/demography/article/59/1/161/293326/What-Tears-Couples-Apart-A-Machine-Learning>
- Gálvez Mora, P. G. (2025). *Modelo de predicción de divorcio en el Ecuador basado en algoritmos de aprendizaje de máquina*. Obtenido de Repositorio Universidad de las Américas: <http://dspace.udla.edu.ec/handle/33000/17280>
- Moumen, A., Shafqat, A., & Alraqad, T. (2024). Divorce prediction using machine learning algorithms in Ha'il region, KSA. *Scientific Reports*, 14, pág. 502.
doi:<https://www.nature.com/articles/s41598-023-50839-1>
- Shita, N. Z. (2024). Predictors of divorce and duration of marriage among first marriage women in Dejne administrative town. *Scientific Reports*, 14, pág. 8728.
doi:<https://doi.org/10.1038/s41598-024-59360-5>